Título: High-frequency Component Helps Explain the Generalization of Convolutional Neural Networks

Ano: 2019 | **Veículo:** CVPR (IEEE/CVF Conference on Computer Vision and Pattern Recognition)

Resumo Geral

Esse estudo investiga como as redes neurais convolucionais (CNNs) processam informações imperceptíveis ao olho humano, especificamente os componentes de alta frequência das imagens. Os autores demonstram que, enquanto as pessoas dependem de sinais de baixa frequência para o reconhecimento, os modelos exploram padrões detalhados que levam a comportamentos intuitivamente estranhos, como a vulnerabilidade a ataques adversários. A pesquisa revela que técnicas comuns para aumentar a precisão, como BatchNorm e Mix-up, podem involuntariamente incentivar o uso dessas frequências altas, sacrificando a robustez do modelo. Além disso, o texto propõe que o ajuste da suavidade dos filtros convolucionais pode servir como uma defesa simples contra manipulações maliciosas. Por fim, a análise sugere uma disparidade fundamental entre a percepção artificial e a biológica, defendendo uma reavaliação de como medimos o sucesso no aprendizado de máquina.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Outra / Suavização/Blur	Filtragem espectral via Transformada de Fourier (LFC/HFC) e suavização espacial de kernels convolucionais.
Arquitetura(s)	ResNet, VGG, AlexNet, CNN rasa/custom	ResNet-18 (base), ResNet-50 (backbone detector), VGG, AlexNet, LeNet e RetinaNet (com FPN).
Dataset(s)	CIFAR10, MNIST, FashionMNIST, ImageNet, COCO	CIFAR10 como base principal; COCO para validação em detecção de objetos.

Métrica(s) de desempenho	Acurácia, Outra (mAP)	Acurácia para classificação e mean Average Precision (mAP) para detecção de objetos.
Análise de frequência/espectral?	Sim	Pilar central do estudo (Transformada de Fourier, HFC/LFC).
Intensidade em múltiplos níveis?	Sim	Raios de filtragem r, suavidade do kernel e intensidade adversária .
Múltiplas arquiteturas?	Sim	Comparação explícita de generalização entre LeNet, AlexNet, VGG e ResNet.
Código/Dados públicos?	Sim	Disponibilizado no GitHub (HaohanWang/HFC).

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

A pesquisa comprova que as intervenções têm efeitos opostos dependendo do cenário (dados limpos vs. ataques adversários):

- **Suavização de Kernels:** A piora na acurácia em dados limpos (ex: de 85,6% para 63,1% no modelo *vanilla*) é acompanhada por uma melhoria expressiva sob ataque adversário (ex: PGD sobe de 0,3% para 8,6%).

- **Heurísticas de Treino (Mix-up e BatchNorm):** Melhoram a acurácia em dados limpos porque incentivam a captura de alta frequência (HFC), mas consequentemente destroem a robustez adversária.

- **Filtragem HFC vs. LFC:** Treinar/testar com baixa frequência (LFC) mantém uma boa generalização (~77% no CIFAR10). Focar apenas em HFC derruba a acurácia para níveis próximos ao acaso (~10% a 12%).

Mecanismos Explicativos Propostos

O estudo não apresenta apenas dados empíricos, mas fornece explicações causais profundas:

- **Disparidade Perceptual:** Humanos usam sinais semânticos de baixa frequência (LFC). CNNs minimizam a perda explorando sinais imperceptíveis de alta frequência (HFC).

- **Memorização de Rótulos Embaralhados:** Sem a correlação natural LFC-rótulo, as CNNs tratam LFC e HFC de forma igual para memorizar dados ruidosos, gerando *overfitting* de alta frequência.

- **Papel do Batch Normalization (BN):** O BN equilibra magnitudes. Como HFC tem magnitude menor que LFC, a normalização permite que o modelo aprenda ambos simultaneamente (acelerando convergência, mas introduzindo vulnerabilidade adversária).

- **Teorema da Convolução:** Filtros espacialmente suaves atuam como filtros passa-baixa naturais. Forçar essa suavidade impede a CNN de depender das frágeis altas frequências.

Relevância para as Questões de Pesquisa (RQs) do SLR

- **RQ1 (Degradação existe):** *Altamente relevante.* Demonstra quantitativamente a perda de desempenho (acurácia e mAP) ao alterar frequências ou aplicar suavização.

- **RQ2 (Mecanismo explicativo):** *Altamente relevante (Foco Principal).* Trabalho seminal que introduz a hipótese do espectro de frequência para explicar a vulnerabilidade adversária e a memorização de rótulos.

- **RQ3 (Relação energia-acurácia):** *Relevante.* Documenta variações exatas de acurácia com base no raio espectral preservado (r) e nível de suavidade ().

- **RQ4 (Condições de melhoria):** *Altamente relevante.* Propõe ativamente a suavização de kernels convolucionais como técnica defensiva para aumentar a robustez adversária.

Qualidade Metodológica e Validade

- **Configuração e Baseline:** Totalmente documentados (ADAM, 100 épocas, LR 10-4, Batch 100). Possui *baseline* claro (modelos *vanilla* sem pré-processamento).

- **Limitações Mencionadas:** Discute abertamente que a suavização direta do kernel só funciona na primeira camada, reflete sobre o "viés de sobrevivência" de técnicas de IA que imitam a visão humana para serem publicadas, e pontua a perda inevitável de HFC na delimitação de objetos pequenos.

Título: A Frequency Perspective of Adversarial Robustness

Autores: Maiya, Ehrlich, Agarwal, Lim, Goldstein & Shrivastava

Ano: 2021 | Veículo: pré-print arXiv (arXiv:2111.00861v1, 26/10/2021) — revisão por pares não informada

Decisão: ACEITAR

Justificativa: o estudo manipula diretamente o conteúdo espectral das imagens de entrada (zeragem probabilística de bandas de frequência via DCT durante o treino) e mede o efeito dessa manipulação sobre a acurácia de classificação em três datasets. Reporta

explicitamente quanto a acurácia cai em função da taxa de remoção e da banda removida, o que atende diretamente às RQ1 e RQ3. Além disso, propõe um mecanismo (a importância relativa das bandas de frequência é dependente do dataset) e critica frontalmente a premissa por trás das defesas por pré-processamento passa-baixa (blur gaussiano, JPEG), o que atende à RQ2.

Resumo Geral

O trabalho investiga a natureza dos exemplos adversários no domínio da frequência e contesta a ideia difundida de que eles seriam um fenômeno de alta frequência. Usando a DCT, os autores medem os "gradientes de perturbação" e mostram que a banda espectral explorada pelo ataque depende do dataset: em CIFAR-10 as ativações concentram-se em altas frequências, enquanto em TinyImageNet e ImageNet já se concentram em frequências baixas/médias mesmo antes do treinamento adversário. Em um segundo bloco de experimentos — o mais relevante para este SLR — treinam 36 modelos por dataset mascarando probabilisticamente bandas de frequência da entrada (9 taxas de remoção × 4 bandas) e medem a acurácia resultante. Por fim, propõem treinamento adversário restrito a subespaços de frequência e mostram que um parâmetro λ, que pondera perturbações de baixa vs. alta frequência, controla explicitamente o trade-off entre acurácia limpa e robustez.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Apêndice A.1 traz otimizador, épocas, learning rate, ε e arquitetura.
2. Utiliza baseline sem pré-processamento para comparação	Parcialmente	Os modelos de treino normal servem de referência, mas o valor da acurácia sem remoção espectral não é tabulado.
3. Reporta métricas quantitativas de classificação de forma clara	Parcialmente	Acurácia limpa e sob ataque são reportadas, mas quase sempre em gráficos; poucos valores numéricos no texto.
4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Hiperparâmetros descritos; não há link para código nem sementes.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	Seções 3, 5.2 e 6.2 propõem explicações causais.

6. Realiza análise no domínio da frequência / espectral	Sim	Pilar central: DCT, bandas 0–63, DCT-PGD.
7. Avalia mais de um dataset	Sim	CIFAR-10, TinyImageNet e ImageNet.
8. Avalia mais de uma arquitetura/modelo	Sim	ResNet-18 (principal) e VGG-16 (Apêndice A.4).
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Discute dependência de dataset, efeito do tamanho da imagem e o aliasing introduzido pelo operador Sgn; não há seção formal de limitações.
10. Publicado em veículo revisado por pares	Não informado	Documento em formato de submissão (arXiv); veículo revisado por pares não indicado.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Não informado	Não informado no texto.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Outra	Filtragem/mascaramento espectral por DCT: zeragem probabilística de bandas de frequência da entrada (bandas 0–15, 16–32, 32–48, 48–63) com taxa p. Blur gaussiano e compressão JPEG são discutidos como defesas, mas não avaliados experimentalmente.
Arquitetura(s)	ResNet, VGG	ResNet-18 em todos os experimentos principais; VGG-16 no Apêndice A.4 para confirmar independência de arquitetura.

Dataset(s)	CIFAR-10, TinyImageNet, ImageNet	Quantidade de imagens e número de classes não informados no texto; domínio: imagens naturais.
Métrica(s) de desempenho	Acurácia	Acurácia limpa e acurácia sob ataque (PGD e Auto-Attack em versão DCT).
Análise de frequência/espectral?	Sim	DCT tipo II; gradientes de perturbação no domínio DCT; occlusion score; bandas 0–63.
Intensidade em múltiplos níveis?	Sim	9 taxas de remoção p (até 0,9), 4 bandas de frequência, $\varepsilon \in \{1/255 \ldots 32/255\}$ e 10 valores de λ.
Múltiplas arquiteturas?	Sim	ResNet-18 vs. VGG-16.
Código/Dados públicos?	Não informado	Nenhuma disponibilização mencionada.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **A remoção espectral degrada, e a degradação escala com a taxa de remoção:** "As expected, we observe that a higher drop rate leads to lower accuracy" (Seção 5.2).

• **A magnitude da degradação depende fortemente do dataset:** removendo 90% das frequências da banda baixa (0–15), CIFAR-10 perde ~2% de acurácia, TinyImageNet ~10% e ImageNet ~35% (Seção 5.2, Figura 3).

• **Remover a banda mais alta pode ser inócuo:** taxas altíssimas de remoção nas frequências 48–63 têm "little to no effect" nos modelos que não são CIFAR-10 (Seção 5.2).

• **Trade-off controlável:** em TinyImageNet e ImageNet, treinar com perturbações de baixa frequência reduz a acurácia limpa e aumenta a robustez; em CIFAR-10 a robustez sobe e depois cai abruptamente (Seção 6.2, Figura 6).

Mecanismos Explicativos Propostos

• **Dependência de dataset, não de "alta frequência":** o conteúdo espectral explorado pelo ataque é uma propriedade do dataset; não há um viés universal para altas frequências.

• **Acoplamento entre baixas frequências e rótulos:** as baixas frequências carregam a informação ligada ao rótulo, por isso sua remoção extrema deixa o modelo sem sinal para aprender.

• **Viés de confirmação metodológico:** o sucesso inicial de defesas por blur/JPEG teria consolidado uma premissa incorreta, pois não se pode testar o cenário inverso (bloquear baixas frequências) sem destruir a informação de rótulo.

• **Frequências "que importam":** para ser robusto, o modelo só precisa ser treinado adversarialmente nas frequências relevantes do dataset, não em todo o espectro.

Evidência Espectral

Sim. Método: DCT tipo II (bidimensional, ordenação zigue-zague em 64 componentes) aplicada aos gradientes de perturbação e à própria entrada. Representação: coeficientes DCT por banda. Bandas analisadas: 0–15, 16–32, 32–48, 48–63 (baixas = 0–32, altas = 33–63). Tipo de energia: magnitude dos coeficientes DCT e "occlusion score" (queda de logit ao remover uma frequência). Relação com desempenho: quanto maior a fração de energia removida em uma banda, menor a acurácia, com inclinação fortemente dependente do dataset.

Limitações Reconhecidas pelos Autores

Os autores registram que o operador Sgn usado no ataque L∞ introduz aliasing de baixas para altas frequências, de modo que as perturbações não ficam estritamente contidas no conjunto de frequências escolhido (apenas as perturbações L2 ficam). Reconhecem também que suas conclusões contrariam trabalhos anteriores baseados só em CIFAR-10 e verificam a generalidade em outras arquiteturas, tamanhos de imagem e normas de ataque. Não há seção formal de ameaças à validade.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Quantifica a queda de acurácia em função da proporção de energia espectral removida, em três datasets.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Oferece um contraponto direto à hipótese "HFC": a banda crítica é dependente do dataset, e defesas passa-baixa foram validadas sob viés de confirmação.

• **RQ3 (Relação energia–acurácia):** Altamente relevante. A Figura 3 é essencialmente uma curva dose-resposta entre energia espectral removida (taxa p, por banda) e acurácia.

• **RQ4 (Condições de melhoria):** Relevante. O parâmetro λ mostra em que condições a manipulação espectral melhora a robustez sem colapsar a acurácia limpa.

Qualidade Metodológica e Validade

Ponto forte: escala experimental incomum (36 modelos por dataset só no experimento de mascaramento) e verificação sistemática de generalidade (outra arquitetura, outros tamanhos de imagem, outra norma). Ponto fraco para nossos fins: os resultados de acurácia estão majoritariamente em gráficos, sem tabelas, o que dificulta extrair valores exatos; não há disponibilização de código; e o veículo de publicação revisado por pares não é informado.

Título: On the Structural Sensitivity of Deep Convolutional Networks to the Directions of Fourier Basis Functions

Autores: Tsuzuku & Sato

Ano: 2019 | Veículo: CVPR 2019 (IEEE/CVF Conference on Computer Vision and Pattern Recognition)

Decisão: ACEITAR (caso limítrofe, ver ressalva)

Justificativa: o estudo modifica a imagem de entrada em bandas espectrais controladas (adição de uma única função de base de Fourier) e mede, frequência a frequência, quanto a predição do classificador muda, em 6 datasets e 8 arquiteturas. Fornece exatamente o tipo de evidência que a RQ2 e a RQ3 pedem: uma relação empírica entre a banda de frequência alterada e a magnitude da alteração de desempenho, acompanhada de uma explicação estrutural (os vetores singulares de camadas convolucionais são bases de Fourier). Ressalva: a manipulação é uma perturbação aditiva adversária, não uma técnica de pré-processamento voltada à qualidade perceptual — sua contribuição para o SLR é o eixo mecanismo/sensibilidade espectral, não a RQ1 clássica.

Resumo Geral

Os autores derivam, a partir da linearização de redes convolucionais, que os vetores singulares de camadas de convolução (com padding circular) são combinações de poucas funções de base de Fourier — e que isso vale também na presença de normalização, skip connections, stride > 1 e average pooling. A previsão teórica é que CNNs devem ser estruturalmente sensíveis a direções de Fourier específicas. Validam empiricamente varrendo todas as frequências de um mapa de Fourier e medindo o fool ratio (percentual de predições alteradas) de cada uma, em MNIST, FashionMNIST, SVHN, CIFAR-10, CIFAR-100 e ILSVRC2015, sobre MLP, LeNet, WideResNet, DenseNet-BC, VGG, ResNet-50 e GoogLeNet. O resultado é um mapa de calor de vulnerabilidade por frequência, do qual derivam um ataque universal caixa-preta (Single Fourier Attack).

Critérios de Qualidade

Critério de qualidade	Resposta	Observação
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Algoritmos 1 e 2 descrevem o procedimento; Seção 5.1 lista datasets, arquiteturas e orçamentos de perturbação.
2. Utiliza baseline sem pré-processamento para comparação	Sim	Ruído aleatório de mesma magnitude $\ell\infty$ e manipulação na base padrão (pixel) servem como controles explícitos (Tabelas 1 e 2).
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Fool ratio tabulado por arquitetura e dataset (Tabelas 1 e 2).
4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Detalhes remetidos ao material suplementar; sem link de código.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	Seção 4 traz proposições formais que explicam a sensibilidade.
6. Realiza análise no domínio da frequência / espectral	Sim	Toda a análise é no domínio de Fourier (DFT).
7. Avalia mais de um dataset	Sim	Seis datasets.
8. Avalia mais de uma arquitetura/modelo	Sim	MLP, LeNet, WideResNet, DenseNet-BC, VGG, ResNet-50, GoogLeNet, CaffeNet.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Reconhece que a aproximação linear pode não valer em redes profundas e que camadas de max-pooling não são cobertas pela teoria; sem seção formal.
10. Publicado em veículo revisado por pares	Sim	CVPR 2019.

11. Código, dados ou parâmetros disponíveis/descritos para replicação	Não informado	Não informado no texto.

Extração de Dados

Campo do SLR	Valor Extraído	Detalhes
Técnica(s) de pré-processamento	Outra	Manipulação aditiva de uma única função de base de Fourier na entrada (Single Fourier Attack e sua variante com sinal, SSFA), varrendo todo o espectro. Controles: ruído aleatório e manipulação na base padrão (pixel).
Arquitetura(s)	ResNet, VGG, CNN rasa/custom, Outra	LeNet, WideResNet, DenseNet-BC, VGG com batch-norm, ResNet-50, GoogLeNet, CaffeNet e um MLP 1000–1000 como controle não convolucional.
Dataset(s)	MNIST, FashionMNIST, SVHN, CIFAR-10, CIFAR-100, ILSVRC2015	Imagens naturais e dígitos; quantidades e número de classes não informados no texto. ILSVRC2015 avaliado em 224×224.
Métrica(s) de desempenho	Outra (fool ratio)	Percentual de imagens cuja predição muda após a perturbação; a acurácia em si não é reportada.
Análise de frequência/espectral?	Sim	DFT; mapas de calor de fool ratio por coordenada de frequência; decomposição de camadas convolucionais em bases de Fourier.
Intensidade em múltiplos níveis?	Sim	$\ell\infty$ de 10/255, 20/255 e 30/255, conforme o dataset, além da varredura de todas as frequências.
Múltiplas arquiteturas?	Sim	Comparação explícita entre CNNs e MLP, e entre LeNet/WideResNet/VGG/DenseNet.
Código/Dados públicos?	Não informado	Nenhuma disponibilização mencionada no texto.

Efeito sobre a Acurácia

Direção do efeito: Piora

• **A degradação depende drasticamente da banda alterada:** em CIFAR-10 e CIFAR-100, VGG e Wide-ResNet chegam a fool ratio próximo de 90% e 99% em direções específicas (Seção 5.2).

• **A manipulação espectral é muito mais danosa que a manipulação no domínio do pixel:** a base padrão (pixel) produziu fool ratio de quase 0% em todos os cenários, contra dezenas de pontos percentuais na base de Fourier (Seção 5.2).

• **Ordem de grandeza (Tabela 1, CIFAR-100, $\ell\infty = 10/255$):** ruído aleatório causa 13,0% / 26,4% / 25,9% / 22,5% de fool ratio em LeNet / WResNet / VGG / DenseNet, enquanto a perturbação de Fourier de mesma magnitude causa 83,4% / 93,7% / 95,8% / 72,3%.

• **As bandas mais danosas não são as altas:** "the networks are relatively robust against high-frequency noises and sensitive to low and middle-frequency noises" (Seção 5.5).

Mecanismos Explicativos Propostos

• **Explicação estrutural (arquitetural):** camadas convolucionais com padding circular têm matrizes duplamente circulantes por blocos, cujos autovetores são bases de Fourier; logo as direções mais sensíveis da rede são combinações de poucas funções de base de Fourier (Proposições 1–5).

• **A sensibilidade é da convolução, não do domínio da imagem:** o MLP treinado nos mesmos dados não exibe os pontos sensíveis no domínio de Fourier (Seção 5.3), o que atribui o fenômeno à arquitetura convolucional.

• **Co-ocorrência por tamanho de kernel:** kernels pequenos (3×3) fazem camadas responderem de forma parecida a frequências próximas, o que explica regiões contíguas de sensibilidade no espectro (Seção 5.4).

• **Não-linearidades atenuam o efeito:** LeNet e DenseNet, que usam max-pooling, mostraram-se mais robustos — os autores atribuem isso ao fato de o max-pooling misturar bases de Fourier e não ser coberto pela teoria (Seção 5.7).

Evidência Espectral

Sim. Método: transformada discreta de Fourier (DFT) e decomposição espectral de camadas convolucionais. Representação: base de Fourier bidimensional $(F_N)_i \otimes (F_N)_j$, com mapa de calor de fool ratio por par (i, j). Bandas analisadas: espectro completo, frequência a frequência (com o centro do mapa correspondendo às altas frequências). Relação com o desempenho: existe um conjunto de "pontos sensíveis" no espectro, concentrado em frequências baixas e médias, em que uma perturbação de amplitude fixa derruba a predição; fora deles, o efeito é pequeno. Os autores mostram ainda que as UAPs

pré-computadas de Moosavi-Dezfooli et al. e as perturbações FGSM concentram sua massa exatamente nesses pontos sensíveis (Seções 5.5 e 5.6).

Limitações Reconhecidas pelos Autores

A análise teórica assume linearidade, padding circular e não cobre camadas de max-pooling — os próprios autores usam essa lacuna para explicar por que LeNet e DenseNet resistiram mais. Também reconhecem que a aproximação linear "might not hold well in deep networks". O caso MNIST foge do padrão e é explicado de forma especulativa ("we suspect that networks can better capture true signal"). Não há seção formal de ameaças à validade.

Relevância para as Questões de Pesquisa (RQs) do SLR

• RQ1 (Degradação existe): Parcialmente relevante. Há degradação clara e quantificada, mas a métrica é fool ratio sob perturbação adversária, não acurácia sob pré-processamento de qualidade perceptual.

• RQ2 (Mecanismo explicativo): Altamente relevante. É a referência estrutural para o argumento de que a sensibilidade espectral da CNN vem da própria operação de convolução — mecanismo aplicável a qualquer alteração espectral da entrada, inclusive filtragem por pré-processamento.

• RQ3 (Relação energia–acurácia): Relevante. Fornece um mapa completo de sensibilidade por frequência, com magnitude de perturbação controlada, permitindo relacionar banda alterada e magnitude do efeito.

• RQ4 (Condições de melhoria): Não fornece evidência direta; sugere apenas, de forma especulativa, que mudanças de arquitetura poderiam mitigar o problema.

Qualidade Metodológica e Validade

Trabalho publicado em veículo de primeira linha (CVPR 2019), com resultados tabulados, controles adequados (ruído aleatório e base de pixel) e ampla varredura de datasets e arquiteturas, incluindo um controle não convolucional (MLP) que isola a causa arquitetural. Limitações para nossos fins: a métrica é fool ratio e não acurácia; a manipulação é aditiva e adversária, e não um filtro de pré-processamento; e não há disponibilização de código.

Título: Leveraging Frequency Analysis for Deep Fake Image Recognition

Autores: Frank, Eisenhofer, Schönherr, Fischer, Kolossa & Holz

Ano: 2020 | Veículo: ICML 2020 (37th International Conference on Machine Learning)

Decisão: ACEITAR

Justificativa: é o artigo do lote que mais se aproxima do desenho experimental do nosso SLR. Há uma tarefa de classificação de imagens (real vs. falsa e identificação da arquitetura geradora), um baseline sem pré-processamento, e a aplicação de técnicas clássicas de pré-processamento — blur gaussiano, compressão JPEG, ruído aditivo e recorte com reamostragem — com medição da queda de acurácia resultante. O artigo ainda oferece o mecanismo (o sinal discriminativo são artefatos de alta frequência gerados pelo upsampling) e uma evidência quantitativa entre suavização espectral e acurácia.

Resumo Geral

O artigo analisa o espectro DCT de imagens geradas por GANs (BigGAN, ProGAN, StyleGAN, SN-DCGAN) e mostra que todas exibem artefatos espectrais severos, consistentes entre arquiteturas, datasets e resoluções. Os autores atribuem esses artefatos às operações de upsampling do gerador e confirmam a hipótese treinando três StyleGANs idênticos que diferem apenas na estratégia de upsampling (vizinho mais próximo, bilinear e binomial). Em seguida usam a representação espectral para classificar: no domínio DCT, uma simples regressão ridge separa real de falso com 100% de acurácia, contra 75,78% no domínio do pixel. Por fim — e este é o bloco central para o SLR — avaliam o que acontece com esses classificadores quando as imagens de teste passam por perturbações comuns de pós-processamento.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Seções 4.1–4.5 detalham amostragem, splits, otimizador, learning rate, grid search e hardware.
2. Utiliza baseline sem pré-processamento para comparação	Sim	A acurácia em dados limpos (Tabelas 1 e 3) é a referência explícita das perturbações da Tabela 5.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Acurácia tabulada em todas as condições, além de taxas de erro relativas.
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Setup completo mais código e modelos pré-treinados publicados.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	Seção 3.3 testa e sustenta a hipótese causal do upsampling.

6. Realiza análise no domínio da frequência / espectral	Sim	DCT tipo II 2D é o eixo central do trabalho.
7. Avalia mais de um dataset	Sim	FFHQ, LSUN bedrooms, CelebA e Stanford dogs.
8. Avalia mais de uma arquitetura/modelo	Sim	Ridge/LASSO, kNN, Eigenfaces+SVM, PRNU, CNN raso próprio e a CNN de Yu et al.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Reconhecem que o classificador ainda pode ser evadido por ataques específicos (citam Carlini & Farid, 2020) e relatam tentativas fracassadas de regularização espectral; não há seção formal de ameaças à validade.
10. Publicado em veículo revisado por pares	Sim	ICML 2020.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Sim	github.com/RUB-SysSec/GANDCTAnalysis, com modelos pré-treinados.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Suavização/Blur, Compressão JPEG, Outra	Blur: filtro gaussiano com kernel amostrado em {3, 5, 7, 9}. JPEG: fator de qualidade ~U(10, 75). Outra: recorte aleatório de 5–20% seguido de reamostragem para a resolução original; ruído gaussiano aditivo com variância ~U(5, 20); e ainda anti-aliasing por kernels de upsampling (bilinear [1,2,1] e binomial [1,4,6,4,1]) no lado do gerador.

Arquitetura(s)	CNN rasa/Custom CNN, Outra	CNN rasa própria com 4 camadas convolucionais (~170 mil parâmetros, ~1,9% da CNN de Yu et al., que tem ~9 milhões); além de regressão ridge, LASSO, kNN, Eigenfaces+SVM e o detector PRNU de Marra et al.
Dataset(s)	FFHQ, LSUN bedrooms, CelebA, Stanford dogs	Detecção real vs. falso: 20.000 treino / 2.000 validação / 10.000 teste. Identificação de fonte: 500.000 treino / 100.000 validação / 150.000 teste (5 classes: real, ProGAN, SN-DCGAN, CramerGAN, MMDGAN), a 128×128. Espectros médios calculados sobre 10.000 imagens. Domínio: faces, quartos e cães.
Métrica(s) de desempenho	Acurácia	Acurácia no conjunto de teste, além de ganho percentual e redução relativa da taxa de erro.
Análise de frequência/espectral?	Sim	DCT tipo II 2D, espectros médios em escala log, mapa de pesos do classificador LASSO mapeado de volta às frequências.
Intensidade em múltiplos níveis?	Sim	Blur com 4 tamanhos de kernel, JPEG com fator de qualidade de 10 a 75, ruído com variância de 5 a 20, recorte de 5% a 20%, e três kernels de upsampling de suavização crescente.
Múltiplas arquiteturas?	Sim	Seis famílias de classificadores comparadas nas mesmas condições.

Código/Dados públicos?	Código e dados	Código, plots e modelos pré-treinados disponibilizados no GitHub.

Efeito sobre a Acurácia

Direção do efeito: Piora

• Quedas grandes em todas as técnicas testadas (Tabela 5, LSUN bedrooms, identificação de fonte): partindo de 98,95% (CNN-Pixel) e 99,64% (CNN-DCT) em dados limpos (Tabela 3), a acurácia cai para 60,56% / 61,42% sob blur; 68,66% / 71,86% sob compressão JPEG; 59,51% / 48,99% sob ruído; 74,49% / 83,52% sob recorte; e 65,98% / 67,76% sob a combinação de todas.

• Quanto mais suavização espectral, menor a acurácia (Tabela 2): a mesma regressão ridge sobre coeficientes DCT cai de 98,24% (upsampling por vizinho mais próximo) para 85,96% (bilinear) e 84,20% (binomial), à medida que o kernel de anti-aliasing cresce. Os autores registram: "heavier anti-aliasing reduces the accuracy of the classifier".

• O ruído é a única perturbação que penaliza mais o domínio da frequência: "the DCT variants of the classifiers are more robust w.r.t. all perturbations except of noise" (Seção 4.5).

• Condição de recuperação (RQ4): treinar com dados perturbados recupera boa parte da acurácia — 93,61% sob blur, 94,83% sob compressão e 89,56% sob ruído para a CNN-DCT (coluna PD da Tabela 5).

Mecanismos Explicativos Propostos

• O sinal discriminativo é de alta frequência e vem do upsampling: os artefatos em grade que permitem a classificação decorrem das operações de upsampling do gerador, confirmado experimentalmente pela troca controlada do kernel de upsampling (Seção 3.3).

• Pré-processamento suavizador remove justamente esse sinal: blur e compressão atenuam as altas frequências onde reside a evidência, e por isso derrubam a acurácia; o mapa de pesos do LASSO confirma que o classificador usa exatamente essas frequências (Figura 4).

• Anti-aliasing como remoção de evidência no domínio da imagem: "this also seems to remove the consistent patterns exploited in the image domain" (Seção 4.2) — o mesmo mecanismo pelo qual um pré-processamento passa-baixa apaga características discriminativas.

• Ruído é um caso distinto: o ruído aditivo introduz energia de alta frequência (em vez de removê-la) e é a única perturbação em que o classificador espectral fica atrás do classificador em pixels.

Evidência Espectral

Sim. Método: DCT tipo II bidimensional, com coeficientes em escala logarítmica e normalização (média zero, variância unitária). Representação: espectro DCT completo (heatmap), médias sobre 10.000 imagens, e mapa dos pesos do classificador LASSO reprojetado no espectro. Bandas analisadas: espectro inteiro, do canto superior esquerdo (baixas) ao inferior direito (altas). Tipo de energia: magnitude dos coeficientes DCT, comparada à lei $1/f^{\alpha}$ ($\alpha \approx 2$) de imagens naturais. Relação com o desempenho: a acurácia de classificação é proporcional à preservação dos artefatos de alta frequência — daí tanto o ganho de 24,22 pontos ao migrar do pixel para o domínio DCT quanto as quedas sob blur e compressão.

Limitações Reconhecidas pelos Autores

Os autores reconhecem explicitamente que, apesar da maior robustez a perturbações comuns, o classificador continua vulnerável a exemplos adversários construídos sob medida, citando trabalho subsequente que evade o método (Carlini & Farid, 2020). Registram também que suas tentativas de corrigir o problema do lado do gerador — um segundo discriminador baseado em DCT e uma penalidade DCT na função de perda — não funcionaram: ou o termo era fraco demais e não tinha efeito, ou dominava e levava ao colapso do treinamento. E observam que amostras em resolução mais baixa (256×256) exibem menos artefatos, inviabilizando a separação linear perfeita obtida em 1024×1024.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. É evidência direta, com baseline limpo, de que blur, compressão JPEG, ruído e recorte degradam substancialmente a acurácia de um classificador CNN treinado.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Identifica precisamente qual característica é removida (artefatos de alta frequência do upsampling) e demonstra, via mapa de pesos, que era ela que sustentava a decisão do modelo.

• **RQ3 (Relação quantitativa):** Relevante. A Tabela 2 é uma relação dose-resposta entre intensidade do anti-aliasing (energia de alta frequência suprimida) e acurácia: 98,24% → 85,96% → 84,20%.

• **RQ4 (Condições de melhoria):** Altamente relevante. Mostra as duas condições em que o desempenho sobe: mudar a representação de entrada para o domínio espectral (+24,22 pontos) e treinar com dados perturbados (recuperação de até ~32 pontos sob blur).

Qualidade Metodológica e Validade

É o artigo metodologicamente mais sólido do lote para os fins do SLR: publicado em veículo revisado por pares de primeira linha, com baseline limpo, métricas tabuladas, seis famílias de classificadores, quatro datasets, múltiplos níveis de intensidade de cada perturbação e código/modelos públicos. Ressalva de escopo: a tarefa é detecção de imagens sintéticas,

um domínio em que o sinal discriminativo é, por construção, de alta frequência — a magnitude das quedas observadas não deve ser extrapolada diretamente para classificação de objetos em imagens naturais.

Título: Dissociating spatial frequency reliance from adversarial robustness advantages in neurally guided deep convolutional neural networks

Autores: Shao, Ren, Wang, Isik & Beck

Ano: Não informado no texto | Veículo: não informado (manuscrito em formato de pré-print; arquivo PDF gerado em 2026)

Decisão: ACEITAR

Justificativa: o estudo aplica filtragem espectral explícita às imagens de treino — filtros passa-baixa, passa-banda e blur gaussiano com σ fixo e σ misto — sobre uma ResNet-18 treinada em ImageNet-50, com um modelo baseline sem qualquer manipulação, e mede o efeito sobre a acurácia top-1 sob ataque. É evidência direta para a RQ4 (em que condições a manipulação espectral melhora ou não melhora o desempenho) e traz uma advertência metodológica valiosa: enviesar o modelo para a banda de frequência que os humanos usam piora o desempenho, e a filtragem tradicional não produz o deslocamento espectral limpo que se supõe.

Resumo Geral

O trabalho pergunta se o ganho de robustez adversária obtido ao alinhar CNNs a representações do córtex visual humano se explica por um viés espectral — para as baixas frequências (LSF) ou para o "canal humano", uma banda estreita de frequência média crítica para o reconhecimento humano de objetos. Os autores primeiro mostram que modelos guiados neuralmente de fato aumentam a dependência de ambas as bandas. Depois testam a causalidade impondo esses vieses diretamente, via embaralhamento seletivo de fase e via filtragem, em quatro condições (canal humano; LSF extremo < 3,5 cpi; blur gaussiano de σ fixo = 1,5; mistura de σ), cada uma em variantes fraca e forte, com cinco sementes por condição. O resultado é uma dissociação: o viés LSF traz ganhos modestos, o viés para o canal humano piora a robustez, a combinação dos dois também piora, e a filtragem convencional não traz vantagem alguma. A conclusão é que o deslocamento espectral é uma propriedade emergente do aprendizado de representações mais humanas, não o mecanismo causal da robustez.

Critérios de Qualidade

Critério de qualidade	Resposta	Observação

1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Seção de Métodos descreve máscaras, otimizador, épocas, learning rate, batch size, label smoothing e sementes.
2. Utiliza baseline sem pré-processamento para comparação	Sim	Modelo Baseline sem viés espectral, além de controles Random, V1-shuffle e TO-shuffle.
3. Reporta métricas quantitativas de classificação de forma clara	Parcialmente	Acurácia top-1 sob ataque e AUC de robustez com IC 95% bootstrap, mas apresentadas em figuras; a acurácia limpa (ε = 0) não é reportada.
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Hiperparâmetros completos, cinco sementes por condição e código público.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	É o objetivo central do artigo: testar mecanismos concorrentes.
6. Realiza análise no domínio da frequência / espectral	Sim	Máscaras no domínio de Fourier e perfis de dependência espectral estimados pelo espectro das perturbações.
7. Avalia mais de um dataset	Não	Apenas ImageNet-50 (o NSD é usado só para os dados neurais humanos).
8. Avalia mais de uma arquitetura/modelo	Não	Apenas ResNet-18, sem modificações arquiteturais.
9. Discute limitações metodológicas ou ameaças à validade	Sim	Seção de discussão com limitações explícitas sobre a operacionalização do viés espectral e sobre camadas de pré-processamento.
10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no documento.
11. Código, dados ou parâmetros	Somente código	github.com/shaox192/spatial-frequency-bias

disponíveis/descritos para replicação		

Extração de Dados

Campo do SLR	Valor Extraído	Detalhes
Técnica(s) de pré-processamento	Suavização/Blur, Outra	Blur: kernel gaussiano de σ fixo = 1,5 e mistura de kernels gaussianos com σ variados (1,0 a 8,0). Outra: filtro passa-baixa preservando frequências < 3,5 cpi; filtro passa-banda de uma oitava no "canal humano"; embaralhamento seletivo de fase por banda (método principal). Aplicados como augmentação sobre uma proporção controlada das imagens de treino.
Arquitetura(s)	ResNet	ResNet-18 treinada do zero, sem modificações arquiteturais, com camada final substituída por saída de 50 classes.
Dataset(s)	ImageNet-50	Subconjunto de 50 categorias do ImageNet, com splits originais de treino e validação; 2.500 imagens de validação; imagens RGB 224×224. Quantidade de imagens de treino não informada. Dados neurais humanos do Natural Scenes Dataset (1.000 imagens de avaliação, Sujeito 1).

Métrica(s) de desempenho	Acurácia, Outra	Acurácia top-1 sob ataque PGD ℓ∞ em sete valores de ε (1/255 a 7/255), resumida como AUC da curva de robustez; além de análise de similaridade representacional (RSA) com dados neurais humanos.
Análise de frequência/espectral?	Sim	Máscaras radiais no domínio de Fourier (cpi), resposta 1D em magnitude, e perfis de dependência espectral obtidos pelo espectro das perturbações adversárias.
Intensidade em múltiplos níveis?	Sim	Variantes de viés fraco e forte (proporção de imagens filtradas no treino), quatro bandas-alvo, σ do blur variado, e sete valores de ε no ataque.
Múltiplas arquiteturas?	Não	Somente ResNet-18.
Código/Dados públicos?	Somente código	Repositório público; os dados são subconjuntos públicos do ImageNet e do NSD.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Viés para baixas frequências — efeito pequeno ou nulo:** "all LSF-biased models showed either comparable or slightly improved adversarial robustness relative to the baseline model" (Resultados).

• **Viés para o canal humano — piora, e piora com a intensidade:** "biasing models towards the human channel was not merely ineffective, but harmful, and stronger bias led to further degradation in performance" (Resultados).

• **A combinação das duas bandas também piora:** a condição "combined-channel" produziu robustez pior que o baseline, ou seja, o ganho modesto do LSF não compensou o prejuízo do canal humano.

• **Filtragem tradicional — sem vantagem alguma:** "Filtered-image augmentation also yielded no robustness advantage even under LSF-biasing conditions" e "filter-based biasing did not elicit clean, selective SF biases" (Fig. S3).

• **Remover uma banda degrada, e a banda mais custosa não é a média:** corromper seletivamente o canal humano reduziu a robustez, mas menos do que corromper a banda de LSF extremo.

Mecanismos Explicativos Propostos

• **Dissociação entre dependência espectral e robustez:** o deslocamento da dependência espectral é uma propriedade emergente do aprendizado de representações mais humanas, e não o mecanismo causal pelo qual o alinhamento neural confere robustez.

• **Desproporção dose-efeito:** os modelos guiados neuralmente exibem deslocamentos espectrais pequenos com ganhos de robustez não triviais, enquanto os modelos explicitamente enviesados exibem deslocamentos muito maiores com ganhos apenas modestos — o que enfraquece a hipótese de que o viés espectral seja suficiente.

• **Compensação entre bandas:** como o restante do espectro continua disponível, o modelo pode compensar redistribuindo sua dependência para outras bandas, inclusive as altas — o que torna a evidência de necessidade de qualquer banda específica ainda mais fraca.

• **Filtragem apenas reduz, não elimina:** os autores sugerem que a filtragem não impõe um viés forte o suficiente porque apenas reduz a energia das bandas indesejadas, deixando informação residual explorável — diferente do embaralhamento de fase.

Evidência Espectral

Sim. Método: máscaras radialmente simétricas no domínio de Fourier, definidas em ciclos por imagem (cpi), usadas tanto para filtragem quanto para embaralhamento seletivo de fase; a dependência espectral de cada modelo é estimada pelo espectro das perturbações adversárias (usadas como sonda diagnóstica das características de que o modelo depende). Bandas analisadas: LSF extremo (< 3,5 cpi), "canal humano" (uma oitava de largura, centrada nas frequências médias) e o restante do espectro até o limite de resolução de 224×224. Relação com o desempenho: os perfis confirmam que as manipulações deslocaram a dependência para a banda-alvo, mas esse deslocamento não se traduziu proporcionalmente em robustez — a evidência central da dissociação.

Limitações Reconhecidas pelos Autores

Os autores reconhecem que operacionalizaram o viés espectral como uma propriedade de população moldada por augmentação de dados, enquanto no sistema visual biológico neurônios individuais têm perfis de sintonia diversos dentro de uma mesma região cortical — o efeito pode depender de restrições arquiteturais, não de estatísticas de treino. Registram ainda uma ressalva metodológica de interesse direto para o nosso SLR: camadas de pré-processamento (como um filtro passa-baixa diferenciável prefixado ao

modelo) alteram os gradientes que dirigem tanto o aprendizado quanto os ataques caixa-branca, tornando difícil separar efeitos biologicamente significativos de mudanças na dinâmica de otimização ou de suavização de gradiente. Reconhecem também que o debate mais amplo sobre a base espectral da vulnerabilidade adversária permanece aberto, com trade-offs que variam por tipo de corrupção e por dataset.

Relevância para as Questões de Pesquisa (RQs) do SLR

• RQ1 (Degradação existe): Relevante. A remoção seletiva de bandas espectrais degrada o desempenho, com magnitude dependente da banda; a banda de LSF extremo é a mais custosa.

• RQ2 (Mecanismo explicativo): Altamente relevante. É evidência contrária à explicação simples "remover altas frequências causa/resolve o problema": a dependência espectral se dissocia do desempenho robusto.

• RQ3 (Relação quantitativa): Parcialmente relevante. Fornece perfis de dependência espectral e AUC de robustez lado a lado, mas o argumento central é justamente a ausência de proporcionalidade entre deslocamento espectral e desempenho.

• RQ4 (Condições de melhoria): Altamente relevante. Delimita com precisão quando a filtragem espectral melhora (LSF, ganho modesto), quando não muda nada (filtragem tradicional) e quando piora (canal humano, isolado ou combinado).

Qualidade Metodológica e Validade

Desenho experimental rigoroso: baseline explícito, controles adicionais (Random, V1-shuffle, TO-shuffle), cinco sementes por condição com intervalos de confiança bootstrap de 10.000 reamostragens, hiperparâmetros idênticos entre condições e código público. Limitações relevantes: um único dataset (ImageNet-50) e uma única arquitetura (ResNet-18); resultados apresentados em figuras, sem tabelas de acurácia; a acurácia em dados limpos não é reportada, o que impede avaliar o custo da filtragem sobre o desempenho não adversário — justamente o desfecho central da nossa RQ1. Veículo de publicação revisado por pares não informado.

Título: Understanding the Impact of Image Quality and Distance of Objects to Object Detection Performance

Autores: Hao, Pei, Lyu, Yuan, Rizzo, Wang & Fang

Ano: 2022 | Veículo: pré-print arXiv (arXiv:2209.08237v1, 17/09/2022) — revisão por pares não informada

Decisão: ACEITAR COMO EVIDÊNCIA SECUNDÁRIA (tarefa de detecção de objetos, não de classificação)

Justificativa: o artigo avalia exatamente a relação central do nosso SLR — redução de qualidade de imagem (resolução espacial e resolução de amplitude por compressão) contra desempenho do modelo — com baseline sem degradação, múltiplos níveis de intensidade, três datasets e quatro variantes de modelo. A tarefa, porém, é detecção de objetos medida por mAP, e não classificação de imagens. Por decisão da equipe, o artigo é admitido no mesmo estatuto secundário já concedido aos resultados em COCO do artigo de Wang et al. (2020): suas evidências podem sustentar afirmações sobre RQ1, RQ3 e RQ4, desde que sempre rotuladas como provenientes de detecção de objetos e nunca extrapoladas diretamente para acurácia de classificação.

Resumo Geral

O estudo investiga como a resolução espacial, a resolução de amplitude (controlada pelo passo de quantização do codificador) e a distância do objeto à câmera afetam a acurácia de detecção e o custo computacional. Como os detectores existentes não são projetados para operar sobre uma faixa ampla de resoluções, os autores propõem primeiro o RA-YOLO, uma variante do YOLOv5 que ajusta o número de escalas da pirâmide de características e das cabeças de detecção conforme a resolução da entrada. Em seguida constroem um dataset com resoluções espaciais e de amplitude variadas, combinando TJU-DHD, EuroCity Persons e BDD100K, com redução de escala por filtro bicúbico (FFmpeg) e compressão pelo codec BPG (HEVC intraframe) com QP de 0 a 51. Os dois resultados centrais para o nosso SLR são assimétricos: a redução de resolução espacial degrada fortemente o desempenho, enquanto a compressão de amplitude não afeta o desempenho até um limiar, a partir do qual a queda é rápida. Por fim, mostram que a resolução determina o alcance útil de detecção — 10 m a 720P contra 40 m a 1024P.

Critérios de Qualidade

Critério de qualidade	Resposta	Observação
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Seções 3.1–3.4 detalham backbone, neck, limiares de resolução, codec, splits, hardware e métrica.
2. Utiliza baseline sem pré-processamento para comparação	Sim	Imagens originais não comprimidas e em resolução original são a referência explícita (TJU Original vs. Down2 vs. Down4; QP = 0).

3. Reporta métricas quantitativas de classificação de forma clara	Parcialmente	A Tabela 2 traz mAP tabulado por resolução e número de escalas, mas as curvas de compressão (Figura 5) estão apenas em gráficos; poucos valores numéricos no texto.
4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Setup e hardware descritos, mas sem código; o link do dataset é apenas prometido ("will be published alongside the paper").
5. Discute mecanismos explicativos, não apenas resultados empíricos	Parcialmente	Há uma explicação — a redução de resolução remove os detalhes de alta frequência necessários a objetos pequenos, e a quantização introduz artefatos — mas ela não é testada isoladamente, e parte é apresentada como suspeita ("We suspect that...").
6. Realiza análise no domínio da frequência / espectral	Não	Não há transformada nem análise no domínio da frequência; o PSNR é usado como métrica de qualidade, não como análise espectral.
7. Avalia mais de um dataset	Sim	TJU-DHD, EuroCity Persons e BDD100K.
8. Avalia mais de uma arquitetura/modelo	Sim	YOLO(3), YOLO(4), YOLO(5) e RA-YOLO — ressalva: são variantes da mesma família YOLOv5, não arquiteturas independentes.

9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Reconhecem a inconsistência de anotação da categoria "rider" entre datasets, que o BDD não entrou no treino, e que a generalização para QP até 20 é expectativa não testada; sem seção formal de ameaças à validade.
10. Publicado em veículo revisado por pares	Não informado	Pré-print arXiv; veículo revisado por pares não indicado.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Não	Sem código; dataset apenas prometido, o que não configura disponibilização.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Outra	(a) Redução de resolução espacial por downsampling bicúbico (FFmpeg), em fatores de 1,42, 2 e 4, cobrindo de 4000P a 500P. (b) Compressão com perdas pelo codec BPG (HEVC intraframe), com parâmetro de quantização QP de 0 a 51 — os autores registram que o BPG tem eficiência de codificação superior à do JPEG e do JPEG2000. Não foram avaliados denoising, equalização de histograma, aguçamento nem super-resolução.

Arquitetura(s)	Outra	RA-YOLO (variante resolução-adaptativa do YOLOv5, com backbone DarkNet e neck PANet) comparada a YOLO(3), YOLO(4) e YOLO(5) — YOLOv5 com 3, 4 e 5 escalas fixas.
Dataset(s)	TJU-DHD, EuroCity Persons, BDD100K	TJU-DHD: 115.354 imagens (90% acima de 2000×2000) e 709.330 objetos rotulados. EuroCity Persons: mais de 47.300 imagens a 1920×1024, com mais de 238.200 instâncias de pessoas, e com anotação de distância. BDD100K: 7.000 imagens de treino e 1.000 de validação a 1280×720, já comprimidas a ~0,647 bpp. Domínio: cenas urbanas de trânsito. Duas categorias: pedestre e ciclista/motociclista.
Métrica(s) de desempenho	Outra	mAP@50 (mean Average Precision com IOU 0,5) como métrica principal; além de recall e precisão por faixa de distância, PSNR como métrica de qualidade da imagem, tempo de inferência e FLOPs. Não há acurácia de classificação.
Análise de frequência/espectral?	Não	O mecanismo de perda de detalhes de alta frequência é invocado verbalmente, mas não há qualquer medição no domínio da frequência.

Intensidade em múltiplos níveis?	Sim	QP de 0 a 51 (varredura completa), três níveis de resolução espacial por dataset e oito faixas de distância de 10 m (0 a 80 m).
Múltiplas arquiteturas?	Sim	Quatro configurações comparadas nas mesmas condições, todas da família YOLOv5.
Código/Dados públicos?	Não	Nenhum código disponibilizado; o link do dataset é apenas anunciado como futuro.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Redução de resolução espacial — piora acentuada:** no TJU, o mAP cai de 77,7% para 58,2% ao reduzir as imagens originais (2000P–4000P) por um fator de 4 (500P–1000P), ou seja, 19,5 pontos percentuais (Conclusão).

• **O efeito da resolução é consistente entre configurações de modelo (Tabela 2):** o mAP médio sobe de 45,7–48,5% (baixa resolução, BDD) para 72,7–75,2% (média, EuroCity) e 74,9–77,7% (alta, TJU), em todas as quatro variantes testadas.

• **Compressão de amplitude — sem efeito até um limiar, depois queda rápida:** "compression does not reduce the detection accuracy until the images are reduced by half (corresponding to QP of 24-28 for TJU and 16 for Eurocity)"; acima de QP 34 (TJU) e 28 (EuroCity) a queda passa a ser rápida (Seção 3.6).

• **Degradação perceptual não implica degradação de desempenho:** "one can compress images in amplitude quite substantially without affecting the detection accuracy, even when the images themselves have degraded quality" (Seção 3.6).

• **Condição de recuperação (RQ4):** o ajuste fino com amostras fortemente quantizadas (QP 34 a 51) melhora o desempenho não só nesses níveis, mas também nos níveis de quantização mais leves — embora o ganho global seja pequeno, cerca de 0,01 em mAP (Seção 3.6).

• **Efeito sobre o alcance útil, não só sobre a média:** a 1024 linhas a detecção confiável de pedestres alcança 40 m; a 720 linhas o alcance cai para 10 m (Seção 3.7, Figura 7b).

Mecanismos Explicativos Propostos

• **Remoção de detalhes de alta frequência necessários a objetos pequenos:** "Further downsampling a high-resolution image to an expected low-resolution representation can remove the high-frequency details necessary to detect small objects and consequently reduce the detection accuracy" (Seção 2.1). É o mecanismo mais alinhado à nossa hipótese, mas é enunciado sem verificação experimental direta.

• **Artefatos de quantização acima de um limiar:** abaixo de certo nível de amplitude, o artefato de quantização torna o objeto mais difícil de reconhecer, levando à queda rápida de desempenho — um mecanismo de introdução de artefato, distinto da remoção de informação.

• **Relação com o tamanho aparente do objeto:** o tamanho da caixa delimitadora é proporcional à resolução e inversamente relacionado à distância; por isso a resolução determina até que distância o objeto ainda ocupa pixels suficientes para ser detectado.

• **Efeito de regularização do treino com dados degradados (especulativo):** os autores suspeitam que exemplos fortemente quantizados tornam o modelo mais robusto também a outros artefatos, como baixa luminosidade e desfoque de movimento — explicitamente apresentado como suspeita.

Evidência Espectral

Não. O artigo não realiza análise no domínio da frequência. A única aproximação é conceitual: a justificativa de que o downsampling remove os detalhes de alta frequência necessários para detectar objetos pequenos. A qualidade da imagem é quantificada por PSNR, que é uma métrica de distorção no domínio do pixel e não informa em qual banda espectral a energia foi perdida — limitação relevante, já que dois níveis de compressão com o mesmo PSNR podem distribuir a perda de energia de formas muito diferentes.

Limitações Reconhecidas pelos Autores

Os autores registram que a categoria "rider" é anotada de forma inconsistente entre os datasets (no TJU a caixa inclui a bicicleta ou motocicleta; no EuroCity e no BDD, apenas a pessoa), o que reduz o mAP dessa categoria e, por consequência, a média reportada. Observam também que o BDD, usado como conjunto de teste de baixa resolução, não fez parte do treino e já vinha comprimido, o que explica seu desempenho bem pior que o das imagens EuroCity Down1.42 de resolução comparável. Na análise de distância, admitem que não incluíram imagens comprimidas no teste e que a equivalência para QP até 20 é uma expectativa, não um resultado ("we expect the results to be similar for QP up to 20"), e que a extensão dos achados para a categoria "rider" e para resoluções acima de 2000P também é expectativa. Não há seção formal de ameaças à validade.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Relevante como evidência secundária. Demonstra degradação grande e quantificada sob redução de resolução (77,7% → 58,2% de mAP) e degradação condicionada a limiar sob compressão — em detecção de objetos, não em classificação.

• **RQ2 (Mecanismo explicativo):** Fracamente relevante. O mecanismo de remoção de alta frequência é invocado, mas não é medido nem testado; deve ser citado como hipótese dos autores, jamais como resultado.

• **RQ3 (Relação quantitativa):** Relevante como evidência secundária. As curvas de mAP contra QP e contra PSNR são relações dose-resposta explícitas, com formato de platô seguido de queda abrupta — um padrão não linear que vale a pena testar na nossa própria análise espectral. Ressalva: a variável independente é PSNR/QP, não energia espectral por banda.

• **RQ4 (Condições de melhoria):** Relevante como evidência secundária. Fornece duas condições em que o desempenho é preservado ou recuperado: comprimir fortemente uma imagem de alta resolução é melhor do que usar uma imagem de baixa resolução pouco comprimida sob a mesma restrição de tamanho de arquivo; e o ajuste fino com amostras fortemente quantizadas melhora o desempenho inclusive nos níveis de quantização mais leves.

Qualidade Metodológica e Validade

Pontos fortes: baseline sem degradação bem definido, varredura completa do parâmetro de quantização (QP 0 a 51), três datasets de domínios e resoluções distintos, e o cuidado de construir um modelo capaz de operar em toda a faixa de resolução — evitando o confundidor de comparar modelos diferentes otimizados para resoluções diferentes, que é o erro metodológico mais comum nesse tipo de estudo. Pontos fracos para os nossos fins: a tarefa é detecção e a métrica é mAP, não acurácia de classificação; não há análise espectral; as quatro "arquiteturas" são variantes da mesma família YOLOv5; os resultados de compressão estão em gráficos, sem tabelas; e não há código nem dataset efetivamente disponibilizados. Regra de uso no SLR: toda afirmação derivada deste artigo deve vir explicitamente rotulada como evidência de detecção de objetos.

Título: Enhancing Vision: Harmonizing Frequency for Imaging Quality and Perception Accuracy

Autores: Hongyang Chen & Kaisheng Ma

Ano: 2025 | Veículo: ICASSP 2025 — IEEE International Conference on Acoustics, Speech and Signal Processing (DOI 10.1109/ICASSP49660.2025.10889903)

Decisão: ACEITAR

Justificativa: é o artigo do acervo que trata mais diretamente da nossa pergunta central. Avalia algoritmos de reconstrução de imagem (ISP inteligente, um pré-processamento de melhoria de qualidade) e mede o efeito sobre tarefas de reconhecimento, incluindo um experimento de classificação em CIFAR-100 com ResNet-18 congelada. Documenta o caso

exato que investigamos: pipelines de reconstrução no estado da arte que produzem imagens de melhor qualidade e ainda assim degradam o desempenho de reconhecimento em relação ao pipeline tradicional da câmera. E, decisivo para a RQ3, inclui um experimento de controle que fixa a qualidade da imagem (PSNR) e mostra que o ganho de desempenho persiste — dissociando qualidade perceptual de acurácia.

Resumo Geral

O trabalho parte da constatação de que qualidade visual e acurácia de reconhecimento nem sempre andam juntas, e propõe um algoritmo de ISP inteligente (RAW→RGB) capaz de melhorar as duas simultaneamente sem depender de treinamento conjunto com a tarefa de alto nível nem de anotações adicionais. O ponto de partida é um experimento preliminar de classificação em CIFAR-100 com um ResNet-18 pré-treinado e congelado, no qual apenas o modelo de reconstrução é atualizado: acrescentar uma perda de alta frequência melhora a acurácia, enquanto acrescentar uma perda de baixa frequência a piora. A partir daí os autores projetam dois componentes — um bloco de upsampling com fusão multi-frequência (MFFB), que separa bandas por filtros convolucionais e transformada wavelet discreta, e uma supervisão consciente de frequência (FAS), que muda o alvo ao longo do treino: todas as bandas na fase inicial, apenas as altas frequências nas fases média e final. O método é avaliado em reconstrução (Zurich RAW to RGB), detecção de objetos (LOD) e segmentação de instâncias (LOD-Seg, dataset criado pelos autores).

Critérios de Qualidade

Critério de qualidade	Resposta	Observação
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Parcialmente	A arquitetura do ISP, as perdas e os hiperparâmetros (α = 0,4; β = 0,5) são descritos, mas o experimento de classificação em CIFAR-100 — o mais relevante para nós — é relatado em poucas linhas, sem tabela.
2. Utiliza baseline sem pré-processamento para comparação	Sim	Duas referências explícitas: o ISP tradicional da câmera (coluna "RGB" das Tabelas III e IV) e, na classificação, o modelo treinado apenas com perda de classificação.

3. Reporta métricas quantitativas de classificação de forma clara	Sim	Tabelas I, III e IV trazem PSNR, MS-SSIM e mAP; os valores de acurácia aparecem no texto da Seção II-A.
4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Hiperparâmetros e arquitetura descritos, mas sem código publicado e sem disponibilização do LOD-Seg, que é um dataset criado pelos autores.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	Vai além do empírico: propõe o viés espectral como causa e testa a hipótese concorrente com um experimento de controle de PSNR.
6. Realiza análise no domínio da frequência / espectral	Sim	DWT com decomposição em LL/LH/HL/HH e curvas de distância de frequência por banda ao longo do treino.
7. Avalia mais de um dataset	Sim	CIFAR-100, Zurich RAW to RGB, LOD, LOD-Seg e SIDD (na ablação de denoising).
8. Avalia mais de uma arquitetura/modelo	Sim	ResNet-18 (classificador e backbone do detector), CenterNet, QueryInst, além dos pipelines PyNET e LW-ISP.
9. Discute limitações metodológicas ou ameaças à validade	Não	Não há seção de limitações nem discussão de ameaças à validade — a fraqueza mais séria do artigo.
10. Publicado em veículo revisado por pares	Sim	ICASSP 2025, IEEE.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Não informado	Nenhum repositório mencionado.

Extração de Dados

Campo do SLR	Valor Extraído	Detalhes
Técnica(s) de pré-processamento	Outra	Reconstrução por ISP inteligente (RAW→RGB) com upsampling de fusão multi-frequência (MFFB) e supervisão consciente de frequência (FAS) guiada por transformada wavelet discreta. Comparada aos pipelines PyNET e LW-ISP e ao ISP tradicional da câmera. Há ainda uma ablação em denoising (SIDD). Não foram avaliados blur, compressão JPEG, equalização de histograma nem super-resolução clássica.
Arquitetura(s)	ResNet, Outra	Classificação: ResNet-18 pré-treinada e congelada. Detecção: CenterNet com ResNet-18. Segmentação de instâncias: QueryInst. Reconstrução: arquitetura U-Net leve inspirada no LW-ISP, comparada a PyNET e LW-ISP.
Dataset(s)	CIFAR-100, Zurich RAW to RGB, LOD, LOD-Seg, SIDD	CIFAR-100 para o experimento de classificação. Zurich RAW to RGB para a qualidade de reconstrução. LOD para detecção. LOD-Seg, criado pelos autores a partir do LOD, para segmentação de instâncias, com seis categorias (bicicleta, garrafa, ônibus, carro, cadeira e motocicleta) e anotações em formato COCO. SIDD na ablação de denoising. Quantidades

		de imagens não informadas.
Métrica(s) de desempenho	Acurácia, Outra	Acurácia de classificação (CIFAR-100); mAP, mAP@50, mAP@75 e mAP@L (detecção e segmentação); PSNR e MS-SSIM (qualidade de reconstrução).
Análise de frequência/espectral?	Sim	DWT decompondo cada amostra em LL, LH, HL e HH; distância L1 normalizada por banda medida ao longo das épocas de treino; perdas separadas por banda.
Intensidade em múltiplos níveis?	Não	A manipulação varia por banda de frequência (alta vs. baixa) e por fase de treino, não por intensidade graduada. Há apenas análise de sensibilidade dos pesos α e β das perdas.
Múltiplas arquiteturas?	Sim	Três pipelines de reconstrução (PyNET, LW-ISP, proposto) mais o ISP tradicional, avaliados sobre classificador, detector e segmentador distintos.
Código/Dados públicos?	Não informado	Nenhum repositório mencionado; o LOD-Seg, criado pelos autores, não é disponibilizado.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• Pré-processamento de melhoria de qualidade degradando reconhecimento — o nosso fenômeno: na Tabela III (LOD, detecção), o PyNET obtém 37,2 mAP contra 40,8 mAP do ISP tradicional da câmera — uma perda de 3,6 mAP. Na Tabela IV (LOD-Seg),

tanto o PyNET quanto o LW-ISP ficam abaixo do ISP tradicional: detecção 41,9 e 41,7 contra 42,8; segmentação 34,1 e 33,9 contra 35,6.

• **Na classificação, o efeito depende de qual banda é reforçada:** com o classificador congelado, acrescentar perda de alta frequência ao treino do reconstrutor eleva a acurácia em CIFAR-100 de 77,72% para 77,83%, ao passo que acrescentar perda de baixa frequência a reduz em 0,29%. Perda perceptual e MSE produzem ganhos marginais de +0,02% e +0,07%.

• **Qualidade de imagem e desempenho são dissociáveis (experimento de controle):** os autores fixam a qualidade de reconstrução em 21,30 dB de PSNR e ainda assim obtêm 2,0 mAP de ganho sobre as imagens RGB tradicionais — o ganho não vem da qualidade da imagem, mas do conteúdo de frequência.

• **Quando a frequência é tratada explicitamente, os dois objetivos convergem:** o método proposto melhora simultaneamente a reconstrução (21,31 → 21,63 dB no Zurich) e o reconhecimento (43,0 mAP no LOD, contra 41,5 do LW-ISP e 40,8 do ISP tradicional).

Mecanismos Explicativos Propostos

• **Viés espectral das redes de reconstrução:** modelos de ISP inteligente não capturam plenamente as propriedades intrínsecas da entrada RAW e produzem reconstruções sem detalhes e texturas realistas, por conta de vieses espectrais internos à rede.

• **Perda de informação nos estágios de upsampling e downsampling:** o pipeline de reconstrução descarta componentes de alta frequência ao longo das mudanças de resolução — é o problema que o bloco MFFB é projetado para corrigir.

• **A alta frequência é o que sustenta o reconhecimento:** os experimentos preliminares indicam que as componentes de alta frequência são decisivas para gerar imagens "amigáveis ao reconhecimento" para modelos pré-treinados, enquanto as componentes de baixa frequência não são consistentemente benéficas.

• **Convergência por banda ao longo do treino:** na fase inicial todas as bandas convergem juntas, com domínio das baixas frequências (LL); nas fases média e final, quando o modelo persegue o estado da arte, é a banda alta (HH) que passa a dominar. Supervisionar as baixas frequências nessas fases atrapalha a convergência.

Evidência Espectral

Sim. Método: transformada wavelet discreta (DWT), decompondo cada amostra em quatro bandas — LL (baixa frequência) e LH, HL e HH (altas frequências) — complementada por filtros convolucionais separáveis com convoluções dilatadas de taxas 1 e 2 para extrair a componente de frequência no ramo convolucional. Representação: distância L1 normalizada entre o espectro do resultado do modelo e o da imagem real, medida por banda e acompanhada ao longo das épocas de treino. Bandas analisadas: LL contra HH, com supervisão diferenciada por fase (todas as bandas nas primeiras 15 épocas, apenas as altas no restante). Relação com o desempenho: o alinhamento espectral em alta frequência

é o que se traduz em ganho de reconhecimento, e o experimento de PSNR controlado mostra que esse ganho é atribuível à frequência e não à qualidade da imagem.

Limitações Reconhecidas pelos Autores

O artigo não traz seção de limitações nem discussão de ameaças à validade. Do nosso ponto de vista, três lacunas merecem registro ao citá-lo: o experimento de classificação em CIFAR-100 é reportado em poucas linhas e produz uma diferença de apenas 0,11 ponto percentual, sem teste estatístico nem múltiplas sementes, o que não permite tratá-lo como efeito estabelecido; o dataset de segmentação LOD-Seg foi construído pelos próprios autores e não é disponibilizado, o que impede replicação independente; e não há código publicado. O experimento de controle de PSNR, que é o resultado mais valioso para nós, é descrito em três frases, sem repetições nem intervalo de confiança.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Documenta pipelines de reconstrução do estado da arte que degradam o desempenho de reconhecimento em relação ao pipeline tradicional da câmera — o caso central da nossa hipótese, ainda que medido em detecção e segmentação.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Atribui a degradação ao viés espectral das redes de reconstrução, que suprimem as altas frequências das quais o classificador depende, e sustenta a afirmação com medições espectrais por banda ao longo do treino.

• **RQ3 (Relação quantitativa):** Relevante. O experimento de PSNR controlado é a evidência mais limpa que encontramos de que qualidade perceptual e desempenho de reconhecimento se dissociam: mesma qualidade de imagem, 2,0 mAP de diferença conforme o conteúdo espectral.

• **RQ4 (Condições de melhoria):** Altamente relevante. Delimita a condição sob a qual o pré-processamento melhora em vez de degradar: preservar ou reforçar explicitamente a alta frequência. E mostra o inverso — reforçar a baixa frequência degrada.

Qualidade Metodológica e Validade

Publicado em veículo revisado por pares de primeira linha na área de processamento de sinais, com baseline explícito, análise espectral genuína e — o que é raro — um experimento de controle desenhado especificamente para separar o efeito da qualidade da imagem do efeito do conteúdo de frequência. As fragilidades são de escala e transparência: é um artigo curto de conferência, sem seção de limitações, sem código, com um dataset próprio não disponibilizado, e com o experimento de classificação — justamente o que mais nos interessa — reportado de forma sumária e com efeito de magnitude muito pequena. Regra de uso no SLR: citar o resultado de detecção e segmentação e o controle de PSNR como evidência substantiva; tratar o resultado de classificação em CIFAR-100 como

indicativo, sempre acompanhado da ressalva de que a diferença é de 0,11 ponto percentual sem teste estatístico.

Título: FCR: Robust Image Classification Method with Frequency Domain Consistency Regularization

Autor: Jiajun Wu (Leeds College, Southwest Jiaotong University)

Ano: 2026 | Veículo: ISCTIS 2026 — 6th International Symposium on Computer Technology and Information Science, IEEE (DOI 10.1109/ISCTIS70043.2026.11571073)

Decisão: ACEITAR

Justificativa: atende a todos os critérios de aceitação sem ressalvas de escopo. Tarefa de classificação de imagens (CIFAR-10 e CIFAR-100), baseline treinado sem qualquer manipulação, três técnicas clássicas de degradação aplicadas ao conjunto de teste (blur gaussiano, ruído gaussiano e blocagem por reamostragem), cinco níveis de severidade por corrupção e análise no domínio da frequência via FFT. Fornece tanto a magnitude da degradação (RQ1) quanto uma condição de mitigação (RQ4).

Resumo Geral

O artigo propõe a Frequency Consistency Regularization (FCR), um método leve de treino robusto que modela as degradações comuns de imagem como perda ou perturbação localizada de informação no espectro. O método tem dois componentes: o Frequency Dropout, que aplica FFT bidimensional à imagem, zera uma região anelar escolhida aleatoriamente no espectro centralizado e retorna ao domínio da imagem por transformada inversa, gerando uma visão degradada com interpretação física explícita; e um termo de regularização por consistência, que usa divergência KL simétrica com escalonamento por temperatura para forçar o modelo a produzir distribuições de predição semelhantes para a imagem original e para a versão perturbada no espectro. A avaliação compara três configurações — baseline com entropia cruzada apenas, só Frequency Dropout, e FCR completo — sobre dados limpos e sob as três degradações, em CIFAR-10 e CIFAR-100.

Critérios de Qualidade

Critério de qualidade	Resposta	Observação

1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Otimizador AdamW, taxa de aprendizado 1e-3, weight decay 5e-4, batch 128, 10 épocas, e a definição das três degradações com seus parâmetros.
2. Utiliza baseline sem pré-processamento para comparação	Sim	Baseline treinado apenas com entropia cruzada, avaliado no conjunto limpo e em cada degradação.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Acurácia tabulada nas Tabelas I, II e III, com médias sobre as corrupções.
4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Hiperparâmetros informados, mas a rede é uma "Tiny ResNet" de implementação própria descrita apenas como três estágios de BasicBlocks, o treino tem só 10 épocas e não há código publicado.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Parcialmente	Atribui o ganho à redução da dependência de detalhes locais de alta frequência, mas não mede essa dependência diretamente — a explicação é inferida do resultado, não testada.
6. Realiza análise no domínio da frequência / espectral	Sim	FFT bidimensional, supressão de regiões anelares e comparação visual dos espectros em log-magnitude.
7. Avalia mais de um dataset	Sim	CIFAR-10 e CIFAR-100, com o mesmo protocolo.
8. Avalia mais de uma arquitetura/modelo	Não	Somente a Tiny ResNet de implementação própria.

9. Discute limitações metodológicas ou ameaças à validade	Não	Não há seção de limitações nem discussão de ameaças à validade.
10. Publicado em veículo revisado por pares	Sim	ISCTIS 2026, IEEE.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Não informado	Nenhum repositório mencionado.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Suavização/Blur, Outra	Avaliadas como degradação do conjunto de teste: blur gaussiano (kernel de 3×3 até 11×11), ruído gaussiano (desvio padrão 0,02 a 0,10) e blocagem, simulada por downsampling para 28×28, 24×24, 20×20, 16×16 e 12×12 seguido de reamostragem por vizinho mais próximo até a resolução original. Proposta como técnica: Frequency Dropout, supressão de regiões anelares no espectro FFT com reconstrução por transformada inversa.
Arquitetura(s)	Outra	"Tiny ResNet" de implementação própria, composta por três estágios de BasicBlocks. Nenhuma arquitetura padrão de referência foi avaliada.

Dataset(s)	CIFAR-10, CIFAR-100	CIFAR-10: 60.000 imagens coloridas em 10 categorias, 50.000 de treino e 10.000 de teste, resolução 32×32. CIFAR-100: mesmo protocolo, com a saída do classificador alterada de 10 para 100 classes. Domínio: imagens naturais de baixa resolução.
Métrica(s) de desempenho	Acurácia	Acurácia de classificação em dados limpos e sob cada degradação, além da média sobre as corrupções.
Análise de frequência/espectral?	Sim	FFT bidimensional com centralização do espectro, supressão de anéis de raio variável e visualização comparativa dos espectros em log-magnitude frente às degradações reais.
Intensidade em múltiplos níveis?	Sim	Cinco níveis de severidade por corrupção no CIFAR-100, com curvas de decaimento da acurácia; e ablação dos hiperparâmetros λ (0,1 a 0,7) e temperatura T (1,0 a 3,0).
Múltiplas arquiteturas?	Não	Somente a Tiny ResNet própria.
Código/Dados públicos?	Não informado	Os datasets são públicos, mas não há disponibilização de código nem da implementação da rede.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **As três degradações pioram o desempenho, e muito (CIFAR-10, Tabela I):** partindo de 84,72% em dados limpos, o baseline cai para 67,84% sob blur gaussiano (−16,88 pontos),

64,28% sob blocagem (−20,44) e 61,35% sob ruído gaussiano (−23,37), com média de 64,49% sob corrupção.

• **O padrão se repete em CIFAR-100 (Tabela III):** o baseline cai de 61,84% para 42,91% sob blur, 41,35% sob blocagem e 39,27% sob ruído.

• **A degradação é progressiva com a severidade:** "The accuracy of all methods decreases as the corruption becomes stronger" — as curvas de decaimento cobrem cinco níveis por tipo de corrupção.

• **A augmentação espectral melhora nos dois regimes (RQ4):** o FCR eleva a acurácia em 1,86 ponto no conjunto limpo e em 4,49 pontos na média sob corrupção no CIFAR-10; no CIFAR-100, 2,47 e 4,12 pontos respectivamente. Só o Frequency Dropout, sem o termo de consistência, já rende de 1,2 a 2,6 pontos sob degradação.

• **Há um ponto ótimo na intensidade da regularização:** o desempenho melhora conforme λ sobe de 0,1 para 0,5, mas cai em $\lambda = 0,7$ — restrições de consistência fortes demais suprimem o aprendizado da tarefa de classificação.

Mecanismos Explicativos Propostos

• **Cada degradação corresponde a uma perturbação espectral característica:** ruído gaussiano afeta as componentes de alta frequência, o borramento enfraquece a informação de alta frequência e a distorção por compressão leva à perda de informação em bandas locais.

• **Dependência excessiva de detalhes locais de alta frequência:** o ganho mais expressivo do método ocorre justamente sob ruído gaussiano, o que os autores interpretam como sinal de que a restrição de consistência reduz a dependência do modelo em relação a detalhes instáveis de alta frequência.

• **Herança da hipótese HFC:** o artigo apoia-se explicitamente na literatura segundo a qual CNNs tendem a se apoiar em informação de alta frequência durante o treino, o que causa queda de desempenho quando essa informação é comprometida.

• **Equivalência entre supressão de anel e degradação real:** a comparação visual mostra que o blur suprime energia de alta frequência na região externa do espectro, produzindo bordas mais suaves e texturas mais fracas, ao passo que o ruído introduz perturbação de banda larga — padrões que a supressão de anéis reproduz de forma controlada.

Evidência Espectral

Sim. Método: transformada rápida de Fourier bidimensional aplicada à imagem de entrada, com centralização do espectro, supressão (zeragem) de uma região anelar selecionada aleatoriamente e retorno ao domínio da imagem por transformada inversa. Representação: espectro de Fourier centralizado, visualizado em log-magnitude. Bandas analisadas: anéis de raio variável, cobrindo desde a região central de baixa frequência até a região externa de alta frequência. Relação com o desempenho: os autores demonstram que as imagens obtidas por supressão de anéis reproduzem de forma controlada as assinaturas espectrais

do blur e do ruído reais, e que treinar com essas visões melhora a acurácia sob as degradações correspondentes — um vínculo empírico entre banda espectral manipulada e desempenho de classificação.

Limitações Reconhecidas pelos Autores

O artigo não apresenta seção de limitações. As restrições que identificamos e que devem acompanhar qualquer citação: o treino usa apenas 10 épocas e uma rede pequena de implementação própria, o que se reflete numa acurácia limpa de 84,72% no CIFAR-10 — bem abaixo do que arquiteturas padrão alcançam nesse dataset; não há comparação com nenhuma arquitetura de referência (ResNet-18, VGG, etc.), o que impede saber se o efeito sobrevive em modelos maiores; não há repetições com múltiplas sementes nem testes estatísticos, de modo que diferenças de 1 a 2 pontos percentuais não podem ser tratadas como estabelecidas; e não há disponibilização de código.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Evidência direta, com baseline limpo, de que blur, ruído e blocagem derrubam a acurácia de classificação entre 17 e 23 pontos percentuais, replicada em dois datasets.

• **RQ2 (Mecanismo explicativo):** Parcialmente relevante. Articula o mapeamento entre tipo de degradação e banda espectral afetada, e atribui a fragilidade à dependência de detalhes de alta frequência — mas essa dependência é inferida do resultado, não medida.

• **RQ3 (Relação quantitativa):** Parcialmente relevante. As curvas de decaimento por severidade fornecem a forma da relação dose-resposta, mas a variável independente é o parâmetro da degradação (σ, tamanho do kernel, fator de reamostragem), não a energia espectral efetivamente removida.

• **RQ4 (Condições de melhoria):** Altamente relevante. Mostra que augmentação no domínio da frequência combinada com regularização por consistência melhora simultaneamente o desempenho limpo e o degradado, e identifica um ponto ótimo na intensidade da restrição.

Qualidade Metodológica e Validade

O desenho experimental é apropriado à pergunta — baseline limpo, ablação separando os dois componentes do método, dois datasets, cinco níveis de severidade e ablação de hiperparâmetros — e a análise espectral é genuína, com verificação visual de que a perturbação sintética reproduz as assinaturas das degradações reais. A fragilidade é de escala e rigor estatístico: rede pequena de implementação própria, 10 épocas de treino, acurácia limpa baixa para o dataset, arquitetura única, ausência de múltiplas sementes e de testes de significância, e sem código. Regra de uso no SLR: as magnitudes de degradação (17 a 23 pontos) são grandes o bastante para serem citadas com segurança; os ganhos do método proposto (1 a 4 pontos) devem ser citados como indicativos, com ressalva explícita sobre a ausência de teste estatístico.

Referências Teóricas

Artigos sem evidência empírica sobre desempenho de classificadores, admitidos por fornecerem a fundamentação formal da pergunta de pesquisa. NÃO contam como evidência para nenhuma RQ e não devem entrar na síntese empírica; servem à introdução, à formulação do problema e à discussão.

Título: The Perception-Distortion Tradeoff

Autores: Yochai Blau & Tomer Michaeli (Technion — Israel Institute of Technology)

Ano: 2018 | Veículo: CVPR 2018 — IEEE Conference on Computer Vision and Pattern Recognition, p. 6228–6237. Versão estendida em arXiv:1711.06077v4 (2020), usada nesta análise

Classificação: REFERÊNCIA TEÓRICA (não é evidência empírica para as RQs)

Justificativa: o artigo prova formalmente que qualidade perceptual e fidelidade (distorção) são objetivos mutuamente incompatíveis, para qualquer medida de distorção — o resultado que fundamenta a premissa do nosso SLR. Não é aceito como evidência empírica porque não há tarefa de classificação de imagens, nem dataset rotulado, nem medição de acurácia de classificador: o "classificador" do teorema é um discriminador real-versus-falso ótimo, um construto teórico usado para definir qualidade perceptual, e a parte experimental compara algoritmos de super-resolução por métricas de qualidade de imagem, não por desempenho de reconhecimento.

Ficha

Campo	**Valor**
Tipo de evidência	Teórica (prova matemática) com validação empírica em qualidade de imagem
Tarefa	Restauração de imagens (super-resolução, denoising, deblurring) — não há classificação semântica
Técnicas discutidas	Super-resolução, denoising, deblurring; GANs como meio de aproximar o limite teórico

Dataset(s)	BSD100 (avaliação de 16 algoritmos de super-resolução ×4)
Métrica(s)	Distorção: RMSE, SSIM, MS-SSIM, IFC, VIF e VGG-2,2. Qualidade perceptual: NIQE, BRISQUE, BLIINDS-II e a métrica de Ma et al.; e escores de opinião humana
Análise espectral	Não (o formalismo é sobre distribuições de probabilidade, não sobre bandas de frequência)
Revisado por pares	Sim — CVPR 2018
Código/Dados públicos	Não informado

Contribuição Teórica Central

• O tradeoff é matemático, não um defeito das métricas: os autores provam que existe uma região do plano percepção-distorção que é inatingível por qualquer algoritmo, e que a fronteira dessa região é monotonicamente não crescente e convexa. Perto dela, só se pode melhorar a qualidade perceptual às custas de mais distorção, e vice-versa.

• Vale para qualquer medida de distorção: o resultado não depende de PSNR ou SSIM; alcança igualmente IFC, VIF e distâncias em espaço de características de redes neurais, o que derruba a interpretação corrente de que o problema estaria nas métricas e bastaria encontrar uma "mais perceptual".

• Definição operacional de qualidade perceptual: a qualidade perceptual é definida pela probabilidade de sucesso do discriminador ótimo entre imagens reais e imagens produzidas pelo algoritmo, que equivale à distância de variação total entre as duas distribuições. É por essa via que o artigo formaliza "parecer natural".

• A convexidade implica que o tradeoff piora perto do limite: quanto mais próximo da fronteira, mais caro fica cada ganho marginal de qualidade perceptual em termos de fidelidade — o que sugere que os algoritmos mais agressivamente otimizados para aparência são também os que mais se afastam da imagem original.

Evidência Experimental

Os autores posicionam 16 algoritmos de super-resolução ×4 no plano percepção-distorção, avaliados no BSD100, medindo distorção por seis métricas de referência completa e qualidade perceptual por métricas sem referência. O mesmo padrão aparece em todos os gráficos: o canto inferior esquerdo fica vazio, revelando a região inatingível, e nas proximidades dessa região as métricas de referência completa e sem referência tornam-se anticorrelacionadas. Os autores mostram ainda que as métricas de distorção deixam de acompanhar o julgamento humano justamente perto do limite — todas as métricas de referência completa testadas divergiram da avaliação humana no caso do SRGAN, considerado excelente em qualidade perceptual. A metodologia proposta de avaliar

algoritmos por um par de métricas foi adotada e validada no desafio PIRM de super-resolução de 2018.

Por que não conta como evidência empírica para as RQs

O eixo de desempenho do artigo é qualidade de imagem, não acurácia de reconhecimento. O teorema relaciona distorção a discriminabilidade estatística entre distribuições de imagens, o que é uma afirmação sobre realismo, não sobre preservação de características discriminativas para uma tarefa semântica. Nada no artigo mede o que acontece com um classificador quando a imagem passa por essas transformações, e a direção do argumento é a inversa da nossa: os autores mostram que otimizar fidelidade prejudica a aparência, enquanto investigamos se otimizar a aparência prejudica o classificador. A ponte entre as duas coisas é uma inferência nossa e deve ser apresentada como tal.

Limitações

Os autores reconhecem que a convexidade da curva percepção-distorção só é garantida quando a divergência empregada é convexa em seu segundo argumento, e que a caracterização depende de premissas sobre a degradação ser não invertível. Registram também que métricas sem referência substituem os escores de opinião humana apenas em cenários nos quais comprovadamente se correlacionam bem com eles — em deblurring cego com borramentos grandes, por exemplo, a substituição não é válida e seria necessário recorrer a opinião humana ou à perda de um discriminador treinado.

Uso Recomendado no SLR

• **Introdução:** para estabelecer que a tensão entre qualidade perceptual e fidelidade não é um artefato metodológico, mas um limite formal — o que justifica investigar se essa tensão se propaga até o desempenho do classificador.

• **Metodologia:** para sustentar a decisão de reportar qualidade perceptual e desempenho do classificador como eixos separados, em vez de supor que um seja proxy do outro.

• **Discussão:** para enquadrar nossos achados: se melhorar a aparência necessariamente aumenta o desvio em relação à imagem original, e se o classificador depende de características dessa imagem original, então a degradação que observamos tem uma explicação anterior à análise espectral.

• **Cuidado obrigatório:** nunca citar o artigo como se ele tivesse medido acurácia de classificação. A ponte entre o tradeoff percepção-distorção e o desempenho de classificadores é interpretação nossa.

Artigos Rejeitados na Triagem

Título: Adversarial Robustness May Be at Odds With Simplicity

Referência: Nakkiran, 2019 — pré-print arXiv (arXiv:1901.00532)

Decisão: REJEITAR

Justificativa: O trabalho é inteiramente teórico: constrói distribuições sintéticas e famílias de classificadores "simples" (funções de limiar linear) para provar que a classificação robusta pode exigir classificadores exponencialmente mais complexos. Não há imagens, não há CNN, não há dataset, não há técnica de pré-processamento e não há qualquer experimento empírico. Nenhuma das quatro RQs pode ser respondida com esse material.

Título: Excessive Invariance Causes Adversarial Vulnerability

Referência: Jacobsen, Behrmann, Zemel & Bethge, 2019 — ICLR 2019

Decisão: REJEITAR (limítrofe)

Justificativa: Há tarefa de classificação (MNIST, ImageNet, shiftMNIST) e um mecanismo bem articulado — redes tornam-se excessivamente invariantes a mudanças semanticamente relevantes por dependerem de poucas características altamente preditivas. Mas o pré-processamento não é variável do estudo: não há blur, denoising, compressão, equalização, aguçamento nem super-resolução, e não há qualquer análise no domínio da frequência. Nota para reconsideração: o experimento binary shiftMNIST (remover um único pixel preditivo no teste eleva o erro da ResNet treinada com entropia cruzada de 0,00% para 73,80%) é a demonstração mais limpa que vimos de que apagar uma característica discriminativa imperceptível colapsa o classificador. Se a equipe decidir ampliar o escopo da RQ2 para mecanismos de perda de característica discriminativa em geral, este artigo deve ser reavaliado.

Título: On the Effectiveness of Spectral Discriminators for Perceptual Quality Improvement

Referência: Luo, Zhu, Xu & Liu, 2023 — ICCV 2023 (arXiv:2307.12027)

Decisão: REJEITAR

Justificativa: O estudo trata de super-resolução baseada em GAN e de avaliação de qualidade de imagem sem referência (NR-IQA). Não há tarefa de classificação de imagens nem métrica de acurácia: os desfechos são PSNR, SSIM, LPIPS e correlações (PLCC, SRCC, KRCC) com julgamentos humanos. A análise de robustez sob mascaramento e ruído por banda de frequência recai sobre o escore de "realness" do discriminador, não sobre o desempenho de um classificador. Enquadra-se no critério de rejeição "estudo exclusivamente sobre geração". Pode ser útil como referência contextual sobre como a super-resolução altera a distribuição espectral da imagem.

Título: Frequency-Domain Deep Guided Image Denoising

Referência: Sheng, Liu, Cao, Shen & Zhang, 2023 — IEEE Transactions on Multimedia, vol. 25, p. 6767–6781

Decisão: REJEITAR

Justificativa: Estudo exclusivamente de restauração: propõe o FGDNet, um algoritmo de denoising guiado que usa uma imagem de guia bem alinhada (por exemplo, infravermelho próximo) para decidir, banda a banda, se um coeficiente de frequência da imagem ruidosa vem de ruído ou de textura. Não há tarefa de classificação, nem classificador avaliado, nem qualquer medição de desempenho de reconhecimento: as métricas são PSNR, SSIM e LPIPS, e os datasets são pares RGB-NIR, flash/ambiente e NYU v2. O termo "accuracy" no artigo refere-se sempre à fidelidade da reconstrução. Aciona o critério de rejeição "estudo exclusivamente sobre geração". Nota: o código é público (github.com/lustrouselixir/FGDNet) e o artigo separa explicitamente bandas de baixa e alta frequência para evitar o over-smoothing de detalhes — pode ser útil como referência metodológica caso venhamos a implementar denoising com decomposição espectral nos nossos experimentos.

Título: High Frequency Detail Accentuation in CNN Image Restoration

Referência: Ayyoubzadeh & Wu, 2021 — IEEE Transactions on Image Processing, vol. 30, p. 8836–8846

Decisão: REJEITAR

Justificativa: Também um estudo exclusivamente de restauração: propõe um espaço de acentuação de características de alta frequência e um termo de perda auxiliar para combater o borramento de detalhes típico de CNNs de restauração, avaliado em super-resolução e denoising por PSNR, SSIM, MS-SSIM, LPIPS e NIQE. Não há tarefa de classificação nem avaliação de classificador. Nota para reconsideração: o artigo contém uma explicação mecanística que é diretamente útil à nossa introdução — redes de restauração favorecem padrões estatisticamente dominantes, e como os padrões de baixa frequência são muito mais frequentes em imagens naturais, estabelecem um viés de suavidade; somado a isso, minimizar normas de erro tende a fazer a média de formas de onda parecidas e suavizar detalhes nítidos. É a razão pela qual algoritmos de restauração alteram sistematicamente o espectro da imagem. Se a equipe quiser essa fundamentação, o artigo pode ser promovido a referência teórica, como foi feito com Blau & Michaeli.