Título: A Study of the Effect of JPG Compression on Adversarial Images

Autores: Dziugaite, Ghahramani & Roy

Ano: 2016 | Veículo: apresentado no ISBA 2016 World Meeting (International Society for Bayesian Analysis); disponível como pré-print arXiv:1608.00853

Decisão: ACEITAR

Justificativa: O estudo aplica uma técnica clássica de pré-processamento (compressão JPEG, qualidade 75) a imagens de entrada de um classificador CNN pré-treinado e mede a acurácia top-1 e a probabilidade atribuída ao rótulo, comparando com o baseline de imagens não processadas. A Tabela 1 fornece a relação direta pré-processamento → desempenho de classificação exigida pelo SLR, incluindo o efeito do JPEG sobre imagens limpas. É também a fonte primária do dado, muito citado na literatura posterior, de que a compressão JPEG custa acurácia em imagens não atacadas.

Resumo Geral

O trabalho parte da observação de que praticamente todos os datasets de classificação de imagens são compostos por imagens JPEG e testa a hipótese de que a recompressão JPEG funcionaria como uma projeção do exemplo adversário de volta ao "subespaço JPEG", que contém o subespaço dos dados naturais. Usando a rede OverFeat pré-treinada no ImageNet 2012 e perturbações Fast Gradient Sign de três magnitudes (ε = 1, 5 e 10 sobre 255), os autores medem a acurácia top-1 e a probabilidade média do rótulo original para as imagens originais, adversárias, adversárias recomprimidas e adversárias com um controle de "ruído JPEG" (permutação aleatória do vetor de modificação introduzido pelo JPEG). O achado central é assimétrico: para perturbações pequenas a compressão JPEG reverte boa parte do ataque, mas nunca recupera integralmente o baseline; para perturbações maiores ela é praticamente inócua. Igualmente relevante para o nosso SLR é o resultado colateral: a compressão JPEG aplicada a imagens limpas já reduz, em média, a confiança do classificador.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Rede, dataset, método de ataque, magnitudes e qualidade JPEG (75) explicitados na Seção 4.

2. Utiliza baseline sem pré-processamento para comparação	Sim	A imagem original x é a primeira linha da Tabela 1 (top-1 = 0,58) e o primeiro boxplot da Figura 3.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Tabela 1 reporta acurácia top-1 e probabilidade média do rótulo para 8 condições.
4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Pipeline de pré-processamento e ataque descritos passo a passo, mas sem hiperparâmetros de implementação nem código.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Parcialmente	Propõem a hipótese do subespaço de dados/subespaço JPEG, mas admitem explicitamente não entender o mecanismo: "We do not yet understand why JPG compression reverses small adversarial perturbations".

6. Realiza análise no domínio da frequência / espectral	Não	Nenhuma DCT é calculada; os autores registram que seria interessante fazê-lo ("It would be interesting to evaluate the discrete cosine transformation of adversarial images to settle this hypothesis").
7. Avalia mais de um dataset	Não	Apenas o conjunto de validação do ImageNet.
8. Avalia mais de uma arquitetura/modelo	Não	Apenas OverFeat.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Reconhecem que a compressão JPEG "is far from a solution" e que o mecanismo permanece inexplicado, mas não há seção formal de limitações.
10. Publicado em veículo revisado por pares	Parcialmente	Apresentado em encontro científico (ISBA 2016); o documento é um pré-print de 6 páginas, sem indicação de revisão por pares completa.

11. Código, dados ou parâmetros disponíveis/descritos para replicação	Não	Nenhum código ou dado disponibilizado.

Extração de Dados

Campo do SLR	Valor Extraído	Detalhes
Técnica(s) de pré-processamento	Compressão JPEG	Compressão JPEG em qualidade fixa 75, aplicada via método save do pacote image do Torch7; controle adicional de "ruído JPEG" (permutação aleatória do delta introduzido pela compressão).
Arquitetura(s)	Outra	OverFeat pré-treinada (5 camadas convolucionais, 3 totalmente conectadas, ReLU e max-pooling), treinada no ImageNet 2012.
Dataset(s)	ImageNet (ILSVRC 2012)	Conjunto de validação completo, 1000 classes; imagens redimensionadas para menor

		dimensão 256 e recortadas em 221×221.
Métrica(s) de desempenho	Acurácia, Outra	Acurácia top-1 e probabilidade média atribuída ao rótulo mais provável da imagem limpa (mean top-label probability).
Análise de frequência/espectral?	Não	Não há análise espectral; a hipótese de ortogonalidade ao subespaço JPEG é formulada mas não testada no domínio da frequência.
Intensidade em múltiplos níveis?	Parcialmente	Três magnitudes de perturbação adversária (ε = 1, 5, 10 sobre 255), mas um único nível de compressão JPEG (qualidade 75).
Múltiplas arquiteturas?	Não	Somente OverFeat.
Código/Dados públicos?	Não	Nem código nem dados.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Sobre imagens limpas, o JPEG piora:** a Figura 3 mostra que "the second boxplot reveals that JPG compression already affects the top-label probability negatively" — a compressão sozinha reduz a confiança média do classificador sobre imagens não atacadas.

• **Sobre imagens adversárias fracas, o JPEG melhora, mas não recupera o baseline:** com ε = 1 a acurácia top-1 cai de 0,58 (limpa) para 0,23 e sobe para 0,48 após a recompressão (Tabela 1); a probabilidade média do rótulo cai de 0,61 para 0,13 e recupera apenas até 0,41.

• **Com perturbações maiores o benefício desaparece:** ε = 5 dá 0,11 sem defesa e 0,26 com JPEG; ε = 10 dá 0,09 e 0,17. Os autores concluem que "JPG recompression alone is insufficient to reverse the effect".

• **O ganho não é reproduzido por ruído estatisticamente equivalente:** o controle JPGnoise (permutação do vetor de modificação do JPEG) leva a acurácia a 0,07, abaixo até da imagem adversária — o benefício depende da direção da modificação, não das suas estatísticas marginais.

Mecanismos Explicativos Propostos

• **Hipótese do subespaço de dados:** imagens naturais vivem em um subespaço de baixa dimensão intrínseca; a perturbação adversária tira a imagem desse subespaço, onde a rede não tem dados de treino e mesmo assim reporta predições confiantes.

• **O JPEG como projeção aproximada:** como todo dataset é composto por imagens JPEG, o "subespaço JPEG" contém o subespaço dos dados; a compressão funcionaria como uma projeção de volta, o que só é eficaz se a perturbação for aproximadamente ortogonal a esse subespaço.

• **Limite explícito da explicação:** os autores registram que a evidência para perturbações grandes contradiz a hipótese de ortogonalidade e afirmam textualmente não compreender por que a compressão reverte as perturbações pequenas.

• **Viés indutivo forte como causa da confiança errada:** "the strong inductive bias of neural network classifiers leads to incorrect yet confident misclassifications" fora do subespaço dos dados.

Evidência Espectral

Não. O artigo não computa nenhuma transformada nem analisa bandas de frequência. A conexão com o domínio espectral é apenas conceitual (o JPEG opera por quantização de coeficientes DCT) e os próprios autores apontam a análise DCT como trabalho futuro necessário para decidir a hipótese que propõem.

Limitações Reconhecidas pelos Autores

Os autores reconhecem que a compressão JPEG não constitui uma defesa prática ("JPG compression is far from a solution"), que mesmo as maiores perturbações avaliadas permanecem quase invisíveis ao olho não treinado, e que o mecanismo pelo qual a compressão reverte perturbações pequenas continua sem explicação. Registram ainda que o experimento é limitado a um único método de ataque (Fast Gradient Sign) e a uma única arquitetura.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Relevante. Fornece o dado, reutilizado por vários trabalhos posteriores, de que a compressão JPEG reduz a acurácia e a confiança do classificador sobre imagens limpas — degradação causada por pré-processamento sem qualquer ataque envolvido.

• **RQ2 (Mecanismo explicativo):** Parcialmente relevante. Formula a hipótese geométrica do subespaço de dados versus subespaço JPEG, mas admite abertamente que ela não explica os resultados observados para perturbações grandes.

• **RQ3 (Relação quantitativa):** Pouco relevante. Varia a intensidade da perturbação, não a intensidade do pré-processamento (qualidade JPEG fixa em 75), e não mede energia espectral.

• **RQ4 (Condições de melhoria):** Relevante. Delimita com precisão a condição em que o pré-processamento ajuda — perturbação de pequena magnitude e aproximadamente ortogonal ao subespaço da transformação — e mostra que o benefício se extingue quando a magnitude cresce.

Qualidade Metodológica e Validade

Trabalho curto (6 páginas) e de escopo deliberadamente restrito: uma arquitetura, um dataset, um ataque, uma qualidade de compressão. A tabela de resultados é clara e o controle com "ruído JPEG" é um cuidado metodológico acima da média para a época, pois isola o efeito da direção da transformação do efeito das suas estatísticas. A ausência de análise espectral e de código limita a contribuição para as RQ2 e RQ3, mas o valor do artigo para o nosso SLR é histórico e factual: é a referência primária para a afirmação de que a compressão JPEG custa acurácia em imagens limpas.

Título: How Image Degradations Affect Deep CNN-based Face Recognition?

Autores: Karahan, Kılınç Yıldırım, Kırtaç, Rende, Bütün & Ekenel

Ano: 2016 | Veículo: não indicado no PDF (pré-print arXiv:1608.05246)

Decisão: ACEITAR

Justificativa: O estudo aplica sistematicamente cinco famílias de degradação de imagem (blur gaussiano e mediano, ruído gaussiano e sal-e-pimenta, contraste, distorção de cor e oclusão) ao conjunto de sondas do protocolo de identificação fechada do LFW e mede a queda de acurácia rank-1 e rank-5 de três CNNs pré-treinadas, com baseline sem degradação. Além da evidência empírica direta para a RQ1, os autores oferecem uma explicação mecanística explícita — o blur remove bordas e textura, que são o sinal discriminativo usado pela rede — que é exatamente a hipótese central do nosso SLR.

Resumo Geral

O trabalho monta um benchmark de robustez a degradações de imagem para reconhecimento facial baseado em CNN, usando o protocolo de identificação de conjunto

fechado do LFW (galeria com 4249 sujeitos, uma imagem por sujeito; sondas com 3143 imagens). As degradações são aplicadas somente às sondas, mantendo a galeria intacta. Três modelos são avaliados — AlexNet e GoogLeNet ajustados sobre uma combinação de CASIA-Webface, FaceScrub e CACD (≈530 mil imagens de 10 770 sujeitos), e a VGG-Face original. O resultado é fortemente assimétrico entre tipos de degradação: blur, ruído e oclusão derrubam drasticamente o desempenho, enquanto distorções de cor e mudanças de balanço de branco quase não afetam. Os autores contrastam explicitamente esse comportamento com o do observador humano, que continua reconhecendo os sujeitos em níveis de ruído em que a acurácia das redes cai abaixo de 6%.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Protocolo LFW closed-set, três arquiteturas, cinco famílias de degradação com parâmetros e passos explicitados na Seção 3.
2. Utiliza baseline sem pré-processamento para comparação	Sim	Resultados sem degradação reportados: rank-1 de 70,13% (VGG-Face), 51,76% (AlexNet) e 77,12% (GoogLeNet).
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Acurácia de identificação rank-1 e rank-5 em curvas por nível de degradação (Fig. 3) e tabela para oclusão (Tab. 1).

4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Hiperparâmetros de fine-tuning e parâmetros das degradações são dados, mas os resultados por nível estão apenas em figuras, sem tabelas numéricas.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	Atribuem a queda causada por blur à remoção de bordas e de informação de textura usada como sinal discriminativo, e identificam a região periocular como a mais informativa.
6. Realiza análise no domínio da frequência / espectral	Não	Nenhuma transformada nem análise de bandas de frequência; o argumento sobre textura é feito no domínio da imagem.
7. Avalia mais de um dataset	Não	Apenas o LFW como benchmark de avaliação (os demais datasets são usados só para fine-tuning).
8. Avalia mais de uma	Sim	AlexNet, VGG-Face e GoogLeNet,

arquitetura/modelo		comparados em todas as condições.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Apontam a necessidade de mais pesquisa e propõem soluções futuras, mas sem seção de ameaças à validade.
10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Parcialmente	Parâmetros das degradações descritos com detalhe suficiente para reprodução; nenhum código ou dado liberado.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**

Técnica(s) de pré-processamento	Suavização/Blur, Denoising (ausente), Outra	Blur gaussiano (σ de 1 a 5, passo 1; kernel = 4σ−1) e blur mediano (kernel de 3 a 9, passo 2); ruído gaussiano (σ de 10 a 50, passo 10) e sal-e-pimenta (parâmetro de 2 a 10, passo 2); contraste (multiplicador de 0,2 a 2,0, passo 0,2); balanço de cor (5% a 30%, passo 5%); intensidade por canal (+20 a +100, passo 20); oclusão sintética (óculos escuros, região periocular, nariz, boca, cachecol).
Arquitetura(s)	AlexNet, VGG, Outra	AlexNet (vetor de 4096-d da fc7) e GoogLeNet (vetor de 1024-d da pool5/7x7_s1), ambos pré-treinados no ImageNet e ajustados para faces; VGG-Face (vetor de 4096-d da fc6).
Dataset(s)	LFW (avaliação); CASIA-Webface + FaceScrub + CACD (fine-tuning)	LFW closed-set: galeria de 4249 sujeitos (1 imagem cada) e sondas de 3143 imagens. Conjunto de fine-tuning combinado: ≈530.000 imagens de 10.770 sujeitos, após

		correção manual de rótulos e remoção de duplicatas.
Métrica(s) de desempenho	Acurácia, Outra	Acurácia de identificação rank-1 e rank-5; similaridade de cosseno entre descritores como métrica auxiliar (Fig. 1).
Análise de frequência/espectral?	Não	Nenhuma análise espectral.
Intensidade em múltiplos níveis?	Sim	Todas as degradações são varridas em cinco ou mais níveis de intensidade (ver detalhes na primeira linha).
Múltiplas arquiteturas?	Sim	AlexNet, VGG-Face e GoogLeNet.
Código/Dados públicos?	Não	Nem código nem dados; o LFW e os datasets de treino são públicos, mas a combinação usada não é liberada.

Efeito sobre a Acurácia

Direção do efeito: Piora

• **Blur derruba o desempenho de forma acentuada e monotônica:** "All of the used deep network models are found to be very sensitive to image blur… increasing blur level decreases the accuracy dramatically" (Seção 4, Fig. 3a e 3b), tanto para filtro gaussiano quanto para filtro mediano.

• **Ruído leva o classificador a níveis próximos do acaso enquanto o humano ainda reconhece:** "At the very increased noise level, identification accuracy of the networks becomes less than %6. However, human eye can still easily recognize subjects at this level" (Seção 4).

• **Oclusão da região periocular é a degradação mais destrutiva:** rank-1 cai de 70,13% para 6,33% (VGG-Face), de 51,76% para 2,97% (AlexNet) e de 77,12% para 6,80% (GoogLeNet) — Tabela 1.

• **Nem toda alteração da imagem degrada:** distorções de cor e mudança de balanço de branco produzem apenas queda leve, e as redes são "surprisingly resilient to darkness distortion effect compared to the human eye" (Seção 4).

• **A sensibilidade depende da arquitetura:** GoogLeNet e AlexNet degradam mais rápido que VGG-Face sob ruído gaussiano crescente; a margem entre GoogLeNet e VGG-Face é de cerca de 10 pontos na maioria dos experimentos e chega a 20 pontos entre GoogLeNet e AlexNet.

Mecanismos Explicativos Propostos

• **Remoção de bordas e de textura como causa direta da queda:** "This decrease in identification accuracy can be explained as the blurring effect removes the edges and smooths color transition on the images. So, it may remove some necessary texture information that the deep CNN model is relying on for discrimination" (Seção 4).

• **Textura como sinal discriminativo aprendido:** "This indicates that texture information has an important role to learn discriminative features for deep neural networks" (Seção 4) — formulação explícita do mecanismo que o nosso SLR investiga.

• **Localização espacial do sinal discriminativo:** o experimento de oclusão mostra que a informação usada pela rede está concentrada na região periocular; ocluí-la é mais danoso do que ocluir nariz ou boca, o que caracteriza a degradação como remoção seletiva de sinal e não como perda difusa de qualidade.

• **Descolamento entre qualidade perceptual humana e desempenho da máquina:** as redes colapsam sob níveis de ruído que o observador humano atravessa sem dificuldade, e resistem a distorções (escurecimento) que atrapalham o humano — as duas escalas de "qualidade" não coincidem.

Evidência Espectral

Não. O artigo não realiza qualquer análise no domínio da frequência. O mecanismo é enunciado em termos espaciais (bordas, transições de cor, textura), o que o torna compatível com a hipótese espectral do nosso SLR mas não constitui evidência espectral direta.

Limitações Reconhecidas pelos Autores

Os autores registram que é necessária mais pesquisa para tornar o reconhecimento facial baseado em CNN robusto a blur, ruído e oclusão, e apontam como soluções práticas ainda não testadas o aumento do conjunto de treino com imagens degradadas e o projeto de modelos especializados por tipo de degradação. Não há discussão formal de ameaças à validade, nem justificativa para a escolha dos níveis de degradação.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Evidência direta, com baseline explícito e varredura de intensidade, de que blur e ruído derrubam a acurácia de identificação de três CNNs pré-treinadas, chegando a menos de 6% sob ruído forte.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Atribui explicitamente a queda causada por blur à remoção de bordas e de informação de textura usada como sinal discriminativo, e localiza espacialmente esse sinal por meio do experimento de oclusão.

• **RQ3 (Relação quantitativa):** Parcialmente relevante. Há curvas completas de acurácia por nível de degradação, o que permite relacionar dose e efeito, mas nenhuma medida de energia espectral é calculada e os valores estão apenas em figuras.

• **RQ4 (Condições de melhoria):** Pouco relevante. Nenhuma condição de melhoria é observada; o artigo apenas sugere, como trabalho futuro, aumentar o treino com imagens degradadas ou especializar modelos por tipo de degradação.

Qualidade Metodológica e Validade

O desenho experimental é adequado e o baseline é explícito e competitivo (o GoogLeNet ajustado dos autores supera o estado da arte de então no mesmo protocolo, 77,12% contra 72,30%). O ponto forte para o nosso SLR é a combinação de varredura sistemática de intensidade com uma explicação mecanística formulada nos termos exatos da nossa hipótese. As fraquezas são a ausência de tabelas numéricas para as curvas de blur e ruído, a limitação a um único benchmark de avaliação e a ausência de qualquer análise no domínio da frequência — o argumento sobre textura permanece qualitativo.

Título: An Empirical Study on the Effects of Different Types of Noise in Image Classification Tasks

Autores: Paranhos da Costa, Contato, Nazaré, Batista Neto & Ponti

Ano: 2016 | Veículo: não indicado no PDF; o repositório de código (wvc_2016_noise) associa o trabalho ao Workshop de Visão Computacional (WVC) de 2016; pré-print arXiv:1609.02781

Decisão: ACEITAR

Justificativa: O estudo avalia explicitamente o denoising como etapa de pré-processamento e mede o seu efeito sobre a classificação, com baseline sem ruído e sem pré-processamento, em dois datasets, três tipos de ruído, cinco níveis por tipo e dois métodos de denoising. O achado central — o denoising recupera parte do desempenho perdido mas nunca alcança o baseline limpo, e os autores atribuem a lacuna à perda de

detalhe e textura causada pela suavização — é evidência direta para as RQ1 e RQ4. A ressalva relevante é que os classificadores são SVM lineares sobre descritores LBP e HOG, e não CNNs.

Resumo Geral

Os autores investigam três perguntas encadeadas: se o ruído prejudica a classificação com descritores LBP e HOG, se a queda se deve à separabilidade das classes ou à falta de robustez do modelo, e se métodos de denoising ajudam. Para isso, geram versões ruidosas dos datasets Corel (10 800 imagens, 80 classes) e Caltech101-600 (600 imagens, 6 classes) com ruído gaussiano (σ de 10 a 50), Poisson (fator de escala de 10 a 12) e sal-e-pimenta (p de 0,1 a 0,5), e versões restauradas com filtro de mediana (11×11) e Non-Local Means. Um SVM linear é treinado separadamente para cada versão do conjunto de treino e testado em todas as versões do conjunto de teste, produzindo mapas de calor completos de F1-score cruzado. O melhor resultado em todas as combinações ocorre quando treino e teste são feitos sobre imagens sem ruído, e o denoising melhora a classificação de dados ruidosos sem jamais recuperar o baseline.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Datasets, tipos e níveis de ruído, métodos e parâmetros de denoising, descritores, classificador e protocolo de treino cruzado descritos nas Seções IV-A a IV-C.
2. Utiliza baseline sem pré-processamento para comparação	Sim	Baseline explícito: modelo treinado e testado em imagens originais, sem ruído e sem denoising — é a célula de melhor desempenho em todos os mapas de calor.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	F1-score médio ponderado pelo número de instâncias por classe, reportado em mapas de calor para todas as combinações treino×teste.

4. Experimentos descritos com detalhe suficiente para replicação	Sim	Parâmetros completos (LBP com R=1 e P=8; HOG com 8 orientações e células de 16×16; NLM com p=7, s=21, h=25; mediana 11×11; grid-search com validação cruzada 5-fold) e código público.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Parcialmente	Interpretam a queda como perda de separabilidade linear das classes e atribuem a lacuna residual do denoising à perda de detalhe e textura, mas não aprofundam o mecanismo.
6. Realiza análise no domínio da frequência / espectral	Não	Nenhuma análise no domínio da frequência.
7. Avalia mais de um dataset	Sim	Corel e Caltech101-600.
8. Avalia mais de uma arquitetura/modelo	Não	Um único classificador (SVM linear) sobre dois descritores; nenhuma CNN é avaliada.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Reconhecem, na conclusão, a necessidade de estender a análise a mais datasets, descritores, métodos de denoising e, sobretudo, a métodos de deep learning.

10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Somente código	Repositório público: github.com/gbpcosta/wvc_2016_noise, contendo também os resultados suplementares não incluídos no artigo.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Denoising, Suavização/Blur	Filtro de mediana com vizinhança 11×11 e Non-Local Means (p = 7, s = 21, h = 25). Degradações avaliadas: ruído gaussiano ($\sigma \in \{10,20,30,40,50\}$), Poisson (escala $\in \{10; 10,5; 11; 11,5; 12\}$) e sal-e-pimenta ($p \in \{0,1…0,5\}$).
Arquitetura(s)	Outra, Não especificado	Nenhuma CNN. Descritores LBP (uniforme, invariante a escala de cinza, escala e rotação) e HOG, classificados por SVM linear one-vs-all com hiperparâmetros por grid-search.

Dataset(s)	Corel; Caltech101-600	Corel: 10.800 imagens RGB, 80 classes, no mínimo 100 imagens por classe. Caltech101-600: subconjunto do Caltech101 com 6 classes (airplanes, bonsai, chandelier, hawksbill, motorbikes, watch) e 100 exemplos por classe.
Métrica(s) de desempenho	F1-score	F1-score médio ponderado pelo número de instâncias de cada classe, escolhido por lidar com desbalanceamento; valores apresentados em mapas de calor (Figs. 7 a 10).
Análise de frequência/espectral?	Não	Nenhuma análise espectral.
Intensidade em múltiplos níveis?	Sim	Cinco níveis para cada um dos três tipos de ruído; um único nível para cada método de denoising.
Múltiplas arquiteturas?	Não	Um único classificador; dois descritores.
Código/Dados públicos?	Somente código	github.com/gbpcosta/wvc_2016_noise

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **O baseline limpo nunca é superado:** "the best results were obtained by classifiers trained and tested using noise-free images" e, na conclusão, "none of the classifiers were able to overcome the performance of the classifier trained and tested with the original dataset" (Seções V e VI).

• **A degradação escala com a intensidade do ruído:** "the higher the noise level the lower the F1-score" para modelos treinados com dados originais (Seção V, questão 1, Fig. 6).

• **O denoising melhora sobre a entrada ruidosa:** "the use of denoising methods improved the classification performance when both training and test sets were affected by the same type of noise" (Seção V, questão 3).

• **Mas o denoising não recupera o baseline, e a causa apontada é a suavização:** "the achieved result was not as good as the one obtained using the original dataset, probably due to the loss of detail and texture caused by these methods"; na conclusão, "due to the smoothing caused by these methods, these results did not match the classification performance of the original dataset".

• **Modelos treinados sobre imagens restauradas generalizam mal para imagens ruidosas:** "models created with images after denoising did not perform well when tested with noisy images" (Seção V, questão 3) — o pré-processamento cria um novo domínio, não restaura o original.

Mecanismos Explicativos Propostos

• **Perda de detalhe e textura pela suavização:** é a explicação oferecida pelos autores para a lacuna residual entre o desempenho pós-denoising e o baseline limpo — o filtro remove, junto com o ruído, informação que o descritor usa.

• **Redução da separabilidade linear das classes:** como todos os modelos passaram por grid-search e os SVMs são lineares, os autores concluem que "our results indicate that the classes become less linearly separable in the presence of noise" (Seção V, questão 2), isto é, o problema está no espaço de características e não apenas na robustez do modelo.

• **Deslocamento do espaço de características:** "LBP and HOG are sensitive to noise, which might cause it to produce different feature spaces for the same data under different levels of noise" (Seção V) — a mesma imagem passa a ocupar posições distintas conforme o nível de degradação.

Evidência Espectral

Não. Não há transformada nem análise de bandas. Vale notar, porém, que LBP e HOG são descritores construídos sobre diferenças locais de intensidade e gradientes — isto é, sobre conteúdo de alta frequência —, o que torna a sensibilidade observada consistente com a hipótese espectral do SLR, ainda que o artigo não a formule nesses termos.

Limitações Reconhecidas pelos Autores

Os autores reconhecem, na conclusão, que a análise precisa ser estendida a mais datasets, descritores e métodos de denoising, e sobretudo a métodos de aprendizado profundo, "since these represent the state-of-the-art of image classification". Registram também que não usaram métricas de qualidade de imagem (PSNR, SSIM) para caracterizar o grau de

degradação, e que a análise de separabilidade linear é superficial por depender do uso de SVMs lineares.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Demonstra, com baseline limpo e matriz completa de generalização cruzada, que o ruído degrada a classificação e que a degradação escala com a intensidade, em dois datasets e três tipos de ruído.

• **RQ2 (Mecanismo explicativo):** Relevante. Atribui a lacuna residual do denoising à perda de detalhe e textura causada pela suavização, e mostra que o efeito do ruído é uma redução da separabilidade linear das classes, e não apenas falta de robustez do modelo.

• **RQ3 (Relação quantitativa):** Parcialmente relevante. Cinco níveis por tipo de ruído permitem observar a dose-resposta, mas os resultados estão em mapas de calor e nenhuma medida de energia espectral é feita.

• **RQ4 (Condições de melhoria):** Altamente relevante. Delimita a condição precisa em que o denoising ajuda — quando treino e teste sofrem o mesmo tipo de ruído — e mostra que o ganho é parcial e não transfere para outros domínios de ruído.

Qualidade Metodológica e Validade

O desenho de treino cruzado (um modelo por versão do conjunto de treino, avaliado em todas as versões do conjunto de teste) é rigoroso e permite separar o efeito do domínio de treino do efeito da degradação no teste — desenho que poucos artigos do lote adotam. Código e resultados suplementares são públicos. A limitação central para o nosso SLR é que nenhum classificador CNN é avaliado: as conclusões valem para LBP/HOG com SVM linear e devem ser transportadas para CNNs apenas como hipótese. Ainda assim, é a evidência mais limpa do lote para a afirmação de que o denoising melhora sobre a entrada degradada sem restaurar o desempenho original, e a explicação oferecida pelos autores (perda de detalhe e textura) é exatamente o mecanismo que o SLR investiga.

Título: Examining the Impact of Blur on Recognition by Convolutional Networks

Autores: Vasiljevic, Chakrabarti & Shakhnarovich

Ano: 2017 (v2; primeira versão 2016) | Veículo: não indicado no PDF (pré-print arXiv:1611.05760)

Decisão: ACEITAR

Justificativa: É um dos artigos mais alinhados ao desenho experimental do nosso SLR: aplica sistematicamente kernels de blur de tipos e intensidades variadas a imagens do ImageNet, mede a queda de acurácia top-5 de uma CNN pré-treinada em imagens nítidas, compara com um baseline limpo, e ainda testa a alternativa de restaurar a imagem por deblurring antes da classificação. Fornece também uma análise da representação interna (invariância a blur camada a camada) e evidência de que o blur moderado pode funcionar como aumento de dados, cobrindo as RQ1, RQ2 e RQ4.

Resumo Geral

Os autores investigam o efeito do blur — desfoque, movimento uniforme e trepidação de câmera — sobre a classificação de imagens por CNNs, e até que ponto essa degradação pode ser remediada. Na primeira parte, avaliam a VGG-16 pré-treinada sobre versões borradas do conjunto de validação do ImageNet 2012, com kernels de disco (desfoque), caixas orientadas (movimento linear), splines aleatórios em grade 15×15 (trepidação) e kernels gaussianos, em quatro escalas de aplicação da rede. Na segunda parte, fazem fine-tuning com misturas de imagens nítidas e borradas e medem a generalização entre tipos e graus de blur. Na terceira, comparam essa estratégia com o deblurring explícito da entrada (com kernel conhecido) seguido do classificador original. Por fim, analisam as ativações intermediárias para localizar em que profundidade a invariância a blur é adquirida, e estendem a análise à segmentação semântica no VOC2012.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Kernels, escalas, protocolo de fine-tuning (2 épocas a 1e-3 e 1 época a 1e-4, momento 0,9, batch 128) e protocolo de avaliação descritos nas Seções 3 e 4.
2. Utiliza baseline sem pré-processamento para comparação	Sim	A linha "Sharp" é o baseline em todas as tabelas (Tabelas 1, 3, 4 e 5).
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Acurácia top-5 tabulada para 12 condições de blur × 4 escalas (Tabela 1) e para 6 modelos × 5 condições (Tabela 3); entropia e entropia cruzada

		das distribuições preditas (Tabela 2).
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Hiperparâmetros completos, geração dos kernels descrita e referenciada; resultados adicionais em material suplementar (incluindo ResNet).
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	Discutem o blur como filtro passa-baixa, analisam a disparidade de ativações camada a camada e argumentam por que a generalização falha entre kernels radiais e orientados.
6. Realiza análise no domínio da frequência / espectral	Não	Os kernels são caracterizados como filtros passa-baixa ("they lead to a loss or attenuation of high-frequency image detail"), mas nenhuma transformada é calculada nem energia por banda é medida.

7. Avalia mais de um dataset	Sim	ImageNet 2012 (classificação) e VOC2012 + COCO (segmentação semântica).
8. Avalia mais de uma arquitetura/modelo	Parcialmente	VGG-16 é o modelo principal; resultados para ResNet aparecem apenas no material suplementar, com "similar performance degradation".
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Discutem abertamente os limites da estratégia (o fine-tuning com um único kernel destrói o desempenho nos demais; o deblurring custa ~4 minutos por imagem), mas sem seção formal de ameaças à validade.
10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Parcialmente	Hiperparâmetros e procedimento de geração de kernels descritos com detalhe suficiente; nenhum

		código liberado no PDF.

Extração de Dados

Campo do SLR	Valor Extraído	Detalhes
Técnica(s) de pré-processamento	Suavização/Blur, Outra	Blur de disco (desfoque, raios r = 2, 4, 6, 8); caixas horizontais e verticais de largura 1 e comprimentos 4 e 8 (movimento linear uniforme); 100 kernels de trepidação 17×17 gerados como splines com 6 pontos de controle em grade 15×15; kernels gaussianos (σ = 4 e 8). Como técnica de restauração, deblurring não-cego com kernel verdadeiro.
Arquitetura(s)	VGG, ResNet	VGG-16 pré-treinada (modelo original dos autores), avaliada nas escalas 128, 256, 512 e 256+512; ResNet no material suplementar; para segmentação, o método de Hariharan et al. sobre ativações concatenadas da VGG-16.

Dataset(s)	ImageNet (ILSVRC 2012); PASCAL VOC 2012 + COCO	ImageNet: conjunto de validação padrão, 1000 classes, redimensionado para escala fixa 384 antes do borramento para uniformizar o tamanho efetivo do kernel. VOC2012 com pesos treinados em VOC + COCO para a extensão em segmentação.
Métrica(s) de desempenho	Acurácia, Outra	Acurácia top-5; entropia e entropia cruzada das distribuições de classe preditas; para segmentação, as métricas do benchmark VOC2012.
Análise de frequência/espectral?	Não	Sem análise espectral quantitativa; a caracterização passa-baixa dos kernels é feita de forma qualitativa na Seção 2.

Intensidade em múltiplos níveis?	Sim	Quatro raios de desfoque (2, 4, 6, 8), dois comprimentos de movimento (4 e 8), dois desvios gaussianos (4 e 8) e um banco de 100 kernels de trepidação de intensidade variável.
Múltiplas arquiteturas?	Parcialmente	VGG-16 no corpo do artigo; ResNet apenas no suplementar.
Código/Dados públicos?	Não	Nem código nem dados liberados no PDF.

Efeito sobre a Acurácia

Direção do efeito: Piora

• **A queda é clara, monotônica e dependente do kernel:** na escala 256, a acurácia top-5 da VGG-16 cai de 90,88% (nítida) para 88,06% / 81,48% / 72,69% / 60,97% com desfoque de raio 2/4/6/8, e para 62,38% e 17,39% com σ gaussiano de 4 e 8 (Tabela 1).

• **Blur de movimento é menos danoso que desfoque radial de "tamanho" comparável:** comprimento 8 horizontal dá 83,32% contra 60,97% do desfoque de raio 8 — os autores atribuem isso ao fato de a atenuação de alta frequência ser unidirecional no primeiro caso e radialmente uniforme no segundo.

• **A degradação vem acompanhada de perda de confiança, não de erro confiante:** a entropia média das distribuições preditas sobe de 1,1837 (nítida) para 2,6131 (D4) e 3,8021 (D8) no modelo original (Tabela 2); o classificador "makes inaccurate predictions… with low-confidence".

• **Escalas maiores agravam o efeito:** na escala 512 a acurácia com desfoque de raio 8 despenca para 22,52% e com σ = 8 para 3,41%, porque o redimensionamento aumenta o tamanho efetivo do kernel.

• **Blur moderado como aumento de dados melhora até a acurácia em imagens nítidas:** o fine-tuning com mistura de imagens nítidas e desfoque de raio 4 elevou a acurácia sobre imagens nítidas de 90,88% para 91,36%, "suggesting that moderate blurring can act as a form of data augmentation" (Seção 4.1).

• **Restaurar por deblurring recupera, mas custa caro e é inferior ao fine-tuning:** no subconjunto de validação, nítida 90,60%, borrada D8 61,57%, deblurred 87,00%; o modelo ajustado aplicado diretamente sobre a imagem borrada atinge 87,15% (mistura) e 88,3% (só D8), com o deblurring consumindo cerca de 4 minutos por imagem em GPU (Tabela 5).

Mecanismos Explicativos Propostos

• **Blur é um filtro passa-baixa:** "Both kinds of blur kernels are 'low-pass' filters, i.e., they lead to a loss or attenuation of high-frequency image detail" (Seção 2) — o mecanismo é enunciado explicitamente em termos de remoção de alta frequência.

• **A informação semântica não é destruída, apenas mal representada:** o fine-tuning "nearly closes the performance gap caused by blur", o que permite aos autores descartar as hipóteses alternativas de deficiência arquitetural ou de ausência de informação discriminativa na imagem borrada — a degradação é um problema de descasamento de distribuição, não de perda irrecuperável de sinal.

• **A invariância a blur é adquirida tarde, no nível semântico:** a análise de distância de Hamming entre ativações binarizadas mostra que o modelo ajustado atinge baixa disparidade entre entrada nítida e borrada apenas nas camadas pool4 e pool5, enquanto "the disparity in activations in the initial layers of the network remains high" (Seção 4.3) — as camadas iniciais não conseguem compensar a perda de alta frequência.

• **A estatística espectral do kernel governa a transferência entre tipos de blur:** o ajuste com kernels de desfoque degrada ligeiramente o desempenho em blur de movimento porque "images blurred with oriented motion kernels present significantly different statistics than defocus blur, with high-frequency attenuation being only along one direction in the former, and radially uniform in the latter" (Seção 4.1).

Evidência Espectral

Parcialmente. Não há transformada de Fourier nem medição de energia por banda, mas todo o argumento mecanístico é formulado em termos espectrais: os kernels são caracterizados como filtros passa-baixa, e a diferença de transferência entre desfoque e movimento é atribuída à direcionalidade da atenuação de alta frequência (radial versus unidirecional). A análise quantitativa efetivamente realizada é feita no espaço de ativações (distância de Hamming por camada), não no domínio da frequência.

Limitações Reconhecidas pelos Autores

Os autores restringem a análise a blur espacialmente uniforme "for ease of analysis", reconhecendo que na prática o kernel pode variar espacialmente por variação de profundidade ou movimento fora do plano. Registram que o ajuste com um único kernel conhecido produz ganho marginal sobre o kernel alvo mas "severely degrades performance for other blur types", e que a estratégia de fine-tuning por escala, embora ligeiramente superior, não compensa o custo de armazenar duas versões do modelo. Reconhecem ainda

que o resultado de deblurring representa o melhor caso possível, por assumir o kernel verdadeiro conhecido.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Tabela 1 é uma das evidências mais limpas do lote: queda monotônica de acurácia top-5 sob doze condições de blur, com baseline nítido, em quatro escalas de aplicação da rede.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Enuncia o blur como filtro passa-baixa que atenua detalhe de alta frequência, mostra por meio do fine-tuning que a informação semântica não foi destruída, e localiza por análise de ativações em que profundidade a invariância é (ou não é) adquirida.

• **RQ3 (Relação quantitativa):** Relevante. Quatro raios de desfoque, dois comprimentos de movimento e dois desvios gaussianos produzem uma curva dose-resposta clara; a dose, porém, é medida como tamanho de kernel e não como energia espectral removida.

• **RQ4 (Condições de melhoria):** Altamente relevante. Documenta duas condições: blur moderado usado como aumento de dados melhora a acurácia até em imagens nítidas (91,36% contra 90,88%), e o deblurring explícito recupera boa parte da acurácia mas é inferior e muito mais caro do que treinar o modelo com a degradação.

Qualidade Metodológica e Validade

Metodologicamente sólido para os fins do SLR: baseline explícito, varredura sistemática de tipo e intensidade de degradação, comparação direta entre as duas estratégias concorrentes (restaurar a entrada versus adaptar o modelo) e uma análise de representação interna que localiza onde a informação é perdida. A ausência de análise espectral quantitativa e a concentração em uma única arquitetura no corpo do texto são as principais limitações. A conclusão de que restaurar a imagem por deblurring é inferior a treinar o modelo com a degradação é diretamente pertinente à nossa RQ4.

Título: DeepCorrect: Correcting DNN Models against Image Distortions

Autores: Borkar & Karam

Ano: 2019 (v5; primeira versão 2017) | Veículo: manuscrito em formato IEEE Transactions (autores identificados como Student Member e Fellow do IEEE); veículo específico não indicado no PDF; pré-print arXiv:1705.02406

Decisão: ACEITAR

Justificativa: O artigo mede a queda de acurácia de redes pré-treinadas sob blur gaussiano e ruído branco aditivo em seis níveis de intensidade cada, com baseline sem distorção, e vai além ao localizar quais filtros convolucionais são responsáveis pela degradação. A identificação de que os filtros mais suscetíveis ao blur são precisamente os seletivos em frequência e orientação (detectores de borda e contorno) é evidência mecanística de primeira ordem para a RQ2 do nosso SLR.

Resumo Geral

O trabalho parte da constatação de que redes treinadas em imagens não degradadas têm desempenho ruim sobre imagens distorcidas, e propõe localizar a origem dessa degradação no nível do filtro convolucional individual. Os autores definem uma métrica de suscetibilidade que ordena os filtros de cada camada pelo ganho de acurácia esperado ao corrigi-los, e mostram que corrigir apenas 50% dos filtros mais suscetíveis de uma única camada já recupera parte substancial do desempenho — evidência de que a degradação não se distribui uniformemente. A partir disso propõem o DeepCorrect, que insere pequenos blocos residuais (unidades de correção) na saída dos filtros de pior ranking, mantendo intactos todos os demais filtros pré-treinados. A visualização dos filtros identificados como mais suscetíveis a cada tipo de distorção é o resultado de maior interesse para o nosso SLR.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Modelos, distorções, níveis, métrica de ranking (com pseudocódigo), arquitetura das unidades de correção e protocolo de treino descritos nas Seções III a V.
2. Utiliza baseline sem pré-processamento para comparação	Sim	Coluna "Original" na Tabela I (AlexNet 0,5694; ResNet18 0,6912) e linha "Baseline" nas Tabelas II, VI e VII.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Acurácia top-1 no ImageNet (Tabelas I e II) e acurácia média por categoria em Caltech-101, Caltech-256 e SUN-397 (Tabelas V a VII).

4. Experimentos descritos com detalhe suficiente para replicação	Sim	Hiperparâmetros de treino descritos, arquitetura das unidades de correção especificada e código público.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	Identificam quais filtros são suscetíveis a cada distorção e interpretam o resultado em termos do tipo de característica que cada filtro extrai (bordas/contornos versus cor).
6. Realiza análise no domínio da frequência / espectral	Parcialmente	Não há transformada; a caracterização dos filtros como "frequency- and orientation-selective" é feita por inspeção visual dos kernels da primeira camada (Fig. 4), não por análise espectral quantitativa.
7. Avalia mais de um dataset	Sim	ImageNet, Caltech-101, Caltech-256 e SUN-397.
8. Avalia mais de uma arquitetura/modelo	Sim	AlexNet e ResNet18 no experimento principal; comparações com Finetune, Finetune-rc e variantes do DeepCorrect.

9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Discutem o custo computacional adicional (as unidades de correção quase dobram os FLOPs) e o compromisso entre número de parâmetros treinados e ganho, mas sem seção formal de ameaças à validade.
10. Publicado em veículo revisado por pares	Não informado	Formato IEEE, mas o veículo não é identificado no PDF.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Somente código	github.com/tsborkar/DeepCorrect

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Suavização/Blur, Outra	Blur gaussiano com $\sigma_b \in \{1, 2, 3, 4, 5, 6\}$ e kernel de tamanho $4\sigma_b$; ruído branco gaussiano aditivo (AWGN) com $\sigma_n \in \{10, 20, 40, 60, 80, 100\}$. Como técnica de "correção", blocos residuais rasos de 4 camadas convolucionais com conexão de atalho inseridos após os

		filtros de pior ranking.
Arquitetura(s)	AlexNet, ResNet	AlexNet e ResNet18 pré-treinadas; variantes DeepCorrect, Deepcorr-b, Deepcorr-rc, Finetune e Finetune-rc.
Dataset(s)	ImageNet (ILSVRC 2012); Caltech-101; Caltech-256; SUN-397	ImageNet: conjunto de validação, 1000 classes. Caltech-101 e Caltech-256: reconhecimento de objetos. SUN-397: classificação de cenas, usada para testar transferência das características invariantes a distorção.
Métrica(s) de desempenho	Acurácia, Outra	Acurácia top-1 (ImageNet) e acurácia média por categoria (Caltech e SUN); FLOPs e número de parâmetros treináveis como métricas de custo.
Análise de frequência/espectral?	Não	Sem análise espectral quantitativa; a leitura dos filtros suscetíveis como "seletivos em frequência e orientação" é qualitativa.
Intensidade em múltiplos níveis?	Sim	Seis níveis de blur e seis níveis de AWGN; adicionalmente, a fração de filtros corrigidos por camada é

		varrida em $\beta \in \{10\%, 25\%, 50\%, 75\%, 90\%\}$.
Múltiplas arquiteturas?	Sim	AlexNet e ResNet18, além de múltiplas variantes de correção.
Código/Dados públicos?	Somente código	github.com/tsborkar/DeepCorrect

Efeito sobre a Acurácia

Direção do efeito: Piora

• **A degradação sob distorção é severa em redes pré-treinadas:** a acurácia top-1 da AlexNet cai de 0,5694 (imagens originais) para 0,2305 sob blur gaussiano e 0,2375 sob AWGN, médias sobre todos os níveis; a ResNet18 cai de 0,6912 para 0,3841 e 0,3255 (Tabela I).

• **A degradação persiste em tarefas transferidas:** com AlexNet como extrator de características, a acurácia média por categoria cai de 0,8500 para 0,4980 (Caltech-101), de 0,6200 para 0,2971 (Caltech-256) e de 0,3100 para 0,1393 (SUN-397) sob blur; sob AWGN cai para 0,3423, 0,1756 e 0,0859 (Tabelas V a VII).

• **A degradação está concentrada em um subconjunto de filtros:** "it is possible to recover a significant amount of the lost performance, by correcting only 50% of the filter activations in any one layer, which indicates that a select subset of convolutional filters in each layer are indeed more susceptible to distortions than the rest" (Seção IV-A, Fig. 3).

• **A correção direcionada recupera mais que o fine-tuning completo, com muito menos parâmetros:** DeepCorrect atinge 0,5071 (blur) e 0,5092 (AWGN) contra 0,4596 e 0,4894 do Finetune e 0,2305/0,2375 do baseline, treinando ≈2,81 milhões de parâmetros contra 61 milhões do Finetune (Tabelas II e III).

• **Mesmo o melhor método não restaura o desempenho sobre imagens limpas:** 0,5071 sob blur corrigido continua abaixo de 0,5694 do baseline não distorcido.

Mecanismos Explicativos Propostos

• **Os filtros mais atingidos pelo blur são os detectores de borda e contorno:** "The identified filters most susceptible to Gaussian blur are mainly frequency- and orientation-selective filters, most of which are color agnostic, while filters most susceptible to AWGN are a mix of both color specific blobs and frequency- and orientation-selective filters" (Seção IV-A, Fig. 4).

• **Correspondência entre o que a técnica remove e o que o filtro extrai:** "This is in line with our intuitive understanding that Gaussian blur majorly affects edges and object contours and not object color, while AWGN affects color as well as object contours" — o dano é seletivo e previsível a partir da natureza espectral da degradação.

• **Descasamento de estatísticas de imagem:** os autores enquadram a queda como consequência de "test images with significantly different image statistics than those used to train these networks" (Seção IV), isto é, deslocamento de domínio.

• **A degradação se propaga por ativações corrompidas, e não por incapacidade da arquitetura:** o objetivo do DeepCorrect é aprender uma transformação que aproxime a ativação distorcida da ativação não distorcida do mesmo filtro; o sucesso dessa estratégia sustenta que o problema está na resposta dos filtros específicos, não na representação global.

Evidência Espectral

Parcialmente. Não há transformada nem medição de energia por banda. Contudo, a evidência central do artigo é espectral em substância: os filtros da primeira camada da AlexNet são classificados em duas famílias — seletivos em frequência e orientação (captam bordas e contornos) e blobs específicos de cor — e o ranking de suscetibilidade mostra que o blur gaussiano atinge preferencialmente a primeira família. É uma demonstração, no nível do filtro, de que a suavização degrada o classificador ao remover exatamente o conteúdo de alta frequência que parte dos filtros aprendeu a detectar.

Limitações Reconhecidas pelos Autores

Os autores reconhecem que as unidades de correção acrescentam custo computacional relevante (aproximadamente o dobro de FLOPs na fase de teste em relação à rede original) e discutem variantes mais econômicas com perda de acurácia. Registram também que o método requer conhecimento prévio do tipo de distorção para treinar as unidades de correção correspondentes. Não há discussão formal de ameaças à validade nem análise da sensibilidade da métrica de ranking.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Queda de 0,5694 para 0,2305 (AlexNet, blur) e de 0,6912 para 0,3841 (ResNet18, blur), com quedas equivalentes sob ruído e replicação em três datasets de transferência.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Localiza a degradação no nível do filtro individual e mostra que os filtros mais atingidos pelo blur são precisamente os seletivos em frequência e orientação, que captam bordas e contornos — evidência mecanística no nível da representação aprendida.

• **RQ3 (Relação quantitativa):** Parcialmente relevante. Há seis níveis de intensidade por degradação e uma varredura da fração de filtros corrigidos, mas os resultados são reportados como médias sobre todos os níveis, o que impede reconstruir a curva dose-resposta a partir das tabelas.

• **RQ4 (Condições de melhoria):** Relevante. Mostra que correção direcionada a um subconjunto de filtros recupera mais desempenho do que o fine-tuning completo com muito menos parâmetros, mas nenhuma condição restaura o baseline de imagens não distorcidas.

Qualidade Metodológica e Validade

Trabalho extenso e bem instrumentado, com baseline explícito, varredura de intensidade, quatro datasets, duas arquiteturas e código público. Para o nosso SLR, o valor principal não está na técnica proposta, mas no diagnóstico: a Figura 4 é uma das evidências visuais mais diretas de que a suavização degrada a classificação por atingir seletivamente os filtros seletivos em frequência e orientação. A limitação é que essa caracterização é feita por inspeção dos kernels, sem quantificação espectral, o que a mantém no plano da evidência qualitativa forte.

Título: Enhancing the Performance of Convolutional Neural Networks on Quality Degraded Datasets

Autores: Yim & Sohn

Ano: 2017 | Veículo: não indicado no PDF (pré-print arXiv:1710.06805)

Decisão: ACEITAR

Justificativa: O estudo avalia três métodos clássicos de denoising (filtragem não-local, bilateral e variação total) como pré-processamento antes de uma CNN pré-treinada, e mede a acurácia de classificação sobre quatro tipos de degradação em quatro intensidades, comparando com o modelo original sem pré-processamento. O achado central — o pré-processamento isoladamente não produz melhoria consistente e chega a reduzir o desempenho sobre o dataset original — é evidência empírica direta para as RQ1 e RQ4, e a explicação oferecida (a filtragem "dilui as bordas-chave do objeto") aponta o mecanismo da RQ2.

Resumo Geral

Os autores investigam se técnicas tradicionais de denoising continuam úteis quando acopladas a uma CNN moderna e profunda, cuja própria hierarquia de filtros já extrai múltiplas propriedades espaciais. Usando Inception-v3 pré-treinada sobre um subconjunto de 50 classes do ImageNet 2012, comparam duas arquiteturas: um modelo único que recebe a imagem pré-processada, e um modelo de canal duplo que recebe simultaneamente a imagem original e a imagem realçada em contornos, concatenando as características antes da camada totalmente conectada. As degradações — ruído gaussiano, speckle, sal-e-pimenta e compressão JPEG, cada uma em quatro intensidades — são aplicadas apenas na fase de teste, nunca no treino. O resultado é que o modelo único com pré-processamento falha, enquanto o canal duplo melhora consistentemente sobre o modelo original.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Métodos de denoising, arquitetura base, tipos e níveis de degradação, estratégias de treino e protocolo de fine-tuning descritos nas Seções III a V.
2. Utiliza baseline sem pré-processamento para comparação	Sim	A linha "Original" da Tabela 1 e a linha de referência das Figuras 8 e 9 correspondem ao modelo sem pré-processamento.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Acurácia top-1 tabulada para 3 métodos × 4 degradações × 4 intensidades (Tabela 1) e comparação de estratégias de fusão (Tabela 2).
4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Estratégia de treino e taxas de aprendizado descritas, mas os parâmetros exatos dos filtros de denoising e dos níveis de degradação não são especificados ("We chose

		the levels of the parameters manually").
5. Discute mecanismos explicativos, não apenas resultados empíricos	Parcialmente	Explicam o fracasso do modelo único pela remoção inconsistente de detalhes e diluição de bordas, mas a análise é qualitativa e baseada em inspeção visual.
6. Realiza análise no domínio da frequência / espectral	Não	Nenhuma análise no domínio da frequência.
7. Avalia mais de um dataset	Não	Um único conjunto: subconjunto de 50 classes do ImageNet 2012.
8. Avalia mais de uma arquitetura/modelo	Não	Apenas Inception-v3 (em configuração única e em canal duplo).
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Reconhecem que o modelo único subajusta e que o método 1 (filtragem não-local) apaga detalhes de forma inconsistente, mas não há seção de ameaças à validade.

10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Não	Nem código nem dados; parâmetros de degradação escolhidos manualmente e não tabelados.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Denoising, Suavização/Blur, Compressão JPEG	Pré-processamento: filtragem não-local (método 1), filtragem bilateral (método 2) e denoising por variação total (método 3). Degradações avaliadas no teste: ruído gaussiano, speckle, sal-e-pimenta e compressão JPEG, em quatro intensidades cada.

Arquitetura(s)	Outra	Inception-v3 pré-treinada (21,2% de erro top-1 e 5,6% top-5 no ILSVRC), usada isoladamente e em arquitetura de canal duplo com fusão por concatenação (4096-d) ou por soma (2048-d).
Dataset(s)	ImageNet (ILSVRC 2012), subconjunto	50 classes escolhidas aleatoriamente entre as 1000 do ImageNet 2012, por eficiência computacional; imagens naturais.
Métrica(s) de desempenho	Acurácia	Acurácia top-1 (as 50 classes tornam o top-5 pouco informativo); resultados também apresentados como razão em relação ao modelo original.
Análise de frequência/espectral?	Não	Nenhuma análise espectral.
Intensidade em múltiplos níveis?	Sim	Quatro níveis de intensidade para cada uma das quatro

		degradações; um único ajuste por método de denoising.
Múltiplas arquiteturas?	Não	Apenas Inception-v3.
Código/Dados públicos?	Não	Nem código nem dados.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **O pré-processamento isolado não entrega melhoria consistente:** "In Figure 8, the preprocessing methods show better accuracy in several cases. However, the results do not conclusively prove that preprocessing is the better method"; na conclusão, "a preprocessing method on its own did not produce any significant improvement" (Seções V-D e VI).

• **O modelo único com pré-processamento perde desempenho no dataset original:** "the single model setup reduces the performance using the original image dataset causing the model to be underfit" (Seção V-D) — custo pago sobre imagens limpas.

• **A arquitetura de canal duplo melhora em todas as degradações:** com filtragem bilateral (Prep.2), a acurácia sobe de 64,74/48,15/35,53/27,59 para 68,79/53,57/40,84/30,70 sob ruído gaussiano nas intensidades 1 a 4, e de 70,95/54,88/40,54/30,36 para 72,88/58,78/46,16/33,62 sob sal-e-pimenta (Tabela 1a e 1c).

• **Também há ganho sob compressão JPEG:** de 88,22/87,90/82,61/63,90 para 89,06/88,46/84,06/67,87 com Prep.2 (Tabela 1d).

• **O método de denoising mais agressivo é o pior:** a filtragem não-local (Prep.1) produz os menores ganhos em todas as degradações, e a filtragem bilateral (Prep.2) os maiores.

• **A forma de fusão importa:** com intensidade 2 e filtragem bilateral, a concatenação supera a soma em todas as degradações (53,57 contra 47,85 sob gaussiano; 60,55 contra 52,81 sob speckle) — Tabela 2.

Mecanismos Explicativos Propostos

• **Denoising é conceitualmente blur seguido de realce de bordas:** "Denoising suppresses the small details and perturbations, and enhances the edges. This operation can basically be represented as a blurring of the image, followed by the enhancement of the edges" (Seção IV-A).

• **O fracasso do método mais agressivo é atribuído à destruição de bordas:** "the preprocessing method '1' produced less improvement because it removed important details of the object inconsistently and, unlike the other two methods, diluted the key edges of an object" (Seção V-D).

• **A remoção inconsistente de detalhe é o fator crítico:** na análise visual, os autores registram que a filtragem não-local "tended to wipe out the lines and partial details of the objects inconsistently", e que "these inconsistencies in maintaining the details are reflected in the results" (Seção III-A).

• **Complementaridade em vez de substituição:** a solução proposta preserva o canal da imagem original justamente porque substituir a entrada pela versão filtrada custa desempenho; as características realçadas em contorno só agregam valor quando somadas às originais, não quando as substituem.

Evidência Espectral

Não. Não há transformada nem análise de bandas. O mecanismo é descrito no domínio da imagem (supressão de detalhes, realce e diluição de bordas), o que é compatível com a hipótese espectral do SLR mas não a testa.

Limitações Reconhecidas pelos Autores

Os autores reconhecem que o modelo único subajusta e reduz o desempenho no dataset original, e que os níveis de degradação foram escolhidos manualmente, sem critério objetivo. O uso de apenas 50 das 1000 classes do ImageNet, justificado por custo computacional, limita a generalidade dos números absolutos. Não há avaliação de outras arquiteturas nem de outros datasets, e nenhum código é disponibilizado.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Relevante. Documenta que aplicar denoising clássico como etapa única de pré-processamento reduz o desempenho sobre o dataset original, além de mostrar a queda de acurácia sob quatro degradações em quatro intensidades.

• **RQ2 (Mecanismo explicativo):** Relevante. Descreve o denoising como borramento seguido de realce de bordas, e atribui o pior resultado do método mais agressivo à remoção inconsistente de detalhes e à diluição das bordas do objeto.

• **RQ3 (Relação quantitativa):** Pouco relevante. Quatro níveis de intensidade por degradação, mas sem varredura da intensidade do pré-processamento e sem qualquer medida espectral.

• **RQ4 (Condições de melhoria):** Altamente relevante. Estabelece uma condição arquitetural precisa: a imagem filtrada só agrega desempenho quando usada como canal adicional ao lado da imagem original, e não quando a substitui; a fusão por concatenação supera consistentemente a fusão por soma.

Qualidade Metodológica e Validade

O desenho tem uma virtude metodológica relevante para o nosso SLR: as imagens degradadas nunca são usadas no treino, de modo que o experimento mede genuinamente

o efeito do pré-processamento sobre um classificador que não viu a degradação. Em contrapartida, o estudo é limitado a uma arquitetura, um subconjunto de dataset, e não especifica os parâmetros dos filtros nem os níveis de degradação, o que compromete a replicabilidade. Para o SLR, o resultado mais útil é negativo e claro: aplicar denoising clássico antes de uma CNN moderna, isoladamente, não melhora de forma consistente e custa acurácia nas imagens limpas — o ganho só aparece quando a imagem filtrada é usada como canal adicional, e não como substituto da original.

Título: Measuring the Tendency of CNNs to Learn Surface Statistical Regularities

Autores: Jo & Bengio

Ano: 2017 | Veículo: não indicado no PDF (pré-print arXiv:1711.11561)

Decisão: ACEITAR

Justificativa: O estudo aplica filtragem explícita no domínio de Fourier (máscara radial passa-baixa e máscara aleatória) às imagens e mede a queda de acurácia de CNNs profundas, com baseline sem filtragem e tabelas completas de generalização cruzada treino×teste. É evidência quantitativa direta de que remover energia espectral degrada o classificador, acompanhada de uma hipótese mecanística explícita — as CNNs se apoiam em regularidades estatísticas superficiais do espectro de Fourier do dataset, e não em abstrações de alto nível.

Resumo Geral

Os autores propõem uma forma operacional de medir se as CNNs aprendem conceitos semânticos ou apenas regularidades estatísticas superficiais. A ideia é construir uma transformação que preserve quase integralmente a reconhecibilidade humana dos objetos, mas altere as estatísticas superficiais do dataset — no caso, as estatísticas de Fourier. Duas filtragens são usadas: máscara radial, que zera os modos de frequência acima de um raio, e máscara aleatória, que zera cada modo com probabilidade p = 0,1. Treinam ResNets pré-ativadas com gargalo, de profundidades 92 e 200, sobre cada versão do conjunto de treino (não filtrado, radial, aleatório e conjunto aumentado) e avaliam sobre todas as versões do conjunto de teste, tabulando o erro final e o "gap de generalização" (a maior diferença de acurácia entre os conjuntos de teste). Os gaps encontrados chegam a mais de 28% no CIFAR-10, e a profundidade da rede não os reduz.

Critérios de Qualidade

Critério de qualidade	Resposta	Observação

1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Definição formal das máscaras (radial e aleatória), hiperparâmetros de treino por dataset, arquiteturas e protocolo de generalização cruzada descritos nas Seções 4 e 5.
2. Utiliza baseline sem pré-processamento para comparação	Sim	A linha e a coluna "Unfilt." das tabelas de generalização (Figs. 5 e 8) constituem o baseline sem filtragem.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Tabelas completas de erro de teste para 4 conjuntos de treino × 3 conjuntos de teste, por dataset e por profundidade, com a coluna de gap de generalização.
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Máscaras definidas por equação, raio e probabilidade explicitados (SVHN: raio 4,25 e p = 0,1; CIFAR-10: raio 11,0 e p = 0,1), semente aleatória fixada em 0, hiperparâmetros completos de otimização.

5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	A hipótese das regularidades estatísticas superficiais é a tese central do artigo, e não um comentário acessório.
6. Realiza análise no domínio da frequência / espectral	Sim	Toda a manipulação é feita no domínio da DFT bidimensional, com máscaras espectrais explícitas; discutem a lei de potência do espectro de imagens naturais.
7. Avalia mais de um dataset	Sim	SVHN e CIFAR-10 (MNIST foi descartado por perder reconhecibilidade sob filtragem).
8. Avalia mais de uma arquitetura/modelo	Parcialmente	Duas profundidades da mesma família (Preact-ResNet-Bottleneck de 92 e 200 camadas), não duas famílias arquiteturais distintas.

9. Discute limitações metodológicas ou ameaças à validade	Sim	Discutem explicitamente que a redução do gap por aumento de dados não demonstra aprendizado de abstrações e que outra perturbação poderia revelar um novo gap.
10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Parcialmente	Parâmetros completos e semente fixada; nenhum repositório de código indicado.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Suavização/Blur, Outra	Filtragem passa-baixa por máscara radial no domínio da DFT (zera modos com norma acima do raio r; r = 4,25 no SVHN e r = 11,0 no CIFAR-10) e filtragem por máscara aleatória fixa (cada modo zerado com

		probabilidade p = 0,1, máscara gerada uma vez e aplicada a todo o conjunto).
Arquitetura(s)	ResNet	Preact-ResNet com arquitetura Bottleneck, profundidades 92 e 200, inicialização HeNormal, semente 0.
Dataset(s)	SVHN; CIFAR-10	SVHN: conjunto de treino original combinado com o conjunto extra, intensidades normalizadas para [0,1]. CIFAR-10: normalização de contraste global e aumento por espelhamento horizontal, com padding para 40×40 e recorte aleatório 32×32. Ambos com imagens 32×32×3.
Métrica(s) de desempenho	Acurácia, Outra	Erro de teste final e "gap de generalização", definido como a maior diferença de acurácia entre os conjuntos de teste avaliados.

Análise de frequência/espectral?	Sim	DFT bidimensional deslocada (componente DC no centro), com máscaras radiais e aleatórias definidas formalmente; discussão da concentração de energia em baixas e médias frequências por lei de potência $P(w) \propto \|w\|^{(\eta-2)}$.
Intensidade em múltiplos níveis?	Parcialmente	Um raio e uma probabilidade por dataset (calibrados para preservar a reconhecibilidade humana), não uma varredura de intensidade.
Múltiplas arquiteturas?	Parcialmente	Duas profundidades da mesma família de arquitetura.
Código/Dados públicos?	Não	Nem código nem dados filtrados liberados.

Efeito sobre a Acurácia

Direção do efeito: Piora

• **A filtragem passa-baixa no teste degrada severamente redes treinadas em dados não filtrados:** no CIFAR-10 com Preact-ResNet-200, o erro sobe de 5,22% (não filtrado) para 23,37% (radial), um gap de 18,15%; na profundidade 92, de 5,54% para 25,75%, gap de 20,21% (Fig. 8).

• **O efeito é bem menor em datasets de espectro mais simples:** no SVHN, o mesmo modelo vai de 1,88% para 8,31% de erro, gap de 6,43% (Fig. 5) — a magnitude da degradação depende fortemente do dataset.

• **Treinar com filtragem aleatória produz o pior comportamento:** no CIFAR-10, o modelo treinado com máscara aleatória atinge 34,19% de erro no teste radial, gap de 28,29% — o maior de todos os experimentos.

• **Treinar em dados filtrados custa pouco no teste não filtrado:** modelos treinados com máscara radial ou aleatória ficam "only off by 1-2% of the best unfiltered test accuracy" (Seção 5.3), o que confirma que a filtragem preserva a informação semântica.

• **Profundidade não resolve:** "Depth does not seem to have any real effect on reducing the observed generalization gaps" (Seção 5.3) — dobrar a profundidade de 92 para 200 camadas praticamente não altera o gap.

• **Aumento de dados reduz o gap, mas os autores não o consideram solução:** o treino no conjunto aumentado leva o gap a 1,88% no CIFAR-10 e 2,93% no SVHN, mas eles argumentam que isso é "a superficial robustness to the varying image statistics", não aprendizado de abstrações.

Mecanismos Explicativos Propostos

• **Hipótese das regularidades estatísticas superficiais:** "the current incarnation of deep neural networks have a tendency to learn surface statistical regularities as opposed to high level abstractions" (Seção 6) — a CNN generaliza bem por explorar pistas superficiais compartilhadas entre treino e teste, e não por capturar semântica.

• **O espectro de Fourier como instância dessas regularidades:** como o espectro de imagens naturais obedece a uma lei de potência, com a energia concentrada nas frequências baixas e médias, é possível filtrar preservando o conteúdo perceptual — e é justamente sobre a parte filtrada que a rede se apoia.

• **Latching nas estatísticas do conjunto de treino:** "deep CNNs trained on an unfiltered natural image dataset exhibit a tendency to latch onto the image statistics of the training set, yielding a non-trivial generalization gap" (Seção 5.3).

• **Dissociação entre percepção humana e representação da máquina:** os autores verificam visualmente que "the recognizability of the objects is quite robust to the human eye" após a filtragem, e mesmo assim a rede erra em até um quarto dos casos — a mesma dissociação que motiva o nosso SLR.

• **Aumento de dados não gera abstração:** "augmenting the training set with a specific subset of adversarial examples does not make the network immune to adversarial examples in general" — por analogia, treinar com um conjunto específico de filtragens produz robustez superficial, e outra perturbação poderia expor um novo gap.

Evidência Espectral

Sim. Método: transformada discreta de Fourier bidimensional (DFT deslocada, com componente DC no centro), aplicada por canal. Representação: máscaras binárias no espaço de frequência — máscara radial M_r (preserva modos com distância euclidiana ao

centro menor ou igual a r) e máscara aleatória M_p (zera cada modo com probabilidade p). Bandas analisadas: no CIFAR-10, raio 11,0 sobre imagens 32×32; no SVHN, raio 4,25. Tipo de energia: os autores invocam a lei de potência do espectro de imagens naturais, P(w) ∝ |w|^(η−2), para justificar que a energia concentrada em baixas e médias frequências permite filtrar preservando o conteúdo perceptual. Relação encontrada com o desempenho: remover o conteúdo de alta frequência do conjunto de teste eleva o erro de 5,22% para 23,37% no CIFAR-10 — a rede depende de energia espectral que o observador humano dispensa.

Limitações Reconhecidas pelos Autores

Os autores são explícitos ao qualificar o próprio resultado positivo: reconhecem que treinar no conjunto aumentado fecha boa parte do gap, mas afirmam não acreditar que isso baste para aprender abstrações de alto nível, e que "it may be possible to generate some other perturbation of the dataset that yields a new generalization gap". Registram também que o MNIST foi excluído por sua esparsidade extrema tornar os dígitos irreconhecíveis após a filtragem, e que a escolha dos hiperparâmetros das máscaras foi calibrada visualmente para preservar a reconhecibilidade humana, sem critério objetivo.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. A filtragem espectral do conjunto de teste eleva o erro de 5,22% para 23,37% no CIFAR-10 e de 1,88% para 8,31% no SVHN, em redes treinadas com dados não filtrados.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. É a formulação canônica da hipótese de que as CNNs generalizam por aprender regularidades estatísticas superficiais do espectro do dataset, e não abstrações semânticas — mecanismo diretamente aplicável ao efeito de qualquer filtragem espectral.

• **RQ3 (Relação quantitativa):** Parcialmente relevante. A magnitude da degradação varia sistematicamente com o dataset e com o tipo de máscara, mas há um único raio de filtragem por dataset, o que impede construir uma curva de energia removida contra acurácia.

• **RQ4 (Condições de melhoria):** Relevante. Mostra que treinar com dados filtrados custa apenas 1 a 2 pontos no teste não filtrado e que o treino aumentado reduz o gap a menos de 3%, mas os próprios autores negam que isso configure ganho genuíno de abstração.

Qualidade Metodológica e Validade

Desenho experimental exemplar para os fins do nosso SLR: a manipulação é espectral e explícita, o baseline é claro, a matriz completa de generalização cruzada permite separar o efeito do domínio de treino do efeito da filtragem no teste, e a variação de profundidade funciona como controle contra a hipótese arquitetural. As limitações são a ausência de varredura de intensidade (um único raio por dataset, o que impede construir uma curva dose-resposta) e o uso de uma única família de arquitetura. É, junto com Yin et al. (2019) e Ortiz-Jiménez et al. (2020), uma das referências centrais do lote para a RQ2.

Título: Defense against Adversarial Attacks Using High-Level Representation Guided Denoiser

Autores: Liao, Liang, Dong, Pang, Hu & Zhu

Ano: 2018 | Veículo: não indicado no PDF; o trabalho reporta primeiro lugar na competição NIPS 2017 de defesas contra ataques adversários; pré-print arXiv:1712.02976

Decisão: ACEITAR

Justificativa: O artigo mede diretamente o custo do denoising sobre imagens limpas — um autoencoder denoising padrão derruba a acurácia do Inception-v3 de 76,7% para 58,3% em imagens não atacadas — e propõe um mecanismo explícito e quantificado para a degradação: o efeito de amplificação de erro, em que a perturbação residual deixada pelo denoiser cresce progressivamente ao longo da hierarquia de camadas. É evidência de primeira linha para as RQ1 e RQ2.

Resumo Geral

O trabalho parte de um paradoxo instrumental: denoisers treinados para minimizar a diferença pixel a pixel em relação à imagem limpa conseguem reduzir drasticamente essa distância e ainda assim não recuperam a classificação correta. Os autores diagnosticam a causa medindo a perturbação relativa camada a camada no modelo alvo, E_l = ||f_l(x_p) − f_l(x)|| / ||f_l(x)||, e mostram que a perturbação residual do denoiser guiado por pixel (PGD), embora pequena na entrada, é amplificada ao longo da rede até atingir, na camada superior, um nível próximo ao da perturbação adversária original. A solução proposta, HGD, substitui a perda em espaço de pixels por uma perda definida sobre as ativações de alto nível do modelo alvo. As variantes FGD, LGD e CGD suprimem a amplificação e reduzem a perda de acurácia em imagens limpas para 0,5 ponto percentual.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Arquiteturas dos denoisers (DAE e DUNET), definição formal das três variantes de perda, conjuntos de treino e teste (WhiteTestSet e BlackTestSet, 40 mil imagens cada) e modelo alvo descritos nas Seções 3 a 5.

2. Utiliza baseline sem pré-processamento para comparação	Sim	A coluna "Clean" das Tabelas 2 e 3 e a linha "NA" (sem defesa) constituem baseline duplo: sem pré-processamento e sem ataque.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Acurácia de classificação e perda de denoising (distância L1) para 3 métodos × 5 condições (Tabela 2) e 6 defesas × 5 condições (Tabela 3).
4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Arquiteturas e perdas descritas; hiperparâmetros de treino resumidos (30 mil imagens limpas, menos de 30 épocas sobre 210 mil imagens adversárias); resultados detalhados por ataque remetidos ao material suplementar.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	O efeito de amplificação de erro é diagnosticado com uma métrica própria, medido camada a camada (Fig. 5) e usado para explicar a inconsistência entre

		perda de denoising e acurácia.
6. Realiza análise no domínio da frequência / espectral	Não	Nenhuma transformada nem análise de bandas; a análise é feita no espaço de ativações, não no domínio da frequência.
7. Avalia mais de um dataset	Não	Apenas ImageNet (subconjuntos construídos pelos autores).
8. Avalia mais de uma arquitetura/modelo	Sim	Inception-v3 como alvo principal; transferibilidade testada para ResNet, Inception-ResNet-v2 e ensV3; comparação entre DAE, DUNET, PGD, FGD, LGD e CGD.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Reconhecem a inconsistência entre a métrica de denoising e a acurácia como uma limitação conceitual das abordagens por pixel, mas não há seção formal

		de ameaças à validade.
10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF; reportam vitória na competição NIPS 2017.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Não	Nem código nem dados liberados no PDF.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Denoising, Outra	Denoising como pré-processamento: autoencoder denoising convencional (DAE), U-Net denoising (DUNET) treinada com perda em espaço de pixels (PGD), e três variantes guiadas por representação de alto nível — FGD (ativações de camada intermediária), LGD (ativações da camada superior) e CGD (logits/classificação).

Arquitetura(s)	Outra	Inception-v3 como modelo alvo padrão; ResNet e Inception-ResNet-v2 usados nos testes de transferibilidade; ensV3 (treino adversário em ensemble) como linha de comparação.
Dataset(s)	ImageNet	Conjuntos construídos pelos autores a partir do ImageNet: WhiteTestSet e BlackTestSet, com 40.000 imagens cada; treino do denoiser com apenas 30.000 imagens limpas e 210.000 imagens adversárias, contra 1,2 milhão de imagens usadas para treinar o ensV3.
Métrica(s) de desempenho	Acurácia, Outra	Acurácia de classificação; perda de denoising medida como distância L1 entre a imagem de entrada e a imagem restaurada; perturbação relativa por camada E_l como métrica diagnóstica.

Análise de frequência/espectral?	Não	Nenhuma análise espectral.
Intensidade em múltiplos níveis?	Sim	Duas magnitudes de perturbação adversária (ε = 4 e ε = 16) em cada conjunto de teste.
Múltiplas arquiteturas?	Sim	Inception-v3, ResNet, Inception-ResNet-v2 e ensV3, além de seis configurações de denoiser.
Código/Dados públicos?	Não	Nem código nem dados.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Denoising padrão degrada fortemente imagens limpas:** o autoencoder denoising (DAE) derruba a acurácia do Inception-v3 de 76,7% para 58,3% sobre imagens não atacadas — 18,4 pontos percentuais perdidos sem que houvesse qualquer ataque (Tabela 2). Os autores registram: "DAE does not perform well on encoding the high-resolution images, as its accuracy on clean images significantly drops".

• **Mesmo um bom denoiser cobra um preço nas imagens limpas:** "DUNET slightly decreases the accuracy of clean images, but significantly improves the robustness of the target model to black-box attacks" — de 76,7% para 75,3% (Tabela 2).

• **Menor erro de reconstrução não implica melhor classificação:** "the denoising loss and classification accuracy of PGD are not so consistent. For white-box attacks, DUNET has much lower denoising loss than DAE, but its classification accuracy is significantly worse" (Seção 5.1) — 13,8% contra 36,7% em ε = 16.

• **Guiar a perda pela representação de alto nível quase elimina o custo nas imagens limpas:** LGD reduz a acurácia limpa em apenas 0,5 ponto (76,2% contra 76,7%) e supera consistentemente PGD e ensV3 em todos os tipos de ataque (Tabela 3).

• **Sob ataque, o pré-processamento melhora de forma expressiva:** no BlackTestSet com ε = 16, a acurácia sobe de 41,0% (sem defesa) para 55,7% (PGD) e 72,2% (LGD).

Mecanismos Explicativos Propostos

• **Efeito de amplificação de erro:** "Standard denoiser suffers from the error amplification effect, in which small residual adversarial noise is progressively amplified and leads to wrong classifications" (Resumo) — é o mecanismo central proposto pelo artigo.

• **Medição direta da amplificação camada a camada:** a perturbação relativa E_l(x_p, x) = ||f_l(x_p) − f_l(x)|| / ||f_l(x)|| mostra que "Although the pixel-level PGD perturbation significantly suppressed, the remaining perturbation is progressively amplified along the layer hierarchy. At the top layer, PGD perturbation is much higher than random perturbation and close to adversarial perturbation" (Seção 5.1, Fig. 5).

• **Explicação da inconsistência entre métrica de qualidade e desempenho:** "Because the classification result is closely related to the top-level features, this large perturbation well explains the inconsistency between the denoising performance and classification accuracy of PGD" — resultado de interesse direto para o SLR, pois mostra por que otimizar qualidade perceptual não otimiza acurácia.

• **Ruído residual estruturado difere de ruído aleatório:** a perturbação residual do denoiser é amplificada muito mais do que ruído gaussiano de magnitude comparável, o que indica que o resíduo mantém estrutura alinhada às direções sensíveis do modelo.

• **Alinhar o objetivo do pré-processamento ao do classificador resolve:** definir a perda sobre ativações de alto nível "strongly suppress the error amplification effect" (Seção 5.2), colocando a perturbação final próxima do nível de ruído aleatório.

Evidência Espectral

Não. O artigo não realiza análise no domínio da frequência. A análise mecanística é feita no espaço de ativações da rede (perturbação relativa por camada), o que é uma alternativa complementar, e não equivalente, à análise espectral prevista nas RQ2 e RQ3.

Limitações Reconhecidas pelos Autores

Os autores reconhecem que a perda em espaço de pixels é intrinsecamente inadequada como objetivo para uma etapa de pré-processamento que antecede um classificador, e que a solução proposta depende do modelo alvo (embora demonstrem transferibilidade parcial para outras arquiteturas). Não há seção formal de ameaças à validade, nem avaliação sob ataques adaptativos que conheçam o denoiser. Os resultados por ataque individual são remetidos ao material suplementar.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Quantifica o custo do denoising sobre imagens limpas com baseline explícito: queda de 76,7% para 58,3% com um autoencoder denoising padrão e de 76,7% para 75,3% com uma U-Net bem treinada.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Propõe e mede o efeito de amplificação de erro, mostrando com uma métrica de perturbação por camada que o resíduo deixado pelo pré-processamento cresce ao longo da hierarquia até dominar as características de topo.

• **RQ3 (Relação quantitativa):** Parcialmente relevante. A relação quantificada é entre perturbação relativa por camada e acurácia, e não entre energia espectral e acurácia; a Figura 5 é uma curva de amplificação, não de dose espectral.

• **RQ4 (Condições de melhoria):** Altamente relevante. Estabelece uma condição de projeto muito precisa: o pré-processamento só é benigno quando sua função-objetivo é definida sobre as representações de alto nível do classificador, e não sobre a fidelidade em espaço de pixels.

Qualidade Metodológica e Validade

Do ponto de vista do nosso SLR, este é um dos artigos mais valiosos do lote, ainda que sua motivação seja a defesa adversária: ele quantifica o custo do denoising sobre imagens limpas, mostra que métricas de qualidade de restauração e acurácia de classificação podem divergir em sentido oposto, e oferece um mecanismo mensurável (a amplificação de erro por camada) para essa divergência. As fraquezas são a ausência de análise espectral, o uso de um único dataset e a não disponibilização de código.

Título: Deflecting Adversarial Attacks with Pixel Deflection

Autores: Prakash, Moran, Garber, DiLillo & Storer

Ano: 2018 | Veículo: não indicado no PDF (pré-print arXiv:1801.08926)

Decisão: ACEITAR

Justificativa: O artigo propõe uma transformação de entrada composta por corrupção local de pixels seguida de denoising por limiarização suave de coeficientes wavelet (BayesShrink), e mede a acurácia top-1 resultante em vários classificadores, incluindo sobre imagens limpas. Além dos números, é uma das formulações mais explícitas na literatura do problema central do nosso SLR: defesas por transformação da entrada degradam a acurácia sobre imagens não degradadas porque a quantização remove sinal junto com o ruído.

Resumo Geral

Os autores propõem processar a imagem de entrada de modo a preservar a classificação correta na presença de manipulações adversárias, sem retreinar nem modificar a CNN. O método tem duas etapas: a deflexão de pixels, que substitui aleatoriamente valores de pixel por valores de vizinhos dentro de uma janela (guiada por mapas de saliência de classe, de modo a corromper preferencialmente regiões pouco relevantes), e o denoising wavelet, que

projeta a imagem na base wavelet db1, aplica limiarização suave com limiar adaptativo BayesShrink e reconstrói. A corrupção introduzida pela deflexão tem conteúdo de frequência improvável para imagens naturais, e por isso é removida pela limiarização junto com parte da perturbação adversária. Os experimentos usam 1000 imagens do conjunto de validação do ImageNet e ResNet-50 como classificador principal, com resultados adicionais para outras arquiteturas.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	As duas etapas da transformação são descritas com pseudocódigo e equações, os três hiperparâmetros (σ, tamanho da janela r e número de deflexões K) e o procedimento de busca são explicitados nas Seções 5 a 9.
2. Utiliza baseline sem pré-processamento para comparação	Parcialmente	Há linha "Clean" nas tabelas, mas o protocolo restringe a avaliação às imagens já classificadas corretamente antes do ataque, de modo que o baseline sem defesa é fixado em 100% por construção; a acurácia original do ResNet-50 no subconjunto (76%) é reportada separadamente.

3. Reporta métricas quantitativas de classificação de forma clara	Sim	Acurácia top-1 tabulada para 7 condições × 3 configurações (Tabelas 1 e 2) e para várias arquiteturas (Tabela 3); comparação entre esquemas de limiarização (Tabela 6).
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Algoritmo com pseudocódigo, base wavelet (db1, com verificação em db2 e haar), limiar BayesShrink, hiperparâmetros finais (σ = 0,04; janela = 10; deflexões = 100) e busca linear em 300 imagens separadas; os autores anunciam liberação do código.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	Explicam por que a quantização do JPEG remove sinal junto com o ruído, por que wavelets são preferíveis a blocos DCT para essa tarefa e por que a corrupção por deflexão é removível.

6. Realiza análise no domínio da frequência / espectral	Parcialmente	O raciocínio é conduzido em termos de conteúdo de frequência e de regularidades da resposta wavelet de imagens naturais, mas nenhum espectro é calculado nem energia por banda é medida.
7. Avalia mais de um dataset	Não	Apenas ImageNet (subconjuntos de 300, 1000 e 10.000 imagens).
8. Avalia mais de uma arquitetura/modelo	Sim	ResNet-50 no corpo do artigo; Tabela 3 reporta resultados para várias arquiteturas, todas com pesos do repositório do TensorFlow.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Discutem que uma configuração ótima para um ataque não é ótima para outro e que a variância cresce com K e r, mas não há seção formal de ameaças à validade.

10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Parcialmente	Hiperparâmetros completos e anúncio de liberação do código ("We will publicly release our implementation code"), mas sem repositório indicado no PDF.

Extração de Dados

Campo do SLR	Valor Extraído	Detalhes
Técnica(s) de pré-processamento	Denoising, Compressão JPEG (discutida), Outra	Denoising wavelet: transformada wavelet discreta com base db1 (verificada também com db2 e haar), limiarização suave com limiar adaptativo BayesShrink modelado por Distribuição Gaussiana Generalizada; comparação com VisuShrink e SUREShrink. Pré-etapa de deflexão de pixels (substituição aleatória por vizinho em janela r, K vezes, guiada por mapas de

		saliência de classe). A compressão JPEG é discutida como alternativa e criticada.
Arquitetura(s)	ResNet, Outra	ResNet-50 como classificador principal (pesos do repositório do TensorFlow, 76% top-1 nas imagens selecionadas); resultados adicionais para outras arquiteturas na Tabela 3.
Dataset(s)	ImageNet	1000 imagens selecionadas aleatoriamente do conjunto de validação para os resultados principais; 300 imagens separadas para busca de hiperparâmetros; 10.000 imagens (todas as 1000 classes, mínimo 3 por classe) em experimento complementar.
Métrica(s) de desempenho	Acurácia	Acurácia top-1, reportada em configuração única e em ensemble de 10 execuções (Ens-10), dada a natureza estocástica da deflexão.

Análise de frequência/espectral?	Parcialmente	Sem transformada de Fourier nem medição de energia; a análise usa a base wavelet e argumentos sobre o conteúdo de frequência da corrupção introduzida.
Intensidade em múltiplos níveis?	Sim	Busca linear sobre $\sigma \in \{0,03; 0,04; 0,05\}$, janela $\in \{5, 10, 50, 100\}$ e número de deflexões, com curvas de acurácia por configuração (Fig. 5); perturbações avaliadas em dois regimes de magnitude L2.
Múltiplas arquiteturas?	Sim	Tabela 3 compara várias arquiteturas de classificador.
Código/Dados públicos?	Não informado	Código anunciado como futuro, sem repositório no PDF.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **O pré-processamento cobra um preço mesmo nas imagens limpas:** sobre o subconjunto de imagens corretamente classificadas antes de qualquer ataque (100% por construção), aplicar deflexão de pixels e denoising wavelet reduz a acurácia para 98,3% em execução única e 98,9% em ensemble de 10 (Tabela 1); na Tabela 2, 98,1% e 98,9%.

• **Sob ataque, o ganho é grande:** com parâmetros σ = 0,04, janela 10 e 100 deflexões, a acurácia sobe de 20,0% para 79,9% sob FGSM, de 14,1% para 83,7% sob IGSM, de 26,3% para 86,3% sob DeepFool, de 25,5% para 91,5% sob JSMA, de 12,1% para 88,0% sob L-BFGS e de 4,8% para 92,7% sob C&W (Tabela 1).

• **O benefício cai com a magnitude da perturbação:** no bloco de "Large perturbations" da Tabela 1, com |L2| entre 0,04 e 0,12, a recuperação sob FGSM é de 11,1% para 61,5% (execução única), abaixo dos 79,9% obtidos com perturbações pequenas.

• **O custo sobre imagens limpas é o obstáculo reconhecido da literatura:** "The biggest obstacle facing most transformation-based defenses is that the transformation degrades the quality of non-adversarial images, leading to a loss of accuracy. This has limited the success of transformations as a practical defense" (Seção 4).

• **O JPEG é apontado como caso exemplar desse custo:** "it is unsurprising that JPEG compression recovers correct classification on some of the adversarial images but also reduces the classification accuracy on clean images"; os autores citam Dziugaite et al. como fonte de uma perda de 8% de acurácia em imagens limpas após compressão JPEG (Seção 7).

Mecanismos Explicativos Propostos

• **Quantização remove sinal junto com o ruído:** "the quantization process in JPEG uses fixed tables that are agnostic to image content, and it quantizes responses at all amplitudes while the important image features generally correspond to large frequency responses. This quantization reduces noise but also gets rid of some of the signal" (Seção 7) — enunciado direto do mecanismo central do nosso SLR.

• **Escolha da base como forma de limitar o dano:** os autores buscam "filters with frequency response better suited to joint space-frequency analysis than the DCT blocks (and more closely matching representations in the early ventral stream, so that features which have a small filter response are less perceptible)", isto é, escolhem a transformação de modo a que o que é descartado seja perceptualmente e discriminativamente menos relevante.

• **Limiar adaptativo por imagem em vez de tabela fixa:** o BayesShrink modela cada coeficiente por uma Distribuição Gaussiana Generalizada e adapta o limiar à quantidade de ruído presente na imagem, o que reduz a remoção de sinal em imagens já limpas — mecanismo que explica por que a perda no baseline limpo é de menos de dois pontos percentuais.

• **A corrupção introduzida é escolhida para ser removível:** "Swapping pixels within a window will tend to add noise with unlikely frequency content to the image", de modo que a limiarização wavelet a elimina; a perturbação adversária, que compartilha parte desse conteúdo, é removida por arrasto.

• **Nem toda a perturbação adversária é de alta frequência:** "While the noise introduced by dropping a pixel is mostly high-frequency, the same cannot be said about the adversarial perturbations" (Seção 7) — ressalva importante contra a leitura simplista de que perturbações relevantes seriam sempre de alta frequência.

Evidência Espectral

Parcialmente. Não há transformada de Fourier nem medição de energia por banda, mas toda a operação de denoising é feita no domínio wavelet (base db1, com verificação em db2 e haar), que é uma representação conjunta espaço-frequência, e a justificativa metodológica do artigo é integralmente formulada em termos de conteúdo de frequência: por que a base wavelet é preferível aos blocos DCT do JPEG, por que a corrupção da deflexão é removível e por que a quantização de amplitude descarta sinal. A comparação entre esquemas de limiarização (BayesShrink, VisuShrink, SUREShrink) na Tabela 6 é, na prática, uma comparação entre políticas de descarte de energia.

Limitações Reconhecidas pelos Autores

Os autores reconhecem que uma configuração de hiperparâmetros ótima para um modelo de ataque não é ótima para outro, porque ataques distintos minimizam normas L_p distintas e produzem tipos de ruído distintos, e por isso adotam deliberadamente um único conjunto de parâmetros para todos os ataques. Registram que a variância da acurácia cresce com o número de deflexões e o tamanho da janela, dada a natureza estocástica do método. Reconhecem também que perturbações adversárias não são exclusivamente de alta frequência e que várias técnicas de detecção falham, citando Carlini e Wagner.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Relevante. Mede o custo do pré-processamento sobre imagens limpas (queda para 98,3% em execução única sobre o subconjunto corretamente classificado) e enuncia esse custo como o obstáculo central das defesas por transformação.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Explica por que a quantização remove sinal junto com o ruído, por que tabelas fixas agnósticas ao conteúdo (JPEG) são piores que limiares adaptativos por imagem (BayesShrink), e ressalva que perturbações relevantes não são exclusivamente de alta frequência.

• **RQ3 (Relação quantitativa):** Parcialmente relevante. A busca de hiperparâmetros produz curvas de acurácia contra o parâmetro de limiarização σ, que é um proxy da quantidade de energia descartada, mas nenhuma energia é efetivamente medida.

• **RQ4 (Condições de melhoria):** Altamente relevante. Mostra que o custo sobre imagens limpas pode ser reduzido a menos de dois pontos percentuais quando a transformação usa uma base adequada (wavelet em vez de blocos DCT) e um limiar adaptado à imagem em vez de uma tabela fixa.

Qualidade Metodológica e Validade

Para o nosso SLR, o valor deste artigo está menos no método proposto e mais nas suas seções 3, 4 e 7, que constituem uma das melhores formulações disponíveis do problema que investigamos: transformações de entrada projetadas para melhorar qualidade ou remover ruído descartam, junto, informação que o classificador usa. O trabalho quantifica esse custo (cerca de 1,7 ponto percentual sobre imagens limpas, com uma técnica desenhada especificamente para minimizá-lo) e explica por que ele existe. As limitações são a ausência de análise espectral quantitativa, o uso de um único dataset e a definição do baseline limpo como 100% por construção do protocolo, o que exige leitura cuidadosa dos números.

Título: Effects of Degradations on Deep Neural Network Architectures

Autores: Roy, Ghosh, Bhattacharya & Pal

Ano: Primeira versão 2018; versão v6 do pré-print datada de 2025 | Veículo: não indicado no PDF (pré-print arXiv:1807.10108)

Decisão: ACEITAR

Justificativa: É o estudo mais sistemático do lote na dimensão arquitetura × degradação: seis arquiteturas avaliadas contra seis modelos de degradação, cada um varrido em múltiplos níveis de intensidade, sobre dois datasets, com baseline sem degradação. Além da evidência empírica ampla para a RQ1, os autores investigam o mecanismo (relacionando robustez à profundidade da rede via SSIM dos mapas de características) e afirmam explicitamente que inferir sobre imagens submetidas a denoising prejudica fortemente a acurácia de um modelo treinado em imagens limpas — enunciado direto da hipótese do nosso SLR.

Resumo Geral

O trabalho compara VGG-16, VGG-19, ResNet-50, Inception-v3, MobileNet e CapsuleNet sob seis modelos de degradação: ruído gaussiano branco, ruído gaussiano colorido, sal-e-pimenta, blur gaussiano, blur de movimento e compressão JPEG. O protocolo é uniforme: cada rede é treinada apenas com o conjunto de treino limpo e depois avaliada repetidamente sobre versões progressivamente degradadas do conjunto de validação. Dois datasets são compilados pelos autores — um de dígitos sintéticos (12 mil imagens, 10 classes, com numerais renderizados em 16 fontes sobre fundos do COCO) e um de imagens naturais de alta resolução (6899 imagens, 8 classes). O achado principal é que a robustez decresce com a profundidade da arquitetura, hipótese que os autores testam medindo o SSIM dos mapas de características da última camada convolucional com e sem ruído. Propõem em seguida uma camada não-treinável-treinável (NTT), cuja parte fixa é um filtro passa-baixa, e mostram que ela troca acurácia no baseline limpo por robustez.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Seis arquiteturas, seis modelos de degradação com faixas e passos explicitados, dois datasets compilados pelos autores e ajustes arquiteturais para comparação

		justa descritos nas Seções III e IV.
2. Utiliza baseline sem pré-processamento para comparação	Sim	Todas as redes são treinadas com o conjunto limpo e o ponto de degradação nula é a origem de todas as curvas (Figs. 3 a 5, 7, 10 e 11).
3. Reporta métricas quantitativas de classificação de forma clara	Parcialmente	Acurácia de validação e top-3 reportadas, porém quase inteiramente em figuras; poucos valores numéricos aparecem no texto (por exemplo, 99,83% do V-CapsNet e a troca de 6% de acurácia base por até 68% de ganho de robustez).
4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Arquiteturas, faixas de degradação e ajustes descritos; código público; mas os resultados por nível não são tabelados.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	Formulam e testam a hipótese de que a robustez depende da profundidade, medindo a variação do SSIM

		dos mapas de características da última camada convolucional (Fig. 8).
6. Realiza análise no domínio da frequência / espectral	Não	Nenhuma transformada; o filtro passa-baixa da camada NTT é usado como componente arquitetural, não como instrumento de análise espectral.
7. Avalia mais de um dataset	Sim	Dígitos sintéticos (12.000 imagens, 10 classes) e imagens naturais (6899 imagens, 8 classes).
8. Avalia mais de uma arquitetura/modelo	Sim	VGG-16, VGG-19, ResNet-50, Inception-v3, MobileNet, CapsuleNet, além do V-CapsNet proposto e das variantes com camada NTT.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Reconhecem que a robustez adversária não se correlaciona com a robustez a degradações e que a camada NTT torna os modelos mais fáceis de atacar, mas não há

		seção formal de ameaças à validade.
10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Somente código	github.com/prasunroy/cnn-on-degraded-images

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Suavização/Blur, Compressão JPEG, Denoising (discutido), Outra	Ruído gaussiano branco e colorido (σ de 0 a 1, passo 0,1); sal-e-pimenta (densidade d de 0 a 1, passo 0,1); blur gaussiano (kernel k_g de 3×3 a 51×51, passo 2, com σ_g = 0,3·((k_g−1)·0,5−1)+0,8); blur de movimento horizontal (kernel k_m de 1×1 a 31×31, passo 2); compressão JPEG (qualidade q de 30 a 0, passo 2). Como componente de defesa, camada NTT com filtro passa-baixa não-treinável

		seguido de filtro treinável, ambos depthwise.
Arquitetura(s)	VGG, ResNet, CNN rasa / Custom CNN, Outra	VGG-16, VGG-19, ResNet-50, Inception-v3, MobileNet, CapsuleNet (com uma e três iterações de roteamento dinâmico) e V-CapsNet, arquitetura de fusão proposta que substitui as camadas iniciais da CapsuleNet pelas da VGG-19.
Dataset(s)	Synthetic Digits (compilado pelos autores); Natural Images (compilado pelos autores)	Dígitos sintéticos: 12.000 imagens (10.000 de treino, 2.000 de validação), 10 classes, numerais em 16 fontes com cor, rotação (−30° a +30°) e tamanho (30 a 240 px) aleatórios sobre fundos do COCO. Imagens naturais: 6899 imagens de alta resolução (5724 de treino, 1175 de validação) em 8 classes (aviões, carros, gatos, cães, flores, frutas, motos, pessoas).

Métrica(s) de desempenho	Acurácia, Outra	Acurácia de validação e acurácia top-3; SSIM dos mapas de características como métrica diagnóstica; PSNR das imagens perturbadas e ε do FGSM na análise adversária.
Análise de frequência/espectral?	Não	Nenhuma análise espectral.
Intensidade em múltiplos níveis?	Sim	Todos os seis modelos de degradação são varridos em faixas com passo definido (11 níveis de ruído, 25 níveis de blur gaussiano, 16 de blur de movimento, 16 de qualidade JPEG).
Múltiplas arquiteturas?	Sim	Seis arquiteturas base mais V-CapsNet e as variantes com camada NTT.
Código/Dados públicos?	Somente código	github.com/prasunroy/cnn-on-degraded-images

Efeito sobre a Acurácia

Direção do efeito: Piora

• **Todas as arquiteturas degradam monotonicamente com a intensidade:** "The experimental results show decreasing classification accuracy for every CNN architecture with the increasing variance of the additive Gaussian noise"; na conclusão, "every network follows a general trend of decreasing recognition rate with gradually increasing noise" (Seções IV-A e VI).

• **Blur degrada todas as CNNs, com vantagem das arquiteturas mais rasas:** "Both Gaussian blur and motion blur degrade the performance of CNNs. However, VGG networks generally perform better than deeper architectures such as ResNet, Inception and MobileNet" (Seção IV-A).

• **A compressão JPEG tem limiar de tolerância:** "JPEG compression does not exhibit any significant degradation of classification accuracy for the networks when the quality parameter q > 20, as the visible structure of the images remains nearly unaltered"; abaixo desse limiar, ResNet e MobileNet caem abruptamente enquanto VGG, Inception e CapsuleNet resistem melhor (Seção IV-A).

• **Profundidade compra acurácia limpa e paga em robustez:** o V-CapsNet atinge 99,83% de acurácia de validação no dataset de imagens naturais, 6,2 pontos acima da CapsuleNet base, mas "the performance sharply falls below the baseline CapsuleNet with increasing noise" (Seção IV-B).

• **Robustez arquitetural custa acurácia no baseline limpo:** "introducing the NTT layer in VGG-19 trades off 6% baseline accuracy in favor of up to 68% improvement in the presence of Gaussian color and salt-and-pepper noise" (Seção V-A) — um compromisso quantificado e controlável.

• **Robustez a degradação e robustez adversária são independentes:** "the performance of a network against adversarial attacks does not correlate to its robustness against image degradation models" (Seção V-B).

Mecanismos Explicativos Propostos

• **Denoising modifica detalhes estruturais sutis e prejudica a inferência:** "When we train a network with standard good-quality image samples but attempt to perform inference on denoised images, the recognition accuracy is heavily affected as several subtle structural details get modified during denoising" (Seção V-A) — enunciado explícito do fenômeno investigado pelo nosso SLR.

• **Profundidade como fator causal da sensibilidade:** "we believe the noise robustness is related to the depth of the network. Apparently, Deeper networks are more sensitive to image degradations" (Seção IV-B); o V-CapsNet é o teste dessa hipótese, pois difere da CapsuleNet base apenas pelo aumento de profundidade.

• **Evidência quantitativa via estabilidade dos mapas de características:** os autores medem o SSIM entre os mapas de características da última camada convolucional com e sem ruído na entrada, e observam que "the change in SSIM is found to be much slower for baseline CapsuleNet than V-CapsNet" (Fig. 8) — a degradação da representação interna acompanha a degradação da acurácia.

• **Filtragem passa-baixa como forma de induzir invariância a artefatos:** a camada NTT é motivada por "learn the invariance toward subtle changes introduced by noising and denoising"; o custo dessa invariância é medido como perda de acurácia no baseline limpo.

• **Diferença de sensibilidade por tipo de degradação:** a CapsuleNet é notavelmente robusta a sal-e-pimenta e a blur, mas não a ruído gaussiano de alta variância, o que indica que a sensibilidade depende do casamento entre a estrutura da degradação e a representação aprendida, e não apenas da magnitude da alteração.

Evidência Espectral

Não. Nenhuma transformada é calculada e nenhuma banda é analisada. O único elemento espectral do trabalho é operacional: a camada NTT proposta usa como parte não-treinável os pesos de um filtro passa-baixa, e a melhoria de robustez obtida com ela é evidência indireta, no plano arquitetural, de que suprimir alta frequência antes das camadas convolucionais aumenta a estabilidade sob degradação ao custo de acurácia limpa.

Limitações Reconhecidas pelos Autores

Os autores reconhecem que incluir amostras degradadas no treino tem limitações práticas, pois o espaço de modelos de ruído possíveis é grande demais e kernels de borramento não-lineares são difíceis de sintetizar, e por isso preferem soluções arquiteturais. Registram que a camada NTT, embora aumente a robustez a degradações, torna os modelos mais fáceis de atacar adversarialmente, ainda que os ataques passem a produzir distorções visualmente perceptíveis (queda acentuada do PSNR). Reconhecem também que a robustez adversária e a robustez a degradações não se correlacionam. Não há seção formal de ameaças à validade.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. É o estudo de maior amplitude do lote: seis arquiteturas × seis degradações × múltiplos níveis × dois datasets, todos com baseline de treino limpo, com degradação monotônica em todos os casos.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Afirma explicitamente que a inferência sobre imagens submetidas a denoising é fortemente prejudicada porque detalhes estruturais sutis são modificados, e sustenta a hipótese da profundidade com medição de SSIM dos mapas de características.

• **RQ3 (Relação quantitativa):** Relevante. As curvas cobrem faixas amplas com passo definido (por exemplo, 25 níveis de blur gaussiano), permitindo leitura da dose-resposta; a limitação é que os valores estão apenas em figuras e não há medição de energia espectral.

• **RQ4 (Condições de melhoria):** Altamente relevante. Quantifica o compromisso de forma incomum na literatura: a camada NTT com filtro passa-baixa troca 6% de acurácia base por até 68% de ganho de robustez, e os autores registram que esse compromisso é controlável pela profundidade e pelo tamanho do filtro.

Qualidade Metodológica e Validade

A maior contribuição metodológica do artigo para o nosso SLR é a amplitude controlada: seis arquiteturas, seis degradações, múltiplos níveis, dois datasets e protocolo uniforme de

treino limpo com avaliação degradada. Os pontos fracos são a apresentação quase exclusivamente gráfica dos resultados, o que impede a extração de valores precisos, e a ausência de qualquer análise espectral. O compromisso quantificado entre acurácia limpa e robustez (6% de acurácia base por até 68% de ganho de robustez) e a afirmação explícita sobre o custo do denoising na inferência são os dois achados mais diretamente aproveitáveis.

Título: Benchmarking Neural Network Robustness to Common Corruptions and Perturbations

Autores: Hendrycks & Dietterich

Ano: 2019 | Veículo: ICLR 2019 (International Conference on Learning Representations) — indicado no cabeçalho do PDF

Decisão: ACEITAR

Justificativa: Além de estabelecer o benchmark ImageNet-C, que fixa o vocabulário de degradações usado por boa parte da literatura posterior, o artigo contém dois experimentos de pré-processamento diretamente pertinentes ao nosso SLR e com baseline explícito: o denoising por Non-Local Means piora a robustez (mCE de 76,7% para 82,1%) e a equalização adaptativa de histograma (CLAHE) a melhora (mCE de 76,7% para 74,5%, com queda de erro limpo de 23,87% para 23,55%). O apêndice fornece ainda a explicação mecanística da falha do denoising.

Resumo Geral

O artigo estabelece dois benchmarks de robustez para classificadores de imagem. O ImageNet-C aplica 15 tipos de corrupção (agrupados em ruído, blur, clima e digital), cada um em cinco níveis de severidade, ao conjunto de validação do ImageNet, e resume o desempenho na métrica mCE (erro médio de corrupção, normalizado pelo erro da AlexNet). O ImageNet-P mede a estabilidade da predição sob sequências de perturbações leves. Os autores comparam arquiteturas de AlexNet a ResNeXt e concluem que houve pouca melhora em robustez relativa ao longo dessa evolução, e testam uma série de intervenções para aumentar a robustez. Entre elas estão duas etapas clássicas de pré-processamento de imagem — restauração por denoising e equalização de histograma — cujos resultados opostos são particularmente informativos para o nosso SLR.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**

1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Definição formal do mCE e do CE, 15 corrupções em 5 severidades, protocolo de avaliação e detalhes de cada intervenção descritos nas Seções 3 a 5 e no Apêndice F.
2. Utiliza baseline sem pré-processamento para comparação	Sim	ResNet-50 sem qualquer pré-processamento (erro limpo 23,87%, mCE 76,7%) é o baseline de todas as comparações.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Tabela 1 reporta erro limpo, mCE e erro por tipo de corrupção para várias arquiteturas; valores numéricos exatos das intervenções no texto e no Apêndice F.
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Benchmarks liberados publicamente; procedimento de fine-tuning das intervenções (cinco épocas) e faixas de hiperparâmetros descritos.

5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	O Apêndice F oferece explicações causais para cada falha de robustez, incluindo o motivo pelo qual o denoising piora o desempenho.
6. Realiza análise no domínio da frequência / espectral	Não	Não há análise no domínio da frequência; as corrupções são caracterizadas por categoria semântica (ruído, blur, clima, digital), não por conteúdo espectral.
7. Avalia mais de um dataset	Sim	ImageNet-C, ImageNet-P, e versões correspondentes de CIFAR e Tiny ImageNet; ImageNet-22K no experimento de robustez a subtipos.
8. Avalia mais de uma arquitetura/modelo	Sim	AlexNet, VGG (com e sem BatchNorm), ResNet, DenseNet, ResNeXt, CondenseNet, MSDNet, Multigrid.

9. Discute limitações metodológicas ou ameaças à validade	Sim	O Apêndice F é dedicado a "informative failures", e os autores enfatizam que o próprio benchmark precisará evoluir para evitar sobreajuste ao conjunto de corrupções.
10. Publicado em veículo revisado por pares	Sim	ICLR 2019, conferência com revisão por pares.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Código e dados	Os benchmarks ImageNet-C e ImageNet-P são publicados como datasets de acesso aberto, junto com o código de geração das corrupções.

Extração de Dados

Campo do SLR	Valor Extraído	Detalhes

Técnica(s) de pré-processamento	Denoising, Equalização de histograma, Suavização/Blur, Compressão JPEG	Como intervenções de pré-processamento: restauração por Non-Local Means com quantidade de denoising determinada pela estimativa de ruído de Donoho e Johnstone; equalização adaptativa de histograma com limite de contraste (CLAHE). Como corrupções avaliadas: ruído gaussiano, shot e impulsivo; blur de desfoque, de vidro fosco, de movimento e de zoom; neve, geada, névoa, brilho; contraste, elástico, pixelização e compressão JPEG — 15 tipos em 5 severidades.
Arquitetura(s)	AlexNet, ResNet, VGG, Outra	AlexNet, VGG-11/19 (com e sem BatchNorm), ResNet-18/50, DenseNet-121/161, ResNeXt-50/101, CondenseNet, MSDNet e redes Multigrid.

Dataset(s)	ImageNet (ILSVRC 2012) / ImageNet-C / ImageNet-P; CIFAR-10-C; Tiny ImageNet-C; ImageNet-22K	ImageNet-C: conjunto de validação do ImageNet (1000 classes) com 15 corrupções × 5 severidades. ImageNet-P: sequências de perturbações leves para medir estabilidade da predição. ImageNet-22K usado para o experimento de robustez a subtipos.
Métrica(s) de desempenho	Acurácia, Outra	Erro de classificação limpo; erro de corrupção (CE) e erro médio de corrupção (mCE), normalizados pelo desempenho da AlexNet; mCE relativo; taxa média de mudança de predição (mFR) e distância top-5 (mT5D) no ImageNet-P.
Análise de frequência/espectral?	Não	Sem análise espectral.

Intensidade em múltiplos níveis?	Sim	Cada uma das 15 corrupções é avaliada em cinco níveis de severidade; as intervenções de pré-processamento são avaliadas em configuração única.
Múltiplas arquiteturas?	Sim	Comparação sistemática de arquiteturas de AlexNet a ResNeXt-101.
Código/Dados públicos?	Código e dados	Benchmarks e código de geração publicados.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Denoising piora a robustez global:** "We found that denoising increased the mCE from 76.7% to 82.1%" (Apêndice F) — a restauração por Non-Local Means, aplicada como pré-processamento, torna o classificador globalmente pior, apesar de melhorar sob ruído.

• **Equalização adaptativa de histograma melhora, e melhora inclusive o erro limpo:** "The ResNet-50 has a 23.87% error rate, but ResNet-50 with CLAHE has an error rate of 23.55%… The ResNet-50 without CLAHE preprocessing has an mCE of 76.7%, while with CLAHE the ResNet-50's mCE decreases to 74.5%" (Seção 5.2).

• **A diferença entre os dois casos é qualitativa, não de grau:** "Unlike our image denoising attempt (Appendix F), CLAHE reduces the effect of some corruptions while not worsening performance on most others" — o critério que separa melhoria de degradação é se a técnica remove informação ou apenas a redistribui.

• **Ganhos em acurácia limpa não implicam ganhos em robustez:** trocar ResNet-50 (23,9% de erro) por DenseNet-121 (25,6%, portanto pior no conjunto limpo) reduz o mCE de 76,7% para 73,4%; o mCE relativo de vários modelos posteriores é pior que o da AlexNet (Fig. 3).

• **Treino de estabilidade também falha:** "Across all noise strengths and stability weight combinations, the models with stability training tested on ImageNet-C have a larger mCEs than the baseline ResNet-50's mCE" (Apêndice F).

• **Modelos menores e mais "simples" não são mais robustos:** CondenseNet com poda mais agressiva piora simultaneamente o erro (28,9%) e a robustez (mCE 84,6%).

Mecanismos Explicativos Propostos

• **A restauração remove detalhe sutil mesmo quando não há ruído a remover:** "A plausible account is that the non-local means algorithm striped the images of their subtle details even when images lacked noise, despite having the non-local means algorithm governed by the noise estimate" (Apêndice F) — apesar de o algoritmo ser controlado por uma estimativa de ruído que deveria deixar imagens limpas quase intactas.

• **Os ganhos locais são anulados por perdas globais:** "the gains in noise robustness were wiped away by subtle blurs to images with other types of corruptions, showing that targeted image restoration can prove harmful for robustness" (Apêndice F).

• **Distinção entre remover informação e redistribuí-la:** o contraste entre CLAHE (que redistribui intensidades e melhora) e Non-Local Means (que suaviza e piora) sugere que o fator determinante não é alterar a imagem, mas sim descartar detalhe fino.

• **Arquiteturas multiescala suprimem ruído sem sacrificar detalhe:** "Since multiscale architectures have high-level representations processed in tandem with fine details, the architectures appear better equipped to suppress otherwise distracting pixel noise" (Seção 5.2) — sugere que processar simultaneamente múltiplas escalas é preferível a filtrar a entrada.

• **Capacidade e agregação de características ajudam:** "more representations, more redundancy, and more capacity allow these massive models to operate more stably on corrupted inputs".

Evidência Espectral

Não. O artigo não realiza análise no domínio da frequência: as 15 corrupções são organizadas por categoria semântica (ruído, blur, clima, digital) e não por conteúdo espectral. Essa lacuna é exatamente o que trabalhos posteriores como Yin et al. (2019) e Saikia et al. (2021) preenchem, ao reordenar as mesmas corrupções do ImageNet-C por fração de energia de alta frequência. Para o nosso SLR, isso significa que o artigo fornece o dado empírico (o denoising piora, o CLAHE melhora) enquanto a explicação espectral vem da literatura subsequente.

Limitações Reconhecidas pelos Autores

Os autores dedicam um apêndice inteiro a falhas informativas, extraindo delas três lições explícitas: a necessidade de testar sobre um conjunto diverso de corrupções, "the difficulty in cleansing corruptions from image", e "the futility in expecting robustness gains from some 'simpler' models". Alertam também que os benchmarks precisarão evoluir para evitar sobreajuste ao conjunto específico de corrupções avaliado, e que corrupções vistas durante o treino não devem ser usadas na avaliação.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Fornece a evidência mais citada de que uma técnica clássica de restauração aplicada como pré-processamento degrada o classificador: o mCE sobe de 76,7% para 82,1% com denoising por Non-Local Means.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Explica a falha do denoising pela remoção de detalhes sutis mesmo em imagens sem ruído, apesar do controle por estimativa de ruído, e generaliza a conclusão de que "targeted image restoration can prove harmful for robustness".

• **RQ3 (Relação quantitativa):** Pouco relevante. As corrupções têm cinco severidades, mas as intervenções de pré-processamento são avaliadas em configuração única e não há qualquer medição de energia espectral.

• **RQ4 (Condições de melhoria):** Altamente relevante. O par denoising versus CLAHE, avaliado sob protocolo idêntico, delimita a fronteira entre degradação e melhoria: redistribuir intensidades melhora simultaneamente o erro limpo e o mCE, enquanto suavizar detalhe piora o mCE.

Qualidade Metodológica e Validade

Artigo publicado em veículo de primeira linha, com benchmarks e código abertos, escala experimental grande e discussão honesta de resultados negativos — qualidade metodológica alta em todos os critérios exceto o espectral. Para o nosso SLR, o par de resultados do Apêndice F e da Seção 5.2 é particularmente valioso porque compara duas técnicas clássicas de pré-processamento sob protocolo idêntico e obtém sinais opostos, delimitando com precisão a fronteira entre a condição da RQ1 (degradação) e a da RQ4 (melhoria).

Título: A Fourier Perspective on Model Robustness in Computer Vision

Autores: Yin, Gontijo Lopes, Cubuk, Shlens & Gilmer

Ano: 2019 | Veículo: NeurIPS 2019 (33rd Conference on Neural Information Processing Systems) — indicado no rodapé do PDF

Decisão: ACEITAR

Justificativa: É o artigo do lote que mais diretamente responde à RQ3. Os autores quantificam a fração de energia de alta frequência de cada corrupção e relacionam esse valor à variação de acurácia do classificador, produzindo curvas com inclinação e resíduo ajustados. Aplicam ainda filtros passa-baixa e passa-alta como front-end explícito do modelo e medem o efeito sobre a acurácia limpa e sobre cada corrupção, cobrindo simultaneamente RQ1, RQ2, RQ3 e RQ4.

Resumo Geral

O trabalho investiga por que ganhos de robustez obtidos com aumento de dados não são uniformes entre tipos de corrupção, e propõe que os compromissos observados se explicam

pelas estatísticas de Fourier das corrupções. Os autores caracterizam cada corrupção do CIFAR-10-C e do ImageNet-C pelo seu espectro médio, constroem mapas de calor de Fourier que medem a sensibilidade do modelo a ruído alinhado a cada vetor de base de Fourier, e mostram que aumento gaussiano e treino adversário deslocam a dependência do modelo para baixas frequências — melhorando a robustez a corrupções de alta frequência e piorando-a a corrupções de baixa frequência. Demonstram também que modelos atingem mais de 30% de acurácia no ImageNet com filtragem passa-baixa extrema e mais de 50% com filtragem passa-alta extrema, usando características quase invisíveis ao olho humano.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Definição formal dos vetores de base de Fourier, dos mapas de calor, das filtragens passa-baixa e passa-alta, das arquiteturas e dos parâmetros de aumento descritos nas Seções 2 a 4.
2. Utiliza baseline sem pré-processamento para comparação	Sim	O modelo treinado naturalmente é o baseline em todas as comparações; a Figura 6 mede explicitamente a diferença de acurácia em relação a ele.

3. Reporta métricas quantitativas de classificação de forma clara	Sim	Tabela 2 reporta acurácia média, mCE e acurácia por corrupção para quatro modelos no CIFAR-10-C; Tabela 1 reporta acurácia por severidade de névoa; resultados de ImageNet no apêndice.
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Arquiteturas (Wide ResNet-28-10 no CIFAR-10, ResNet-50 no ImageNet), parâmetros de aumento (σ = 0,1 e 0,4), normas das perturbações e implementação do AutoAugment referenciada por repositório público.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	A explicação espectral dos compromissos é a tese central; os autores testam a hipótese com cinco experimentos independentes e reportam também o caso em que ela falha.

6. Realiza análise no domínio da frequência / espectral	Sim	Espectro de Fourier das imagens naturais e das corrupções, mapas de calor de sensibilidade por base de Fourier, filtragens passa-baixa e passa-alta com largura de banda variável, e métrica de fração de energia de alta frequência.
7. Avalia mais de um dataset	Sim	CIFAR-10 / CIFAR-10-C e ImageNet / ImageNet-C.
8. Avalia mais de uma arquitetura/modelo	Parcialmente	Wide ResNet-28-10 no CIFAR-10 e ResNet-50 no ImageNet; a comparação principal é entre estratégias de treino, não entre arquiteturas.
9. Discute limitações metodológicas ou ameaças à validade	Sim	Reportam explicitamente o caso em que a perspectiva de Fourier não é preditiva (aumento com "ruído de névoa" piora o desempenho sob névoa) e alertam contra o sobreajuste ao conjunto de corrupções de validação.

10. Publicado em veículo revisado por pares	Sim	NeurIPS 2019, conferência com revisão por pares.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Parcialmente	Parâmetros completos e referências a implementações públicas do AutoAugment e do ImageNet corrompido em memória; nenhum repositório próprio indicado.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Suavização/Blur, Compressão JPEG, Denoising (implícito via aumento), Outra	Filtragem passa-baixa e passa-alta aplicada como front-end do modelo (largura de banda 15 para o passa-baixa e 31 para o passa-alta), filtragem de ruído por largura de banda variável, aumento com ruído gaussiano, treino adversário e AutoAugment. As 15 corrupções do CIFAR-10-C e do ImageNet-C, incluindo blur e JPEG, são avaliadas e ordenadas

		por conteúdo espectral.
Arquitetura(s)	ResNet, Outra	Wide ResNet-28-10 (CIFAR-10) e ResNet-50 (ImageNet), cada um treinado em seis regimes: natural, aumento gaussiano, treino adversário, front-end passa-baixa, front-end passa-alta e AutoAugment.
Dataset(s)	CIFAR-10 / CIFAR-10-C; ImageNet / ImageNet-C	CIFAR-10: 10 classes, imagens 32×32; CIFAR-10-C com 15 corrupções × 5 severidades. ImageNet: 1000 classes; corrupções aplicadas em memória em vez de usar as imagens comprimidas do ImageNet-C.
Métrica(s) de desempenho	Acurácia, Outra	Acurácia top-1 em dados limpos e corrompidos; taxa de erro nos mapas de calor de Fourier; mCE com o modelo treinado naturalmente como referência.

Análise de frequência/espectral?	Sim	Análise espectral extensa — ver a seção Evidência Espectral.
Intensidade em múltiplos níveis?	Sim	Largura de banda dos filtros passa-baixa e passa-alta varrida de 0 a 30; cinco severidades por corrupção; normas fixas de perturbação (ℓ2 = 4 no CIFAR-10 e 15,7 no ImageNet, com variantes maiores no apêndice).
Múltiplas arquiteturas?	Parcialmente	Uma arquitetura por dataset; seis regimes de treino comparados.
Código/Dados públicos?	Parcialmente	Sem repositório próprio; implementações de terceiros referenciadas.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Filtrar passa-alta a entrada degrada tudo, inclusive o erro limpo:** "Applying a high-pass front end degrades performance on all corruptions (as well as clean test error), but performance degradation is more severe on the high frequency corruptions" (Seção 4.1); a acurácia média cai para 0,68 contra 0,77 do modelo natural (Fig. 6).

• **Filtrar passa-baixa produz compromisso, não melhoria uniforme:** "applying a low pass front-end degrades performance on fog and contrast while improving performance on

additive noise and blurring" — o mesmo pré-processamento melhora e piora conforme a corrupção presente.

• **Remover baixa frequência é muito mais custoso que remover alta:** "model performance drops off far more rapidly when low frequency information is removed than high" (Seção 4.2, Fig. 1) — a assimetria decorre de as imagens naturais concentrarem energia nas baixas frequências.

• **Modelos alcançam alta acurácia com conteúdo quase invisível ao humano:** "With aggressive low-pass filtering, the model is still above 30% on ImageNet when the images appear to be simple globs of color. In the case of high-pass filtering, models can achieve above 50% accuracy using features in the input that are nearly invisible to humans" (Fig. 1).

• **Aumento gaussiano e treino adversário compram robustez alta-frequência com robustez baixa-frequência:** "both methods improve robustness to corruptions that are concentrated in the high frequency domain while reducing robustness to corruptions that are concentrated in the low frequency domain" (Resumo); no CIFAR-10-C, o modelo natural cai de 95% para 92% em contraste enquanto os modelos aumentados caem para 57% e 77% (Tabela 2).

• **Aumento diverso é a única estratégia que melhora quase tudo:** AutoAugment atinge acurácia média de 86% e mCE de 64 no CIFAR-10-C, contra 77%/100 do natural, 83%/98 do aumento gaussiano e 81%/108 do treino adversário (Tabela 2).

• **Casar o espectro não basta:** treinar com "ruído de névoa" estatisticamente idêntico à corrupção de névoa no domínio de Fourier piora o desempenho sob névoa em todas as severidades (0,9606 → 0,9090 na severidade 1; 0,7429 → 0,4626 na severidade 5), Tabela 1.

Mecanismos Explicativos Propostos

• **Viés espectral induzido pelo treino determina a robustez:** "the two augmentation methods encourage the model to become invariant to high frequency information while relying more on low frequency information" (Seção 4.1), verificado por mapas de calor de Fourier em CIFAR-10 e ImageNet.

• **O modelo natural é sensível em quase todo o espectro:** "The naturally trained model is highly sensitive to additive perturbations in all but the lowest frequencies" (Fig. 3) — o classificador depende de energia distribuída por bandas que o observador humano ignora.

• **Assimetria estrutural entre alta e baixa frequência:** "Given that natural images are concentrated more in low frequencies, a model can more easily learn to 'ignore' high frequency information rather than low frequency information" (Seção 4.2) — a explicação para a assimetria da dose-resposta.

• **Estatísticas suficientes frágeis:** "In naturally occurring data there are many correlations between the input and target that models can utilize to generalize well. However, utilizing such sufficient statistics will lead to dramatic reduction in model performance should these same statistics become corrupted at test time" (Seção 3).

• **Defesas baseadas em remover alta frequência são mal fundamentadas:** "we should expect that if we adversarially searched for errors in the low frequency domain, we will find

them easily. This explains why JPEG compression, or any other method based on specifically removing high frequency content, should not be expected to be robust to worst-case perturbations" (Seção 4.4).

• **Limite da explicação espectral:** o experimento do "ruído de névoa" mostra que casar as estatísticas marginais de Fourier não é suficiente — os autores reconhecem que "the Fourier perspective is not predictive in all situations" (Seção 4.2).

Evidência Espectral

Sim. Método: transformada de Fourier bidimensional; construção de matrizes de base de Fourier U_(i,j) de norma unitária com no máximo dois elementos não nulos no espectro; "mapas de calor de Fourier" que registram a taxa de erro do modelo sob perturbação alinhada a cada vetor de base; filtragem passa-baixa e passa-alta com largura de banda variável aplicada tanto ao ruído quanto à entrada do modelo. Representação: espectro médio E[|F(X)[i,j]|] das imagens naturais e espectro médio do delta de cada corrupção, E[|F(C(X) − X)[i,j]|]. Bandas analisadas: todo o plano de frequência no CIFAR-10 (32×32) e o quadrado central 63×63 no ImageNet. Tipo de energia: a métrica-chave é a fração de energia de alta frequência da corrupção, ‖H(C(X) − X)‖² / ‖C(X) − X‖², com H denotando filtragem passa-alta de largura de banda 27, calculada por corrupção e promediada sobre imagens e severidades. Relação encontrada com o desempenho: a Figura 6 representa, para seis modelos, a variação de acurácia em relação ao modelo natural contra essa fração de energia, com reta ajustada, inclinação (k) e resíduo (r) reportados na legenda — é a evidência mais próxima de uma relação quantitativa explícita entre energia espectral e acurácia encontrada no lote.

Limitações Reconhecidas pelos Autores

Os autores relatam explicitamente o experimento em que a própria hipótese falha (aumento com ruído de mesmas estatísticas de Fourier da névoa degrada o desempenho sob névoa) e reconhecem que "the Fourier perspective is not predictive in all situations of transfer between data augmentation and robustness". Alertam que medir estatísticas de perturbações adversárias "is not a well defined problem because these statistics will ultimately depend on how the adversary constructs the perturbation". Registram ainda que o AutoAugment "is not strictly more robust than the baseline — there are frequencies for which robustness is degraded rather than improved", e advertem contra o sobreajuste ao conjunto de corrupções de validação.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Mostra que filtragem passa-alta como front-end degrada todas as corrupções e também o erro limpo, e que filtragem passa-baixa produz melhoria e piora conforme a corrupção presente.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Estabelece com mapas de calor de Fourier que o modelo treinado naturalmente é sensível em quase todo o espectro, e explica a assimetria entre alta e baixa frequência pela concentração de energia das imagens naturais nas baixas frequências.

• **RQ3 (Relação quantitativa):** Altamente relevante. É a evidência mais próxima de uma relação quantitativa explícita no lote: a fração de energia de alta frequência da corrupção,

‖H(C(X)−X)‖²/‖C(X)−X‖², é relacionada à variação de acurácia por regressão linear, com inclinação e resíduo reportados.

• **RQ4 (Condições de melhoria):** Altamente relevante. Mostra que aumento diverso (AutoAugment) melhora quase todas as corrupções sem o compromisso espectral, e ao mesmo tempo demonstra, com o contraexemplo do ruído de névoa, que casar as estatísticas espectrais da degradação não basta para obter melhoria.

Qualidade Metodológica e Validade

É o artigo metodologicamente mais forte do lote para as RQ2 e RQ3: publicado em veículo de primeira linha, com dois datasets, seis regimes de treino, instrumentação espectral própria e, sobretudo, uma métrica escalar de energia espectral relacionada quantitativamente à variação de acurácia. A honestidade em reportar o contraexemplo (Tabela 1) aumenta a confiabilidade das demais conclusões. As limitações são o uso de uma única arquitetura por dataset e a ausência de repositório próprio de código.

Título: Adversarial Examples Are Not Bugs, They Are Features

Autores: Ilyas, Santurkar, Tsipras, Engstrom, Tran & Mądry

Ano: 2019 | Veículo: NeurIPS 2019 (33rd Conference on Neural Information Processing Systems); pré-print arXiv:1905.02175

Decisão: ACEITAR (caso limítrofe, ver ressalva)

Justificativa: O estudo constrói datasets em que características imperceptíveis ao humano são removidas ou isoladas, treina classificadores sobre eles e mede a acurácia padrão resultante contra um baseline explícito, quantificando o custo de remover exatamente o tipo de sinal que o pré-processamento de qualidade perceptual tende a eliminar. Fornece assim a fundamentação mecanística mais citada para a premissa central do nosso SLR — a de que classificadores dependem de sinais que o observador humano não percebe. A ressalva é importante: nenhuma técnica clássica de pré-processamento é avaliada e não há análise espectral; a manipulação é feita por otimização no espaço de características.

Resumo Geral

Os autores argumentam que exemplos adversários não são artefatos de treino, mas consequência direta da existência de características "não-robustas": padrões presentes na distribuição de dados que são genuinamente preditivos mas frágeis e incompreensíveis para humanos. Formalizam a distinção entre características robustamente úteis e não-robustamente úteis e a testam construindo dois datasets a partir do CIFAR-10. No primeiro, D̂_R, as características não-robustas são filtradas restringindo o conjunto disponível àquelas usadas por um modelo treinado adversarialmente; treinar com ele por método padrão produz um classificador com robustez não trivial. No segundo, D̂_rand e D̂_det, as imagens são perturbadas adversarialmente e reetiquetadas, de modo que apenas as características não-robustas correlacionam-se com o rótulo; treinar com elas ainda assim generaliza para o conjunto de teste original.

Critérios de Qualidade

Critério de qualidade	Resposta	Observação
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Arcabouço formal das características robustas e não-robustas, procedimento de construção de cada dataset (com pseudocódigo no Apêndice C) e protocolos de treino descritos nas Seções 2 e 3.
2. Utiliza baseline sem pré-processamento para comparação	Sim	O classificador ERM padrão treinado no dataset original D é o baseline (95,25% de acurácia padrão no CIFAR-10, Tabela 7; 95,3% na Tabela 1).
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Tabelas 1, 7 e 9 reportam acurácia padrão e acurácia robusta para cada dataset construído e para cada modelo gerador.
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Procedimentos descritos passo a passo, número de passos de otimização especificado, resultados

		replicados com várias arquiteturas; código público do grupo.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	O mecanismo — utilidade genuína de características não-robustas presentes na distribuição — é a tese central, sustentada por um arcabouço teórico e por um estudo de caso analítico.
6. Realiza análise no domínio da frequência / espectral	Não	Nenhuma análise no domínio da frequência; as características não são caracterizadas espectralmente.
7. Avalia mais de um dataset	Parcialmente	CIFAR-10 nos experimentos principais e uma versão restrita do ImageNet (ImageNet_R) na Tabela 1.
8. Avalia mais de uma arquitetura/modelo	Sim	ResNet-50, ResNet-18, DenseNet, Inception-v3 e VGG-16 na análise de transferibilidade (Fig. 3).

9. Discute limitações metodológicas ou ameaças à validade	Sim	Discutem explicitamente que não é possível validar por conjunto de validação, pois este vem da distribuição construída e não da real, o que impede parada antecipada informada; e que a construção a partir de ruído sofre deslocamento de distribuição.
10. Publicado em veículo revisado por pares	Sim	NeurIPS 2019, conferência com revisão por pares.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Código e dados	Código e datasets construídos disponibilizados pelo grupo dos autores.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**

Técnica(s) de pré-processamento	Outra	Nenhuma técnica clássica de pré-processamento. A manipulação é uma reconstrução do dataset por otimização no espaço de características: D̂_R (imagens sintetizadas de modo a preservar apenas as características usadas por um modelo robusto) e D̂_rand / D̂_det (imagens perturbadas adversarialmente em direção a uma classe alvo e reetiquetadas).
Arquitetura(s)	ResNet, VGG, Outra	ResNet-50 como modelo principal; ResNet-18, DenseNet, Inception-v3 e VGG-16 no experimento de transferibilidade; classificadores robustos treinados adversarialmente com ε = 0,25 e ε = 0,5.
Dataset(s)	CIFAR-10; ImageNet (subconjunto restrito)	CIFAR-10 com 10 classes para todos os experimentos principais; ImageNet_R, uma versão com

		conjunto restrito de classes, na Tabela 1.
Métrica(s) de desempenho	Acurácia	Acurácia padrão sobre o conjunto de teste original D e acurácia adversária sob perturbações de norma limitada; taxa de transferência de exemplos adversários entre arquiteturas.
Análise de frequência/espectral?	Não	Nenhuma análise espectral.
Intensidade em múltiplos níveis?	Não aplicável	Não há técnica de pré-processamento com intensidade graduável; variam-se o modelo gerador (robusto ou padrão), o tipo de reetiquetagem (aleatória ou determinística) e o ponto de partida da otimização (imagem ou ruído).
Múltiplas arquiteturas?	Sim	Cinco arquiteturas no experimento de transferibilidade.

Código/Dados públicos?	Código e dados	Código e datasets liberados publicamente.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Remover as características imperceptíveis custa acurácia padrão:** treinar por método padrão sobre o dataset robusto $\hat{D}_R$ produz 85,40% de acurácia padrão no CIFAR-10, contra 95,25% do ERM no dataset original — cerca de 10 pontos percentuais perdidos (Tabela 7).

• **Mas compra robustez adversária sem treino adversário:** o mesmo modelo atinge 48,20% de acurácia robusta em $\varepsilon = 0{,}25$ e 21,85% em $\varepsilon = 0{,}5$, contra 4,49% e 0,0% do ERM padrão (Tabela 7).

• **As características imperceptíveis são, sozinhas, suficientes para generalizar:** treinar apenas sobre $\hat{D}_{rand}$ atinge 63,3% no conjunto de teste original do CIFAR-10 e 87,9% no ImageNet_R; sobre $\hat{D}_{det}$, 43,7% e 64,4% (Tabela 1) — muito acima do acaso, com todas as características robustas correlacionadas ao rótulo errado.

• **Iniciar a construção a partir de ruído degrada mais:** treinar sobre o dataset não-robusto construído a partir de ruído atinge apenas 45,60% de acurácia padrão, contra 87,68% quando construído a partir de imagens, efeito que os autores atribuem a deslocamento de distribuição (Tabela 7).

• **Quanto mais o modelo aprende as mesmas características frágeis, melhor ele generaliza:** "the test accuracy of each architecture is predictive of how often adversarial examples transfer" (Seção 3.2, Fig. 3), com taxas de transferência de 43,7% a 87,9% acompanhando o desempenho no conjunto padrão.

Mecanismos Explicativos Propostos

• **Características não-robustas são genuinamente preditivas, não ruído:** "This indicates that non-robust features are indeed useful for classification in the standard setting" (Seção 3.2) — a fragilidade do classificador decorre de ele explorar sinal real, ainda que imperceptível.

• **Desalinhamento entre a noção humana de robustez e a geometria dos dados:** os autores atribuem o fenômeno a "a misalignment between the (human-specified) notion of robustness and the inherent geometry of the data" (Resumo) — formulação diretamente aplicável à discrepância entre qualidade perceptual e desempenho de classificação.

• **Filtrar características frágeis produz modelos robustos por treino padrão:** "By filtering out non-robust features from the dataset (e.g. by restricting the set of available features to those used by a robust model), one can train a significantly more robust model using standard training" (Seção 3.1) — com o custo de acurácia padrão quantificado acima.

• **Modelos captam características frágeis mesmo quando há alternativas robustas disponíveis:** "non-robust features can be picked up by models during standard training, even in the presence of robust features that are predictive" (Seção 3.2), evidenciado pelo resultado sobre Ĥ_det.

• **A transferibilidade decorre do uso compartilhado dessas características:** arquiteturas diferentes convergem para as mesmas características frágeis, o que explica a transferência de exemplos adversários entre modelos.

Evidência Espectral

Não. O artigo não realiza qualquer análise no domínio da frequência e não caracteriza as características não-robustas espectralmente. A ponte entre este trabalho e a hipótese espectral do nosso SLR é feita por terceiros: Yin et al. (2019) observam explicitamente que "these invisible high frequency features are related to the experiments of [Ilyas et al.], which show that certain imperceptibly perturbed images contain features which are useful for generalization". Ao citar Ilyas et al., portanto, é necessário distinguir com clareza o que o artigo demonstra (existência e utilidade de características imperceptíveis) do que ele não demonstra (que essas características sejam de alta frequência).

Limitações Reconhecidas pelos Autores

Os autores reconhecem que a validação por conjunto de validação não é possível nesses experimentos, pois o conjunto de validação provém da distribuição construída e não da distribuição real, de modo que "validation accuracy will not be predictive of the true test accuracy, and thus will not help determine when to early stop" — e por isso reportam a acurácia da última iteração, não a melhor. Registram também que a construção a partir de ruído sofre deslocamento de distribuição, o que explica o desempenho subótimo. Reconhecem que o arcabouço formal assume que características fora do conjunto otimizado não são afetadas pela otimização, hipótese que não verificam diretamente.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Parcialmente relevante. Há degradação medida com baseline (85,40% contra 95,25% de acurácia padrão ao remover as características não-robustas), mas a intervenção não é uma técnica de pré-processamento de qualidade perceptual.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. É a referência fundacional para a premissa do SLR: classificadores dependem de características genuinamente preditivas e imperceptíveis ao humano, de modo que qualquer transformação que as elimine cobra um preço em acurácia.

• **RQ3 (Relação quantitativa):** Não fornece evidência. Não há análise espectral nem qualquer medida de energia; a intervenção não tem parâmetro de intensidade graduável.

• **RQ4 (Condições de melhoria):** Relevante. Mostra que a remoção dessas características produz robustez adversária substancial sem treino adversário, delimitando o que se ganha em troca do que se perde.

Qualidade Metodológica e Validade

Publicado em veículo de primeira linha, com arcabouço teórico, experimentos controlados, múltiplas arquiteturas e código público. A ressalva que justifica a classificação como caso limítrofe é de escopo: nenhuma técnica de pré-processamento de qualidade perceptual é avaliada e nenhuma análise espectral é feita, de modo que o artigo não contribui para as RQ1 e RQ3 no sentido estrito. Sua utilidade para o nosso SLR é fundacional e restrita à RQ2 e, parcialmente, à RQ4: estabelece com evidência quantitativa que remover, do sinal de entrada, aquilo que o humano não percebe custa acurácia ao classificador — que é precisamente a premissa que a nossa hipótese espectral pretende especificar e medir.

Título: Hold me tight! Influence of discriminative features on deep network boundaries

Autores: Ortiz-Jiménez, Modas, Moosavi-Dezfooli & Frossard

Ano: 2020 | Veículo: NeurIPS 2020 (34th Conference on Neural Information Processing Systems), Vancouver — indicado no rodapé do PDF

Decisão: ACEITAR

Justificativa: O artigo aplica filtragem passa-baixa explícita no domínio da DCT ao CIFAR-10 e mede a acurácia de teste resultante em dois regimes — treinar na versão filtrada e testar no original, e treinar no original e testar na versão filtrada — encontrando uma assimetria dramática (queda de cerca de 3 pontos no primeiro caso contra queda para 27,45% no segundo). Fornece ainda um mecanismo bem sustentado: as fronteiras de decisão só existem nas direções em que o classificador foi treinado com características discriminativas, e por isso a remoção de energia espectral no teste desloca a entrada para regiões onde o modelo é cego.

Resumo Geral

Os autores propõem medir a distância dos exemplos à fronteira de decisão em subespaços controlados, usando a base DCT bidimensional para gerar subespaços de observação que varrem o espectro de baixas a altas frequências. Aplicando esse arcabouço a MNIST, CIFAR-10 e ImageNet, encontram que as redes têm margem pequena nas direções de baixa frequência e grande invariância nas de alta frequência para MNIST e ImageNet, enquanto no CIFAR-10 a margem é mais uniformemente distribuída ao longo do espectro. Para estabelecer causalidade, realizam duas intervenções sobre os dados: trocam as baixas pelas altas frequências ("flipping" da DCT), verificando que a distribuição de margens acompanha a nova representação, e filtram o CIFAR-10 para reter apenas um bloco 16×16 de baixas frequências, verificando que a rede se torna invariante às direções esvaziadas.

Critérios de Qualidade

Critério de qualidade	Resposta	Observação

1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Definição formal das margens e dos subespaços de observação, geração dos subespaços por janela deslizante na diagonal do tensor DCT, datasets e arquiteturas descritos nas Seções 2 e 3.
2. Utiliza baseline sem pré-processamento para comparação	Sim	Redes treinadas no CIFAR-10 original são a referência das duas comparações (Fig. 2b e Fig. 4).
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Acurácias de teste reportadas no texto e na legenda da Fig. 4 (90,79% para fine-tuning em T_LP, 89,67% para treino do zero, 27,45% para dados filtrados avaliados na rede original).
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Base DCT, tamanho dos blocos, passo da janela, arquiteturas e código público.

5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	O mecanismo é a tese central e é testado com intervenções projetadas para descartar as hipóteses alternativas de arquitetura e algoritmo de treino.
6. Realiza análise no domínio da frequência / espectral	Sim	Toda a análise é conduzida na base DCT bidimensional, com subespaços que percorrem o espectro de baixas a altas frequências, e as intervenções são filtragens espectrais explícitas.
7. Avalia mais de um dataset	Sim	MNIST, CIFAR-10 e ImageNet, além de datasets sintéticos construídos para isolar os mecanismos.
8. Avalia mais de uma arquitetura/modelo	Sim	MLPs, LeNet, DenseNet-121, ResNet-50 e várias redes pré-treinadas do PyTorch (mais experimentos no material suplementar).

9. Discute limitações metodológicas ou ameaças à validade	Sim	Discutem explicitamente os fatores de confusão possíveis (arquitetura e algoritmo de treino) e desenham experimentos para descartá-los; registram que a base DCT não é perfeitamente alinhada às características do dataset.
10. Publicado em veículo revisado por pares	Sim	NeurIPS 2020, conferência com revisão por pares.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Somente código	github.com/LTS4/hold-me-tight

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**

Técnica(s) de pré-processamento	Suavização/Blur, Outra	Filtragem passa-baixa no domínio da DCT: retenção apenas dos coeficientes em um bloco 16×16 no canto superior esquerdo da diagonal do tensor DCT do CIFAR-10 (conjunto denominado T_LP), garantindo energia nula fora desse subespaço; para o MNIST, largura de banda 14×14. Intervenção adicional de "flipping" da DCT, que troca baixas por altas frequências.
Arquitetura(s)	ResNet, Outra	MLPs (dados sintéticos), LeNet, DenseNet-121 (CIFAR-10) e ResNet-50 e outras redes pré-treinadas do PyTorch (ImageNet).
Dataset(s)	MNIST; CIFAR-10; ImageNet; datasets sintéticos	MNIST e CIFAR-10 com 10 classes; ImageNet com redes pré-treinadas; famílias sintéticas T1 e T2 com N = 10.000 amostras em D = 100 dimensões, construídas para conhecer as características

		discriminativas por construção.
Métrica(s) de desempenho	Acurácia, Outra	Acurácia de teste; distribuição da margem (menor perturbação necessária para trocar a decisão) por subespaço espectral, reportada em percentis 5, mediana e 95.
Análise de frequência/espectral?	Sim	Base DCT bidimensional; subespaços de K×K amostrados na diagonal do tensor DCT por janela deslizante de passo T; distribuições de margem por banda; intervenções de filtragem e inversão espectral.
Intensidade em múltiplos níveis?	Parcialmente	Duas larguras de banda de filtragem (16×16 no CIFAR-10 e 14×14 no MNIST) e vários tamanhos de subespaço de observação, mas sem varredura sistemática de intensidade de filtragem.
Múltiplas arquiteturas?	Sim	MLP, LeNet, DenseNet-121,

		ResNet-50 e demais redes pré-treinadas.
Código/Dados públicos?	Somente código	github.com/LTS4/hold-me-tight

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Filtrar passa-baixa no teste degrada catastroficamente uma rede treinada no original:** "testing T_LP data on a CIFAR-10 trained network only achieves 27.45% test accuracy" (Seção 3.2.2) — o mesmo tipo de filtragem que preserva o conteúdo perceptual derruba a acurácia de cerca de 93% para 27,45%.

• **Mas treinar com dados filtrados custa pouco:** "by training with only low frequency data, the test accuracy of the network on the original CIFAR-10 only drops around 3%"; a DenseNet-121 treinada do zero em T_LP atinge 89,67% no CIFAR-10 original e a versão apenas ajustada, 90,79% (Fig. 4).

• **A assimetria é a evidência central:** remover alta frequência do treino custa cerca de 3 pontos; removê-la apenas do teste custa mais de 65 — a degradação não decorre da perda de informação semântica, mas do descasamento entre o domínio de treino e o de teste.

• **A dependência espectral varia por dataset:** "For MNIST and ImageNet, the networks present a strong invariance along high frequency directions and small margin along low frequency ones", enquanto no CIFAR-10 "the margin values are more uniformly distributed; an indication that the network exploits discriminative features across the full spectrum" (Seção 3.2).

• **Em datasets já dominados por baixas frequências, filtrar não custa nada:** "For MNIST, training on a low-pass version (with bandwidth 14×14) yields no drop in test accuracy" (nota de rodapé 8) — condição precisa em que o pré-processamento é inócuo.

Mecanismos Explicativos Propostos

• **As fronteiras de decisão só existem onde há características discriminativas:** "the decision boundaries of a neural network can only exist for as long as the classifier is trained with the features that hold them together" (Seção 3.2.2) — daí o título do artigo.

• **Filtrar o treino induz invariância nas direções esvaziadas:** "by eliminating the high frequency content, we have forced the network to become invariant along these directions. This clearly demonstrates that there existed discriminative features in the high frequency spectrum of CIFAR-10" (Seção 3.2.2).

• **A invariância induzida é a razão do baixo custo no treino filtrado:** "Because T_LP has no high frequency energy, a network trained on it will uniformly extend its boundaries in this

part of the spectrum and no high frequency perturbation will be able to flip the network's output".

• **A degradação no teste decorre de fronteiras existentes nas bandas removidas:** "networks trained on CIFAR-10 do have boundaries in the high frequencies, and hence showing them original samples perturbed in this frequency range (i.e., T_LP) can greatly change their decisions" — o pré-processamento age, para a rede, como uma perturbação em direções sensíveis.

• **A geometria é causada pelos dados, não pela arquitetura:** o experimento de inversão espectral mostra que "the margin strongly depends on the data distribution, and it is not solely an effect of the network architecture" (Seção 3.2.1); os autores argumentam que as intervenções foram desenhadas justamente para descartar arquitetura e algoritmo de treino como explicações alternativas.

Evidência Espectral

Sim. Método: transformada discreta do cosseno bidimensional (2D-DCT), escolhida por evitar subespaços complexos e por aproximar bem a transformada de decorrelação. Representação: subespaços de observação de dimensão K×K amostrados por janela deslizante ao longo da diagonal do tensor DCT, o que produz um gradiente bem definido de baixas a altas frequências. Bandas analisadas: todo o espectro, de baixa a alta, em MNIST, CIFAR-10 e ImageNet; intervenções concentradas no bloco 16×16 de baixas frequências (CIFAR-10) e 14×14 (MNIST). Tipo de energia: os autores garantem que "no training image has any energy, hence information, outside of this frequency subspace" nos conjuntos filtrados. Relação encontrada com o desempenho: as bandas de margem pequena são exatamente aquelas em que o dataset contém características discriminativas exploradas pela rede; remover energia dessas bandas apenas no teste leva a acurácia de cerca de 93% para 27,45%, enquanto removê-la também no treino custa apenas cerca de 3 pontos.

Limitações Reconhecidas pelos Autores

Os autores reconhecem que a base DCT "is not perfectly feature-aligned", ainda que seja uma boa aproximação para os datasets estudados, e discutem explicitamente que a inspeção de margens em uma base não alinhada às características exploradas pode não separar direções de margem pequena e grande — motivo pelo qual comparam com bases ortogonais e aleatórias como controle. Reconhecem também que flutuações finitas na margem ao longo das direções invariantes seriam esperadas mesmo em um classificador linear por construção, e apresentam uma caracterização teórica desse efeito no material suplementar.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. A filtragem passa-baixa aplicada apenas ao conjunto de teste derruba a acurácia do CIFAR-10 para 27,45%, o que é uma das maiores degradações por pré-processamento documentadas no lote.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Oferece um mecanismo geométrico testado por intervenção: fronteiras de decisão só existem nas bandas onde o classificador foi treinado com características discriminativas, de modo que filtrar apenas o teste move a entrada para direções em que a rede tem fronteiras, enquanto filtrar também o treino induz invariância.

• **RQ3 (Relação quantitativa):** Relevante. As distribuições de margem por subespaço da DCT constituem um mapa completo de sensibilidade por banda, com percentis reportados, ainda que não haja curva de energia removida contra acurácia.

• **RQ4 (Condições de melhoria):** Relevante. Identifica a condição em que a filtragem é inócua: quando o dataset já não contém informação discriminativa na banda removida, como no MNIST, onde a filtragem passa-baixa com largura 14×14 não causa nenhuma perda de acurácia.

Qualidade Metodológica e Validade

Desenho experimental de alta qualidade: publicado em veículo de primeira linha, com código público, três datasets reais mais famílias sintéticas construídas para conhecer as características por construção, múltiplas arquiteturas e intervenções desenhadas explicitamente para descartar fatores de confusão. Para o nosso SLR, o achado de maior valor é a assimetria entre filtrar o treino e filtrar o teste, que separa com nitidez duas causas possíveis de degradação — perda de informação e descasamento de domínio — e mostra que, no CIFAR-10, é a segunda que domina.

Título: TensorShield: Tensor-based Defense Against Adversarial Attacks on Images

Autores: Entezari & Papalexakis

Ano: 2020 | Veículo: não indicado no PDF (pré-print arXiv:2002.10252)

Decisão: ACEITAR (caso limítrofe, ver ressalva)

Justificativa: O estudo usa aproximação de baixo posto por decomposição tensorial como etapa de pré-processamento explicitamente motivada pela remoção de componentes de alta frequência, e mede a acurácia top-1 resultante de uma CNN pré-treinada, comparando com a compressão JPEG estocástica do método Shield. Fornece evidência para as RQ2 e RQ4 sobre a relação entre descarte de conteúdo espectral e desempenho. A ressalva é séria: o artigo não reporta a acurácia sobre imagens limpas, de modo que não é possível medir o custo do pré-processamento no baseline sem ataque.

Resumo Geral

Os autores partem da premissa, herdada do método Shield, de que perturbações adversárias concentram-se no espectro de alta frequência da imagem e podem ser removidas por técnicas de compressão ou aproximação de baixo posto. Em vez de usar compressão JPEG, propõem tratar a imagem (ou um lote de imagens) como um tensor multimodal e obter uma aproximação de baixo posto por decomposição Tensor-Train, escolhida por escalar linearmente com a dimensão. A imagem reconstruída é então alimentada à rede. Experimentos com ResNet-v2 50 sobre o conjunto de validação do ImageNet, contra ataques FGSM, i-FGSM e PGD, mostram que o método supera consistentemente a quantização local estocástica do Shield, tanto em acurácia sob ataque quanto em tempo de execução. Os autores exploram ainda o efeito do tamanho do lote e da introdução de aleatoriedade nos postos.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Decomposições comparadas (Parafac, Tucker, Tensor-Train), representações tensoriais (3 modos, 3 modos empilhados, 4 modos), tamanhos de lote, faixas de posto, modelo e biblioteca descritos nas Seções 3 e 4.
2. Utiliza baseline sem pré-processamento para comparação	Não	A linha "No defense" da Tabela 1 corresponde a imagens atacadas sem defesa, não a imagens limpas; a acurácia do ResNet-v2 50 sobre imagens não atacadas e sem pré-processamento não é reportada em nenhum ponto do artigo.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Acurácia top-1 e tempo de execução tabulados para sete configurações × três ataques (Tabela 1) e para configurações com aleatoriedade (Tabela 2).

4. Experimentos descritos com detalhe suficiente para replicação	Sim	Modelo (ResNet-v2 50 do TF-Slim), biblioteca de ataques (CleverHans), biblioteca de decomposição (TensorLy), hardware e faixas de busca de hiperparâmetros especificados; desativação do recorte central explicitamente registrada.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Parcialmente	A motivação espectral é enunciada com clareza, mas não é testada; nenhum experimento verifica que o que a aproximação de baixo posto descarta é de fato conteúdo de alta frequência.
6. Realiza análise no domínio da frequência / espectral	Não	Nenhuma transformada nem medição de energia; a análise é feita no "espectro de matriz" (perfil de valores singulares e dimensionalidade intrínseca de baixo posto), que é uma noção distinta de espectro.

7. Avalia mais de um dataset	Não	Apenas o conjunto de validação do ImageNet.
8. Avalia mais de uma arquitetura/modelo	Não	Apenas ResNet-v2 50; a variação é de método de decomposição, não de arquitetura de classificador.
9. Discute limitações metodológicas ou ameaças à validade	Não	Não há discussão de limitações nem de ameaças à validade; a ausência de baseline limpo não é comentada.
10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Parcialmente	Bibliotecas e configurações descritas com detalhe suficiente para replicação; nenhum código próprio liberado.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**

Técnica(s) de pré-processamento	Denoising, Compressão JPEG (comparação), Outra	Aproximação de baixo posto por decomposição tensorial como pré-processamento: Tensor-Train (principal), Tucker e Parafac; representações em 3 modos, 3 modos empilhados e 4 modos (lotes); postos varridos de 40 a 150; variante com posto aleatório por bloco de imagem (blocos de 50×50 e 150×150). Comparação com a quantização local estocástica (SLQ) do Shield, que aplica compressão JPEG em qualidades 20, 40, 60 e 80 por bloco 8×8.
Arquitetura(s)	ResNet	ResNet-v2 50 do módulo TF-Slim do TensorFlow.
Dataset(s)	ImageNet (ILSVRC 2012)	Conjunto de validação com 50.000 imagens de 1000 classes; os experimentos de ajuste de parâmetros usam 1000 imagens. Recorte central desativado em todas as avaliações, seguindo a crítica de Cornelius ao

		protocolo original do Shield.
Métrica(s) de desempenho	Acurácia, Outra	Acurácia top-1 sob ataque e tempo de execução em segundos sobre o conjunto completo.
Análise de frequência/espectral?	Não	Nenhuma análise espectral no domínio da frequência; a análise de "espectro" é a do perfil de valores singulares.
Intensidade em múltiplos níveis?	Sim	Postos varridos de 50 a 120 em passos de 5 (e de 40 a 150 na busca geral), cinco tamanhos de lote (1, 5, 10, 20, 50) e dois tamanhos de bloco na variante aleatória; ataques em ε = 4.
Múltiplas arquiteturas?	Não	Apenas ResNet-v2 50.
Código/Dados públicos?	Não	Nem código nem dados liberados.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Sob ataque, o pré-processamento recupera acurácia de forma expressiva:** com Tensor-Train em representação de 4 modos e lote 5, a acurácia sobe de 11,10% para 51,53% sob PGD, de 18,40% para 43,59% sob FGSM e de 7,49% para 50,46% sob i-FGSM, todos com $\varepsilon = 4$ (Tabela 1).

• **A aproximação de baixo posto supera a compressão JPEG estocástica:** o SLQ do Shield atinge 44,60% (PGD), 29,40% (FGSM) e 38,60% (i-FGSM), ficando entre 7 e 14 pontos abaixo do Tensor-Train, embora seja o método mais rápido (410 s contra 675 s).

• **O grau de compressão é um parâmetro crítico com compromisso explícito:** a acurácia varia sistematicamente com o posto escolhido e com o tamanho do lote, e os autores registram que "There is a trade-off between runtime and accuracy. Based on the priorities of the system, one might sacrifice accuracy for speed".

• **Processar em lotes melhora o desempenho:** "decomposing images in batches, extracts latent structure corresponding to perturbations from multiple images and captures general characteristics of perturbations"; o lote 5 produz a maior acurácia.

• **O custo sobre imagens limpas não é medido:** o artigo não reporta a acurácia do ResNet-v2 50 sobre imagens não atacadas, com ou sem a transformação — limitação que impede avaliar a direção do efeito no cenário central do nosso SLR.

Mecanismos Explicativos Propostos

• **Perturbações adversárias como conteúdo de alta frequência:** "The adversarial attacks do not preserve the spectral characteristics of images and add high frequency components to images to remain unnoticeable to the human eyes. Perturbations in image domain are crafted in a way that mostly affect high frequency spectrum of images" (Seção 3.1).

• **Descarte de alta frequência como princípio de defesa:** "discarding the high frequency factors of the image using approaches like compression or low-rank approximation of images could be successful defense mechanisms against these type of perturbations" — a premissa que o nosso SLR interroga.

• **Baixo posto como proxy de baixa frequência:** os autores transpõem o argumento do domínio da frequência para o "espectro de matriz", isto é, o perfil de valores singulares e a dimensionalidade intrínseca de baixo posto dos dados; a equivalência entre as duas noções é assumida, e não demonstrada.

• **Estrutura latente compartilhada entre imagens:** a melhoria obtida ao decompor lotes é atribuída à captura de "higher-order correlations" que caracterizam a perturbação de forma mais geral do que a análise de uma única imagem permitiria.

Evidência Espectral

Não. Apesar de a motivação do artigo ser inteiramente espectral, nenhuma transformada de Fourier ou DCT é calculada e nenhuma energia por banda é medida. A análise efetivamente realizada é sobre o "espectro de matriz" — perfil de valores singulares e posto — que é uma noção de compressibilidade distinta da noção de frequência espacial. A equivalência entre descartar componentes de posto alto e descartar frequências altas é assumida como premissa e nunca verificada empiricamente, o que é a principal fragilidade do artigo para as RQ2 e RQ3.

Limitações Reconhecidas pelos Autores

O artigo não possui seção de limitações nem de ameaças à validade. As limitações mais relevantes para o nosso SLR não são reconhecidas pelos autores: a ausência de qualquer medida de acurácia sobre imagens limpas (com ou sem a transformação), a não verificação da premissa espectral que motiva o método, e a avaliação sobre uma única arquitetura e um único dataset. O único cuidado metodológico explicitamente registrado é a desativação do recorte central, adotada por causa da crítica de Cornelius ao protocolo de avaliação original do Shield.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Pouco relevante. Não há baseline de imagens limpas, de modo que o artigo não permite avaliar se o pré-processamento degrada o classificador na ausência de ataque.

• **RQ2 (Mecanismo explicativo):** Relevante como objeto de crítica. Fornece uma formulação limpa da premissa "a perturbação relevante é de alta frequência, logo descartá-la é seguro", que é justamente a premissa que trabalhos posteriores com análise espectral direta contestam; útil para situar a nossa pergunta de pesquisa.

• **RQ3 (Relação quantitativa):** Pouco relevante. A varredura de postos e tamanhos de lote produz curvas de acurácia contra grau de compressão, que funcionam como proxy da informação descartada, mas nenhuma energia espectral é medida e a equivalência entre posto e frequência é assumida sem verificação.

• **RQ4 (Condições de melhoria):** Relevante. Mostra que a escolha da representação e do grau de compressão altera substancialmente o resultado (Tensor-Train em quatro modos supera SLQ por 7 a 14 pontos), e que processar imagens em lotes captura melhor a estrutura da perturbação.

Qualidade Metodológica e Validade

Trabalho curto e de escopo restrito, com boa descrição experimental (bibliotecas, hardware, faixas de busca) e um cuidado metodológico relevante ao corrigir o protocolo de avaliação do baseline. A classificação como caso limítrofe decorre de duas ausências que afetam diretamente o nosso SLR: não há baseline de imagens limpas, o que impede medir o custo do pré-processamento no cenário sem ataque, e não há verificação da premissa espectral que fundamenta o método. Sua contribuição principal é fornecer, na Seção 3.1, um enunciado limpo da hipótese "perturbação relevante é de alta frequência, logo descartá-la é seguro" — hipótese que artigos como Yin et al. (2019) e Maiya et al. (2021) contestam com evidência espectral direta.

Título: Improving Robustness Against Common Corruptions with Frequency Biased Models

Autores: Saikia, Schmid & Brox

Ano: 2021 | Veículo: não indicado no PDF (pré-print arXiv:2103.16241)

Decisão: ACEITAR

Justificativa: O artigo organiza explicitamente as corrupções do ImageNet-C por conteúdo espectral e mede, para cada regime de treino, o compromisso entre erro em imagens limpas e erro sob corrupção, com baseline sem intervenção. Quantifica o custo de enviesar o modelo para robustez de alta frequência (o erro limpo sobe de 11,8% para 14,8% e depois 16,0%) e propõe uma condição precisa em que esse custo é evitado, cobrindo diretamente as RQ1, RQ2 e RQ4.

Resumo Geral

O trabalho parte da observação, herdada de Yin et al., de que aumento de dados com ruído gaussiano ou treino adversário melhora a robustez a corrupções de alta frequência e piora a robustez a corrupções de baixa frequência, além de degradar o erro em imagens limpas. Os autores propõem, em vez de buscar um modelo único robusto em todo o espectro, treinar dois especialistas com vieses de frequência opostos e combiná-los por média das predições — o método RoHL. O especialista de alta frequência é treinado com aumento de ruído e borramento gaussianos e com uma regularização nova, a minimização da variação total dos mapas de características das camadas convolucionais iniciais; o especialista de baixa frequência é treinado com aumento de contraste. A combinação melhora o erro sob corrupção sem degradar o desempenho em imagens limpas.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Regimes de treino, operações de aumento, fator de regularização (λ = 1e−5), arquiteturas, benchmarks e métricas descritos nas Seções 4 e 5.
2. Utiliza baseline sem pré-processamento para comparação	Sim	O modelo "Standard", treinado em imagens naturais sem aumento nem regularização, é a linha de referência da Tabela 1 (erro limpo 12,2%, mCE 49,9%).

3. Reporta métricas quantitativas de classificação de forma clara	Sim	Tabelas 1 a 4 reportam erro limpo e mCE para cada regime; erro por tipo de corrupção nas Figuras 4 e 5; AP e mAPc para detecção de objetos.
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Hiperparâmetros no corpo e no suplementar, análise de sensibilidade de λ, frameworks identificados (mmdetection), aumentos pré-computados de terceiros referenciados.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	O viés de frequência do modelo é o mecanismo proposto e é testado com ablações por camada, com variação de arquitetura e com ordenação espectral das corrupções.
6. Realiza análise no domínio da frequência / espectral	Sim	As corrupções são ordenadas por quantidade de conteúdo de alta frequência, com espectros de Fourier das operações básicas apresentados na Fig. 2 e a

		metodologia de ordenação detalhada no suplementar.
7. Avalia mais de um dataset	Sim	ImageNet-100 / ImageNet-C-100 nas ablações, ImageNet / ImageNet-C nos resultados principais, além de ImageNet-R, ObjectNet e um dataset automotivo com corrupções reais.
8. Avalia mais de uma arquitetura/modelo	Sim	ResNet50 e ResNet18 na classificação, com verificação em DenseNet e MNasNet no suplementar; FasterRCNN com backbone ResNet50 na detecção.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Discutem que os compromissos são "mais nuançados" do que a literatura anterior sugere e contestam explicitamente uma conclusão de Yin et al., mas não há seção formal de ameaças à validade.
10. Publicado em veículo	Não informado	Sem indicação de veículo no PDF.

revisado por pares		
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Parcialmente	Hiperparâmetros completos entre artigo e suplementar; nenhum repositório próprio indicado no PDF.

Extração de Dados

Campo do SLR	Valor Extraído	Detalhes
Técnica(s) de pré-processamento	Suavização/Blur, Denoising (implícito), Compressão JPEG, Outra	Aumentos usados para induzir viés espectral: ruído gaussiano N(0; 0,08) e borramento gaussiano com kernel 3 (viés de alta frequência); aumento de contraste (viés de baixa frequência); AugMix e DeepAugment como aumentos diversos. Regularização por minimização da variação total dos mapas de características convolucionais (λ = 1e−5). As 15 corrupções do ImageNet-C, incluindo blur e JPEG, são avaliadas e ordenadas espectralmente.

Arquitetura(s)	ResNet, Outra	ResNet50 nos resultados principais, ResNet18 nas ablações em ImageNet-100; DenseNet e MNasNet como verificação de generalidade no suplementar; FasterRCNN com backbone ResNet50 para detecção.
Dataset(s)	ImageNet / ImageNet-C; ImageNet-100 / ImageNet-C-100; ImageNet-R; ObjectNet; dataset automotivo	ImageNet-100: subconjunto de 100 classes usado nas ablações, com o correspondente ImageNet-C-100. ImageNet-R: 30 mil renderizações artísticas de 200 classes do ImageNet. ObjectNet: 50 mil imagens de 313 classes, das quais 109 sobrepõem-se ao ImageNet. Dataset automotivo com corrupções do mundo real para classificação e detecção.
Métrica(s) de desempenho	Acurácia, Outra	Erro de classificação limpo (100 − acurácia top-1); erro médio de corrupção (mCE), normalizado pela AlexNet no ImageNet-C; AP no padrão COCO e mAPc médio sobre

		tipos de corrupção para detecção.
Análise de frequência/espectral?	Sim	Espectro de Fourier das operações de aumento (Fig. 2) e ordenação das 15 corrupções do ImageNet-C por conteúdo de alta frequência, usada como eixo x das Figuras 4 e 5.
Intensidade em múltiplos níveis?	Parcialmente	Variantes de viés fraco e forte por composição de aumentos; cinco severidades por corrupção; análise de sensibilidade do fator λ no suplementar; mas sem varredura sistemática de intensidade das operações de filtragem.
Múltiplas arquiteturas?	Sim	ResNet50, ResNet18, DenseNet, MNasNet e FasterRCNN.
Código/Dados públicos?	Não informado	Sem repositório próprio no PDF; usam imagens do DeepAugment

		pré-computadas por terceiros.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Enviesar o modelo para robustez de alta frequência custa acurácia em imagens limpas:** a regularização por variação total leva o erro limpo de 11,8% (AugMix) para 14,8% (AMTV) e o mCE de 40,9% para 35,9%; combinada com aumento gaussiano, o erro limpo chega a 16,0% e o mCE a 31,5% (Tabelas 1 e 2).

• **O custo escala com a intensidade do viés:** "As we add more high-frequency robustness bias, performance on clean images and low-frequency corruptions deteriorated" (Seção 5.3.1).

• **O efeito é oposto conforme o conteúdo espectral da corrupção:** "the TV regularized model consistently improves over the standard and the AugMix model on all corruptions that affect high frequencies. On low-frequency corruptions (Eg: brightness, contrast, fog), TV regularization has a negative effect" (Seção 5.2, Fig. 4).

• **O viés de baixa frequência não cobra o mesmo preço:** o aumento por contraste "does improve performance on other low-frequency corruptions (fog, frost, brightness). Also it does not degrade the clean error" — erro limpo permanece em 11,8% com mCE caindo de 40,9% para 39,1% (Tabela 2).

• **Os compromissos não são simétricos nem simples:** o aumento por contraste também melhora certas corrupções de ruído, o que leva os autores a concluir que "trade-offs are more nuanced compared to high-frequency augmentation operations", contestando a leitura de Yin et al. de que não existiria compromisso claro para baixas frequências.

• **Combinar especialistas evita o custo:** o ensemble RoHL de dois modelos com vieses opostos atinge erro limpo de 11,4% e mCE de 28,4%, e 11,7%/25,9% na variante mais forte, contra 10,9%/39,1% de um ensemble padrão de dois modelos AugMix (Tabela 3).

Mecanismos Explicativos Propostos

• **Blur remove características de alta frequência que a rede usa:** "corruptions that include blur affect the high-frequency components, as they diminish high-frequency image features such as edges" (Seção 3.1).

• **Reduzir a dependência de alta frequência custa acurácia limpa:** "Data augmentation with operations that act on the high-frequencies make the trained model to rely less on high-frequency features and have been shown to improve robustness to corruptions concentrated in the high-frequency spectrum considerably. However, as they remove high-frequency features from the model, they also reduce performance on clean images considerably" (Seção 3.1) — enunciado direto do compromisso central do nosso SLR.

• **Filtrar a imagem de teste é pior que regularizar o modelo:** "TV minimization could directly filter out noise in the test images, but this requires solving an optimization problem

for each test image, which makes the approach slow. Moreover, denoising will also destroy important high-frequency signals and may introduce new artefacts on test images" (Seção 4.3) — os autores explicitamente preferem regularizar as ativações a pré-processar a entrada, justamente pelo custo do denoising.

• **O local da intervenção importa:** "Applying TV regularization on early conv feature maps is crucial for achieving strong high-frequency robustness" (Seção 5.1.2) — a supressão de alta frequência precisa ocorrer cedo na hierarquia.

• **Assimetria estrutural do espectro natural:** "Natural images are inherently dominated by the low-frequency components", o que torna a robustez a corrupções de baixa frequência intrinsecamente mais difícil de obter que a robustez a alta frequência.

• **Vieses ortogonais produzem erros ortogonais:** "Models trained with different robustness biases are likely to make different errors" — hipótese que fundamenta o ensemble e é confirmada pela superioridade do RoHL sobre ensembles de membros com o mesmo viés.

Evidência Espectral

Sim. Método: transformada de Fourier bidimensional aplicada às operações de corrupção e de aumento. Representação: espectros de Fourier das três operações básicas (contraste, ruído gaussiano e borramento gaussiano), apresentados na Figura 2, mostrando que o contraste concentra-se nas componentes de baixa frequência (próximas ao centro) enquanto ruído e borramento têm concentrações relativamente maiores nas regiões de alta frequência. Bandas analisadas: as 15 corrupções do ImageNet-C são ordenadas de baixa a alta frequência pela quantidade de conteúdo de alta frequência, com a metodologia de ordenação detalhada no material suplementar; essa ordenação é usada como eixo horizontal das Figuras 4 e 5. Relação encontrada com o desempenho: os perfis de erro por corrupção ordenada revelam um cruzamento sistemático — o modelo regularizado por variação total é uniformemente melhor na metade de alta frequência do eixo e uniformemente pior na metade de baixa frequência, e o modelo ajustado com contraste apresenta o padrão inverso.

Limitações Reconhecidas pelos Autores

Os autores contestam explicitamente a conclusão de Yin et al. de que não existiria compromisso claro para corrupções de baixa frequência, e reformulam o resultado ao mostrar que o aumento por contraste — uma operação genérica de baixa frequência — melhora fog, frost e brilho, ao contrário do aumento por perturbação direta de componentes de Fourier de baixa frequência, que destrói as estatísticas naturais da imagem. Reconhecem, porém, que o próprio ganho é irregular (o aumento por contraste melhora certos ruídos e piora blur) e que os compromissos são mais nuançados do que a leitura espectral simples sugere. Não há seção formal de ameaças à validade.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. Quantifica com baseline explícito o custo em acurácia limpa de reduzir a dependência de alta frequência: o erro sobe de 11,8% para 14,8% e depois 16,0% conforme o viés se intensifica.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Enuncia diretamente que operações de alta frequência fazem o modelo depender menos de características de alta frequência e por isso reduzem consideravelmente o desempenho em imagens limpas, e justifica a preferência por regularizar o modelo em vez de filtrar a entrada pelo fato de o denoising destruir sinais de alta frequência importantes e introduzir artefatos.

• **RQ3 (Relação quantitativa):** Relevante. As 15 corrupções são ordenadas por conteúdo de alta frequência e os perfis de erro por corrupção mostram um cruzamento sistemático entre modelos de viés oposto, o que constitui uma relação ordinal, ainda que não uma curva de energia contra acurácia.

• **RQ4 (Condições de melhoria):** Altamente relevante. Estabelece que o viés de baixa frequência (aumento por contraste) melhora sem custo no erro limpo, ao contrário do viés de alta frequência, e mostra que combinar especialistas com vieses ortogonais evita inteiramente o compromisso (erro limpo de 11,4% com mCE de 28,4%).

Qualidade Metodológica e Validade

Estudo amplo e bem controlado, com ablações em ImageNet-100 e resultados principais em ImageNet completo, verificação em arquiteturas fora da família ResNet, extensão para detecção de objetos e avaliação em corrupções reais de um dataset automotivo. Para o nosso SLR, a contribuição mais valiosa é a quantificação sistemática do compromisso entre erro limpo e robustez em função do viés espectral induzido, junto com uma justificativa explícita de por que os autores preferem regularizar o modelo a filtrar a entrada — o denoising "destrói sinais de alta frequência importantes e pode introduzir novos artefatos". A ausência de repositório de código é a principal fragilidade de reprodutibilidade.

Título: Assessing the Impact of CNN Auto Encoder-Based Image Denoising on Image Classification Tasks

Autores: Hami & JameBozorg

Ano: 2024 | Veículo: não indicado no PDF (pré-print arXiv:2404.10664)

Decisão: ACEITAR

Justificativa: É o artigo do lote cujo título e desenho experimental mais se aproximam da pergunta central do SLR: mede diretamente o efeito do denoising sobre a acurácia de classificação, com baseline de entrada não processada, em duas arquiteturas. Fornece evidência para a RQ4 (melhoria quando a entrada é genuinamente ruidosa e o método é casado ao tipo de ruído) e registra explicitamente, na conclusão, a condição de degradação por excesso de processamento, relevante para a RQ1.

Resumo Geral

O trabalho aborda a detecção de defeitos em produtos de fundição (rotores de bombas submersíveis) a partir de imagens ruidosas, e integra detecção de ruído e denoising ao pipeline de classificação. Em uma primeira fase, cinco arquiteturas são comparadas em classificação binária (defeituoso versus normal) sobre imagens ruidosas. Em uma segunda fase, os autores classificam o tipo de ruído operando no domínio da frequência — aplicando

FFT bidimensional às imagens e treinando um classificador sobre a magnitude espectral — e então aplicam a técnica de denoising específica para cada tipo: autoencoder convolucional com conexões de atalho para ruído gaussiano e periódico, e três filtros de mediana sequenciais de kernel 3 para sal-e-pimenta. A acurácia de classificação binária é então recomputada sobre as imagens restauradas.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Divisões de dados, arquiteturas, métricas de avaliação do denoising, pipeline de detecção de tipo de ruído e escolha dos filtros descritos nas Seções 2.1 a 2.3.
2. Utiliza baseline sem pré-processamento para comparação	Sim	A Tabela 1 reporta a acurácia dos classificadores sobre as imagens ruidosas sem denoising (VGG16 94,62%; InceptionV3 84,70%), que é o baseline sem pré-processamento das comparações finais.
3. Reporta métricas quantitativas de classificação de forma clara	Parcialmente	O baseline está tabelado com acurácia, recall, precisão, F1, sensibilidade e especificidade, mas os valores pós-denoising

		(97,0% e 90,0%) aparecem apenas no resumo e em figuras, sem tabela correspondente.
4. Experimentos descritos com detalhe suficiente para replicação	Parcialmente	Divisões percentuais, tamanhos de entrada e ferramentas são descritos, e os datasets são referenciados por link; mas a arquitetura do autoencoder não é especificada em detalhe (apenas visualizada) e os hiperparâmetros de treino não são reportados.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Parcialmente	Registram, na discussão, que a aplicação excessiva do modelo remove detalhes cruciais e produz borramento, mas não desenvolvem o mecanismo nem o testam.
6. Realiza análise no domínio da frequência / espectral	Parcialmente	O domínio da frequência é usado como espaço de representação para classificar o tipo de ruído (FFT 2D e deslocamento espectral), com acurácia de 99,5%; não há, porém, análise de bandas nem

		medição de energia relacionada ao desempenho de classificação de defeitos.
7. Avalia mais de um dataset	Não	Um único domínio de imagens: produtos de fundição (rotores), em duas fases do mesmo conjunto.
8. Avalia mais de uma arquitetura/modelo	Sim	VGG16, InceptionV3, AlexNet, ResNet50 e uma CNN customizada na Fase 1; VGG16 e Inception-ResNet-V2 na classificação de tipo de ruído.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Reconhecem o risco de degradação por excesso de denoising e a divergência entre métricas favoráveis e qualidade visual real, mas não há seção formal de ameaças à validade.
10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF.

11. Código, dados ou parâmetros disponíveis/descritos para replicação	Somente dados	Os autores fornecem links para os conjuntos das Fases 1 e 2 e para os rótulos, hospedados pelo departamento de engenharia da computação da Bu-Ali Sina University; nenhum código é liberado.

Extração de Dados

Campo do SLR	**Valor Extraído**	**Detalhes**
Técnica(s) de pré-processamento	Denoising, Suavização/Blur, Outra	Autoencoder convolucional com conexões de atalho entre camadas correspondentes do codificador e do decodificador, treinado contra a imagem de referência (e não contra a entrada), para ruído gaussiano e periódico; três filtros de mediana sequenciais de kernel 3×3 para ruído sal-e-pimenta (kernels 5, 7 e 9 produziram resultados inferiores).

Arquitetura(s)	VGG, ResNet, CNN rasa / Custom CNN, AlexNet, Outra	Fase 1 (classificação binária): VGG16, InceptionV3, AlexNet, ResNet50 e uma CNN customizada, com transferência de aprendizado e EarlyStopping. Fase 2 (classificação de tipo de ruído no domínio da frequência): VGG16 e Inception-ResNet-V2.
Dataset(s)	Casting product image data for quality inspection (Kaggle), versão ruidosa	Fase 1: 1063 imagens de treino, 85 de teste e 85 de validação (≈70/15/15), duas classes (Defected e OK), todas ruidosas; imagens redimensionadas para 224×224 e normalizadas. Fase 2: imagens ruidosas com as respectivas referências; 750/250/250 para a classificação de tipo de ruído e 1032/182 para o treino do denoiser (entrada 256×256).

Métrica(s) de desempenho	Acurácia, F1-score, Precisão, Recall, Outra	Classificação: acurácia de treino e teste, perda, recall, precisão, F1-score, sensibilidade, especificidade e curvas ROC. Denoising: SSIM, PSNR, LPIPS (calculado com pesos da AlexNet no PyTorch) e qualidade visual subjetiva.
Análise de frequência/espectral?	Parcialmente	FFT bidimensional com deslocamento espectral usada como representação de entrada para classificar o tipo de ruído (99,5% de acurácia com VGG16 após 24 épocas; 96,4% com Inception-ResNet-V2 após 12 épocas); nenhuma análise de bandas ou de energia.
Intensidade em múltiplos níveis?	Parcialmente	Kernels de mediana comparados (3, 5, 7, 9) e discussão sobre aplicação repetida do autoencoder; sem varredura sistemática de intensidade de denoising.

Múltiplas arquiteturas?	Sim	Cinco arquiteturas comparadas na Fase 1 e duas na classificação de tipo de ruído.
Código/Dados públicos?	Somente dados	Links públicos para os conjuntos das Fases 1 e 2 e para os rótulos; sem código.

Efeito sobre a Acurácia

Direção do efeito: Melhora

• **O denoising casado ao tipo de ruído melhora a classificação:** "For the VGG16 classifier, accuracy increased from 94.6% to 97.0%… Similarly, for the InceptionV3 classifier, accuracy improved from 84.7% to 90.0%" (Resumo) — ganhos de 2,4 e 5,3 pontos percentuais sobre o baseline de imagens ruidosas.

• **A eficácia depende do casamento entre método e tipo de ruído:** "while the Autoencoder deep model effectively removes both periodic and Gaussian noise, it fails to adequately enhance images affected by salt and pepper noise. Additionally, the median filter can only perform well on salt and pepper noise" (Seção 2.3.2) — nenhum método é universalmente adequado.

• **A qualidade da restauração varia muito por tipo de ruído:** SSIM médio de 87,96 ± 1,50 para sal-e-pimenta com filtros de mediana, 81,69 ± 4,75 para ruído periódico e apenas 64,04 ± 12,88 para ruído gaussiano com o autoencoder (Tabela 2), com desvios-padrão que indicam alta variabilidade no caso gaussiano.

• **A detecção do tipo de ruído no domínio da frequência é altamente confiável:** 99,5% de acurácia com VGG16 sobre a magnitude da FFT, o que viabiliza o roteamento automático para o denoiser adequado.

• **Aplicação excessiva de denoising degrada, ainda que as métricas melhorem:** "Given the complexity of our model, excessive application may lead to the removal of crucial image details, resulting in poor image quality despite favorable metrics. This could manifest as blurring if the model is applied multiple times or if the model itself is overly complex" (Seção 4).

Mecanismos Explicativos Propostos

• **Excesso de processamento remove detalhes cruciais:** é o mecanismo explicitamente reconhecido pelos autores na discussão, formulado em termos de remoção de detalhe e

borramento resultante — o mesmo fenômeno que o nosso SLR investiga, aqui identificado como um limite superior da dose de denoising.

• **Divergência entre métricas de qualidade e qualidade efetiva:** os autores registram que a degradação por excesso pode ocorrer "despite favorable metrics", isto é, SSIM e PSNR podem melhorar enquanto a informação relevante para a tarefa é destruída — observação convergente com a inconsistência entre perda de denoising e acurácia relatada por Liao et al. (2018).

• **Conexões de atalho como forma de preservar alta frequência:** "These connections enable the network to retain high-resolution information from earlier layers, preserving fine details during the up-sampling process" (Seção 2.3) — a escolha arquitetural é justificada precisamente pela necessidade de não perder detalhe fino durante a restauração.

• **Separabilidade de sinal e ruído no domínio da frequência:** "One of the primary reasons for utilizing the frequency domain in image classification tasks is its capability to distinguish between signals (desired information) and noises (unwanted artifacts)" (Seção 2.2) — o argumento que justifica classificar o tipo de ruído espectralmente.

Evidência Espectral

Parcialmente. O domínio da frequência é usado de forma instrumental e bem-sucedida: as imagens são transformadas por FFT bidimensional com deslocamento espectral e a magnitude resultante serve de entrada para um classificador de tipo de ruído, que atinge 99,5% de acurácia. Não há, porém, análise de bandas, medição de energia espectral, nem qualquer tentativa de relacionar quantitativamente energia removida a variação de acurácia — o espectro é usado como espaço de representação para uma tarefa auxiliar, e não como instrumento de análise do efeito do pré-processamento sobre o classificador principal.

Limitações Reconhecidas pelos Autores

Os autores reconhecem, na discussão, que a aplicação excessiva do modelo de denoising remove detalhes cruciais da imagem e produz borramento, e que isso pode ocorrer mesmo quando as métricas quantitativas parecem favoráveis. Não discutem, contudo, o fato de o estudo se restringir a um único domínio de imagens industriais com apenas duas classes, a ausência de tabela com os resultados de classificação pós-denoising, a não disponibilização do código, nem a alta variabilidade do SSIM no caso gaussiano (desvio-padrão de 12,88 sobre média de 64,04).

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Parcialmente relevante. O artigo documenta melhoria, não degradação; sua contribuição para a RQ1 é a advertência explícita de que a aplicação excessiva do denoising remove detalhes cruciais e produz borramento, mesmo com métricas favoráveis.

• **RQ2 (Mecanismo explicativo):** Relevante. Identifica a remoção de detalhe por excesso de processamento como mecanismo de degradação e registra a divergência entre métricas de qualidade de imagem e qualidade efetiva para a tarefa; justifica as conexões de atalho do autoencoder pela necessidade de preservar detalhe fino.

• **RQ3 (Relação quantitativa):** Pouco relevante. O domínio da frequência é usado apenas como espaço de representação para classificar o tipo de ruído; não há medição de energia por banda nem relação com a acurácia do classificador principal.

• **RQ4 (Condições de melhoria):** Altamente relevante. É o caso mais claro de melhoria do lote, e as condições são explícitas: a entrada precisa estar genuinamente degradada, o método de denoising precisa ser casado ao tipo de ruído (detectado automaticamente com 99,5% de acurácia no domínio da frequência), e a dose precisa ser controlada.

Qualidade Metodológica e Validade

O alinhamento temático com o nosso SLR é o mais direto do lote, mas a execução metodológica é a mais frágil entre os artigos aceitos: os resultados centrais de classificação pós-denoising não são tabelados, os hiperparâmetros de treino não são reportados, o código não é liberado e o estudo cobre um único domínio de imagens com duas classes. A Tabela 1, com o baseline de cinco arquiteturas, é sólida; a comparação pós-denoising não tem o mesmo rigor. Para o SLR, o artigo é útil sobretudo como evidência de que o denoising melhora quando três condições se verificam simultaneamente — a entrada é genuinamente degradada, o método é casado ao tipo de degradação, e a dose é controlada — e a formulação dessa terceira condição na Seção 4 é a sua contribuição mais original.

Lote 3 — Artigos Aceitos

Dois PDFs acrescentados à pasta nao_analisados e triados em 03/09/2026: ambos aceitos. São referências fundacionais da linha investigada — o primeiro estabelece o desenho experimental empírico da RQ1, o segundo fornece a verificação causal do mecanismo de textura.

Título: Understanding How Image Quality Affects Deep Neural Networks

Autores: Dodge & Karam

Ano: 2016 | Veículo: não indicado no PDF (pré-print arXiv:1604.04004)

Decisão: ACEITAR

Justificativa: É o estudo seminal do desenho experimental que o nosso SLR investiga: quatro CNNs pré-treinadas avaliadas sobre o ImageNet degradado por cinco tipos de distorção de qualidade, cada um varrido em múltiplos níveis, com baseline de imagens originais. Além da evidência empírica direta para a RQ1, os autores propõem explicitamente que o blur degrada a classificação por remover texturas das quais a rede depende, e sustentam essa hipótese com uma análise das respostas dos filtros na primeira e na última camada convolucional.

Resumo Geral

O trabalho parte da distinção entre qualidade perceptual humana e qualidade do ponto de vista de um sistema de visão computacional, e argumenta que distorções cotidianas de

aquisição, transmissão e armazenamento — muito mais prováveis na prática do que perturbações adversárias — precisam ser caracterizadas separadamente. Os autores avaliam quatro arquiteturas pré-treinadas (Caffe Reference, VGG-CNN-S, VGG-16 e GoogLeNet) sobre 10 mil imagens do conjunto de validação do ImageNet 2012, degradadas por compressão JPEG, compressão JPEG2000, ruído gaussiano, borramento gaussiano e redução de contraste, cada distorção em nove a onze níveis. O achado central é uma assimetria nítida entre tipos de degradação: todas as redes são muito sensíveis a blur e ruído, e notavelmente resilientes a compressão e contraste. A análise das ativações mostra que o blur altera pouco as respostas da primeira camada mas muito as da última, enquanto o ruído é captado imediatamente pelos filtros iniciais.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**
1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Quatro arquiteturas (com contagem de camadas e parâmetros na Tabela I), dataset, cinco tipos de distorção com faixas e passos explicitados e bibliotecas de compressão identificadas — Seção III.
2. Utiliza baseline sem pré-processamento para comparação	Sim	As imagens originais do ImageNet constituem o ponto de partida de todas as curvas (nível de distorção nulo na Figura 2); a Figura 3 mostra a confiança do softmax da imagem original em comparação com as degradadas.

3. Reporta métricas quantitativas de classificação de forma clara	Parcialmente	Acurácia top-1 e top-5 reportadas para 4 redes × 5 distorções × todos os níveis, mas exclusivamente em figuras; nenhum valor é tabelado, o que impede extrair números precisos.
4. Experimentos descritos com detalhe suficiente para replicação	Sim	Pesos pré-treinados da biblioteca Caffe (públicos), faixas e passos de cada distorção, bibliotecas LibJPEG e OpenJPEG, e protocolo de amostragem (10 imagens por classe) descritos com detalhe suficiente.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	Propõem que o blur degrada por remover texturas usadas pela rede e sustentam a hipótese com a análise comparativa das respostas dos filtros nas camadas conv1-1 e conv5-3 (Figura 4).

6. Realiza análise no domínio da frequência / espectral	Não	Nenhuma transformada nem análise de bandas; a única menção espectral é qualitativa ("the high frequency nature of the noise is picked up by many of the early layer filters").
7. Avalia mais de um dataset	Não	Apenas o conjunto de validação do ImageNet 2012.
8. Avalia mais de uma arquitetura/modelo	Sim	Caffe Reference (AlexNet), VGG-CNN-S, VGG-16 e GoogLeNet, comparadas em todas as condições.
9. Discute limitações metodológicas ou ameaças à validade	Parcialmente	Reconhecem que treinar com imagens de baixa qualidade poderia degradar o desempenho em imagens de alta qualidade e deixam a investigação para trabalho futuro, mas não há seção formal de ameaças à validade.
10. Publicado em veículo revisado por pares	Não informado	Sem indicação de veículo no PDF.

11. Código, dados ou parâmetros disponíveis/descritos para replicação	Parcialmente	Pesos pré-treinados públicos e parâmetros das distorções completamente especificados; nenhum código próprio liberado.

Extração de Dados

Campo do SLR	Valor Extraído	Detalhes
Técnica(s) de pré-processamento	Suavização/Blur, Compressão JPEG, Outra	Borramento gaussiano com σ de 1 a 9 em passos de 1 (janela do filtro igual a 4σ); ruído gaussiano aditivo por componente de cor com σ de 10 a 100 em passos de 10; compressão JPEG com parâmetro de qualidade de 2 a 20 em passos de 2 (LibJPEG); compressão JPEG2000 com PSNR de 20 a 40 em passos de 2 (OpenJPEG); redução de contraste por mistura com imagem cinza, fator de 0 a 1 em passos de 0,1.

Arquitetura(s)	AlexNet, VGG, Outra	Caffe Reference Model (implementação da AlexNet; 5 camadas convolucionais, 3 totalmente conectadas, 61 milhões de parâmetros), VGG-CNN-S (5 e 3 camadas, 102 milhões), VGG-16 (13 e 3 camadas, 138 milhões) e GoogLeNet (21 camadas de inception, 1 totalmente conectada, 7 milhões). Todas pré-treinadas no ImageNet, com pesos da biblioteca Caffe.
Dataset(s)	ImageNet (ILSVRC 2012)	Subconjunto de 10.000 imagens do conjunto de validação (10 imagens escolhidas aleatoriamente em cada uma das 1000 categorias), por economia de computação; imagens originais de qualidade relativamente alta.
Métrica(s) de desempenho	Acurácia, Outra	Acurácia top-1 e top-5; saída da unidade softmax da classe correta como medida de confiança (Figura 3).

Análise de frequência/espectral?	Não	Sem análise espectral; a natureza de alta frequência do ruído é mencionada de forma qualitativa na leitura das ativações.
Intensidade em múltiplos níveis?	Sim	Nove níveis de blur, dez de ruído, dez de JPEG, onze de JPEG2000 e onze de contraste.
Múltiplas arquiteturas?	Sim	Quatro arquiteturas comparadas em todas as condições.
Código/Dados públicos?	Não	Nem código nem dados degradados liberados; os pesos usados são públicos.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Todas as redes são fortemente sensíveis a blur, já em níveis moderados:** "All of the networks are very sensitive to blur. Even for moderate blur levels, the accuracy of the networks decreases significantly" (Seção IV, Figura 2a).

• **O ruído leva o classificador a níveis muito baixos em condições que o humano atravessa sem dificuldade:** "At a noise standard deviation of 90 the networks performance becomes less than 20% on average; however at this level of noise, the images are still easily recognizable by human observers" (Seção IV).

• **A compressão é surpreendentemente inócua até um limiar:** "The networks are surprisingly resilient to JPEG and JPEG2000 compression distortions. It is only at very low

quality levels (quality parameter less than 10 for JPEG and PSNR less than 30 for JPEG2000) that the performance begins to decrease" (Seção IV).

• **A redução de contraste também é bem tolerada:** "The networks also show resiliency with respect to contrast changes. Again, the VGG-16 network appears more robust than the other networks" (Seção IV).

• **A sensibilidade a ruído depende da profundidade da arquitetura:** "compared with the Caffe network and the VGG-CNN-S network, the performance of the VGG-16 and GoogleNet falls off slower. This could be because of the deeper structure of the VGG-16 and GoogleNet networks, which allows the networks more room to learn features that are not affected by noise" (Seção IV).

• **A confiança do classificador decresce monotonicamente com a qualidade, para todas as redes e todas as distorções:** "For all networks and for all distortions this confidence decreases as the image quality decreases" (legenda da Figura 3); exemplo do gato persa sob blur: 0,891 / 0,988 / 0,996 / 0,863 caem para 0,297 / 0,841 / 0,962 / 0,357 no nível seguinte.

• **A vulnerabilidade é comum às arquiteturas testadas, e não peculiar a um modelo:** "it shows that the reduced performance under blur and noise is not limited to a particular model, but is common to the considered DNN architectures" (Seção V).

Mecanismos Explicativos Propostos

• **Blur degrada porque remove texturas das quais a rede depende:** "This reduction in performance can possibly be explained because blur removes textures in these images. The network may be looking for specific textures to classify an image" (Seção IV) — enunciado antecipado da hipótese de viés de textura, formalizada três anos depois por Geirhos et al. (2019).

• **Pequenas alterações nas primeiras camadas propagam-se e amplificam-se nas camadas profundas:** "The blur causes the filter responses in the first convolutional layer to change, but only slightly. However, at the last convolutional layer, the filter responses exhibit significant changes… This tells us that small changes in the first layer response are propagating to create larger changes at the higher layer" (Seção IV, Figura 4).

• **Ruído e blur agem por vias distintas na hierarquia:** "The effect of noise is more evident in the first convolutional layer. The high frequency nature of the noise is picked up by many of the early layer filters. The responses of the last convolutional layer are not so noisy, but are much different than those from the original image" (Seção IV) — o ruído acrescenta energia de alta frequência captada imediatamente, o blur a remove e o dano só se manifesta em profundidade.

• **Qualidade perceptual humana e qualidade para a máquina não são comensuráveis:** os autores abrem o artigo notando que "the computer may be fooled by images that are perceived by humans to be identical… or in some cases the computer can recognize images that are indistinguishable from noise by a human observer. Thus, it is important to separately consider how image quality can affect computer vision applications" (Seção I).

Evidência Espectral

Não. O artigo não computa nenhuma transformada e não analisa bandas de frequência. A única referência espectral é qualitativa, na leitura das ativações: "The high frequency nature of the noise is picked up by many of the early layer filters". A análise quantitativa efetivamente realizada é feita no espaço de ativações, comparando visualmente as respostas dos filtros das camadas conv1-1 e conv5-3 da VGG-16 sob imagem original, borrada e ruidosa (Figura 4).

Limitações Reconhecidas pelos Autores

Os autores reconhecem que a solução aparentemente óbvia — treinar as redes com imagens de baixa qualidade — não é livre de custo: "Training with low quality images should improve testing results on low quality images, but perhaps this may also result in decreased performance on high quality images. Furthermore, training with increased number of samples leads to longer training times. An investigation of the benefits of training with low quality samples is left for future work." Registram também que Caffe e GoogLeNet já são treinadas com leve perturbação de cor como regularização e ainda assim têm desempenho ruim sob degradação. Não há seção formal de ameaças à validade, e o uso de 10 mil das 50 mil imagens de validação é justificado apenas por economia computacional.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Altamente relevante. É a evidência de referência de que CNNs pré-treinadas degradam sob distorções de qualidade, com quatro arquiteturas, cinco distorções e varredura densa de intensidade sobre o ImageNet.

• **RQ2 (Mecanismo explicativo):** Altamente relevante. Propõe a remoção de textura como causa da degradação por blur e sustenta a proposta com análise de ativações que localiza onde, na hierarquia, o dano se manifesta — distinguindo a via do blur (dano tardio, por propagação) da via do ruído (dano imediato nas camadas iniciais).

• **RQ3 (Relação quantitativa):** Relevante. As curvas cobrem nove a onze níveis por distorção e permitem identificar limiares de tolerância (qualidade JPEG 20, PSNR JPEG2000 30), mas os valores estão apenas em figuras e nenhuma energia espectral é medida.

• **RQ4 (Condições de melhoria):** Relevante. Delimita a condição de neutralidade do pré-processamento: compressão acima do limiar de qualidade e mudanças de contraste não degradam significativamente o classificador. Nenhuma condição de melhoria efetiva é observada.

Qualidade Metodológica e Validade

É o trabalho fundador da linha empírica que o nosso SLR revisa, e por isso aparece como referência em praticamente todos os demais artigos aceitos (Vasiljevic et al., Borkar & Karam, Hendrycks & Dietterich, Geirhos et al. e Yin et al. o citam explicitamente). O desenho é simples e correto: baseline claro, quatro arquiteturas, cinco distorções, varredura densa de intensidade. As fragilidades são a apresentação exclusivamente gráfica dos resultados, que impede a extração de valores numéricos, o uso de um único dataset e a ausência de qualquer análise espectral — a hipótese da textura é proposta mas não testada. Para o SLR, seu valor está menos nos números e mais em dois pontos: a assimetria documentada entre distorções que removem detalhe fino (blur, ruído) e as que

não removem (compressão moderada, contraste), e a formulação precoce do mecanismo de textura.

Título: ImageNet-trained CNNs are Biased Towards Texture; Increasing Shape Bias Improves Accuracy and Robustness

Autores: Geirhos, Rubisch, Michaelis, Bethge, Wichmann & Brendel

Ano: 2019 | Veículo: ICLR 2019 (International Conference on Learning Representations) — indicado no cabeçalho do PDF

Decisão: ACEITAR

Justificativa: O artigo estabelece, com experimentos controlados sobre CNNs e observadores humanos, que redes treinadas no ImageNet classificam por textura local e não por forma global — o mecanismo que melhor explica por que técnicas de pré-processamento que suavizam textura degradam classificadores. Avalia ainda o efeito de filtragem passa-alta e passa-baixa paramétrica sobre a acurácia, com baseline e comparação humana, e reporta um achado de valor excepcional para a RQ3: o borramento é a única distorção em que a rede menos dependente de textura é mais frágil, e os autores atribuem isso explicitamente à distribuição espectral dos dados de treino.

Resumo Geral

Os autores confrontam quantitativamente duas hipóteses sobre o que as CNNs aprendem — a hipótese da forma, dominante na literatura, e a hipótese da textura — usando imagens com conflito de pistas geradas por transferência de estilo (por exemplo, a silhueta de um gato com a textura de pele de elefante). Em nove experimentos psicofísicos totalizando 48.560 ensaios com 97 observadores, mostram que humanos classificam pela forma enquanto CNNs treinadas no ImageNet classificam pela textura. Em seguida constroem o Stylized-ImageNet (SIN), uma versão do ImageNet em que a textura local é substituída por estilos de pintura, e demonstram que a mesma arquitetura ResNet-50 passa a aprender uma representação baseada em forma. O viés de forma do modelo sobe de 22% para 81%. Essa representação traz benefícios emergentes: melhor detecção de objetos, melhor acurácia no ImageNet quando SIN é usado como aumento, e robustez a distorções nunca vistas no treino.

Critérios de Qualidade

Critério de qualidade	**Resposta**	**Observação**

1. Metodologia experimental claramente definida (técnicas, datasets, modelos)	Sim	Geração dos estímulos por transferência de estilo, protocolo psicofísico (apresentação de 200 ms, máscara de ruído rosa 1/f, resposta em grade 4×4 de 16 categorias), arquiteturas, regimes de treino e conjunto de distorções descritos nas Seções 2 e 3 e no Apêndice.
2. Utiliza baseline sem pré-processamento para comparação	Sim	A ResNet-50 padrão treinada no ImageNet (vanilla) é o baseline de todas as comparações (Tabela 2), e os dados de observadores humanos servem de referência adicional nas curvas de distorção.
3. Reporta métricas quantitativas de classificação de forma clara	Sim	Tabela 2 reporta top-1 e top-5 no ImageNet e mAP50 no PASCAL VOC 2007 e MS COCO para quatro regimes de treino; a Tabela 5 do Apêndice reporta o erro de corrupção no ImageNet-C; a Figura 6 traz curvas de acurácia por nível para oito famílias de distorção.

4. Experimentos descritos com detalhe suficiente para replicação	Sim	Pesos dos modelos, código, dataset Stylized-ImageNet e os dados comportamentais completos (49 mil ensaios com 97 observadores) publicados em dois repositórios públicos.
5. Discute mecanismos explicativos, não apenas resultados empíricos	Sim	O mecanismo — viés de textura versus viés de forma — é a tese central, testada por intervenção sobre os dados de treino e não apenas observada.
6. Realiza análise no domínio da frequência / espectral	Parcialmente	Não há transformada nem medição de energia por banda, mas há experimentos de filtragem passa-alta e passa-baixa paramétrica, e a explicação da exceção do blur é formulada em termos de sobre-representação de sinais de alta frequência no conjunto de treino.
7. Avalia mais de um dataset	Sim	ImageNet, Stylized-ImageNet, ImageNet-C, PASCAL VOC 2007 e MS COCO, além dos conjuntos de estímulos psicofísicos.

8. Avalia mais de uma arquitetura/modelo	Sim	ResNet-50 nos experimentos principais e ResNet-152 no Apêndice (Tabela 4); os experimentos de conflito de pistas incluem também AlexNet, VGG-16, GoogLeNet e ResNet-50.
9. Discute limitações metodológicas ou ameaças à validade	Sim	Discutem que o ganho de robustez é emergente e não garantido, contrastam explicitamente com o achado de Geirhos et al. (2018) de que treinar em distorções específicas não confere robustez a outras, e explicam a única exceção observada (blur) em vez de omiti-la.
10. Publicado em veículo revisado por pares	Sim	ICLR 2019, conferência com revisão por pares.
11. Código, dados ou parâmetros disponíveis/descritos para replicação	Código e dados	github.com/rgeirhos/texture-vs-shape (pesos, código e dados comportamentais) e github.com/rgeirhos/Stylized-ImageNet (geração do dataset).

Extração de Dados

Campo do SLR	Valor Extraído	Detalhes
Técnica(s) de pré-processamento	Suavização/Blur, Outra	Filtragem passa-baixa e passa-alta paramétrica (eixo em log2 do desvio-padrão do filtro), ruído uniforme, ruído de fase, redução de contraste e perturbações de eidolon (três níveis de coerência), cada família com mais de cinco níveis de intensidade. Como intervenção sobre o treino, transferência de estilo (AdaIN) para construir o Stylized-ImageNet, que remove pistas de textura local preservando a forma global.
Arquitetura(s)	ResNet, VGG, AlexNet, Outra	ResNet-50 nos quatro regimes (treinada em IN, em SIN, em SIN+IN, e em SIN+IN com ajuste fino em IN, denominada Shape-ResNet); ResNet-152 no Apêndice; AlexNet, VGG-16, GoogLeNet e ResNet-50 nos experimentos de conflito de pistas.

Dataset(s)	ImageNet; Stylized-ImageNet; ImageNet-C; PASCAL VOC 2007; MS COCO	ImageNet: 1000 classes, 1,2 milhão de imagens de treino. Stylized-ImageNet: versão estilizada do ImageNet gerada por transferência de estilo com o conjunto Painter by Numbers. ImageNet-C: 15 corrupções. Estímulos psicofísicos organizados nas 16 categorias de nível básico do "16-class-ImageNet".
Métrica(s) de desempenho	Acurácia, Outra	Acurácia top-1 e top-5 no ImageNet; acurácia de classificação por nível de distorção nas 16 categorias, comparada com observadores humanos; viés de forma versus textura (fração de decisões pela forma); mAP50 para detecção de objetos; erro médio de corrupção no ImageNet-C.

Análise de frequência/espectral?	Parcialmente	Não há transformada calculada, mas há filtragem espectral explícita (passa-alta e passa-baixa) em múltiplos níveis, e a explicação da exceção do blur invoca a distribuição de energia de alta frequência do conjunto de treino.
Intensidade em múltiplos níveis?	Sim	Todas as oito famílias de distorção da Figura 6 têm mais de cinco níveis de intensidade; o viés de forma é induzido em quatro graus distintos pelos quatro regimes de treino.
Múltiplas arquiteturas?	Sim	ResNet-50, ResNet-152, AlexNet, VGG-16 e GoogLeNet.
Código/Dados públicos?	Código e dados	Pesos, código, dataset e dados comportamentais completos em repositórios públicos.

Efeito sobre a Acurácia

Direção do efeito: Efeito misto (depende do contexto)

• **Reduzir a dependência de textura melhora a robustez a quase todas as distorções:** "the SIN-trained network outperforms the IN-trained CNN on almost all image manipulations" (Seção 3), avaliado sobre ruído uniforme, ruído de fase, contraste, filtragem passa-alta e passa-baixa e três variantes de eidolon.

• **O borramento é a única exceção, e a explicação é espectral:** "Low-pass filtering / blurring is the only distortion type on which SIN-trained networks are more susceptible, which might be due to the over-representation of high frequency signals in SIN through paintings and the reliance on sharp edges" (Seção 3) — achado de valor excepcional para a nossa RQ3.

• **O ganho é emergente, sem que a rede tenha visto qualquer degradação no treino:** "The SIN-trained ResNet-50 approaches human-level distortion robustness—despite never seeing any of the distortions during training" (Seção 3).

• **Treinar apenas em dados sem textura custa muito no conjunto limpo:** top-1 no ImageNet cai de 76,13% (vanilla, treinada em IN) para 60,18% (treinada só em SIN); top-5 cai de 92,86% para 82,62% (Tabela 2).

• **Mas combinar os dois regimes elimina o custo e ainda melhora:** treinada em SIN+IN, a ResNet-50 atinge 74,59% de top-1; com ajuste fino adicional em IN (Shape-ResNet), atinge 76,72% de top-1 e 93,28% de top-5 — acima da vanilla em ambos (Tabela 2).

• **O ganho transfere para detecção de objetos:** mAP50 sobe de 70,7 para 75,1 no PASCAL VOC 2007 e de 52,3 para 55,2 no MS COCO (Tabela 2).

• **E para o benchmark de corrupções comuns:** o erro médio de corrupção no ImageNet-C cai de 76,7 (ResNet-50 padrão) para 69,3 com treino conjunto em SIN e IN, com melhoria em 13 dos 15 tipos de corrupção — nenhum deles presente no treino (Seção 3 e Tabela 5 do Apêndice).

• **O viés de forma do modelo pode ser deslocado por larga margem:** a fração de decisões baseadas na forma sobe de 22% (modelo treinado em IN) para 81% (treinado em SIN), aproximando-se do comportamento humano (Seção 3, Figura 5).

Mecanismos Explicativos Propostos

• **Hipótese da textura: CNNs treinadas no ImageNet reconhecem por textura local, não por forma global:** "ImageNet-trained CNNs are strongly biased towards recognising textures rather than shapes, which is in stark contrast to human behavioural evidence and reveals fundamentally different classification strategies" (Resumo) — é o mecanismo mais direto disponível na literatura para explicar por que suavizar textura degrada classificadores.

• **Textura é frágil a qualquer perturbação; forma é estável:** "While local textures are easily distorted by all sorts of noise (including those in the real world, such as rain and snow), the object shape remains relatively stable. Furthermore, this finding offers a compellingly simple explanation for the incredible robustness of humans when coping with distortions: a shape-based representation" (Seção 4).

• **O viés de textura é induzido pelos dados, não pela arquitetura:** "a ResNet-50 architecture can indeed learn to recognise objects based on object shape, revealing that the

texture bias in current CNNs is not by design but induced by ImageNet training data" (Seção 4) — a mesma arquitetura muda de estratégia ao mudar o conjunto de treino.

• **Atalho estatístico como versão da navalha de Occam:** "standard ImageNet-trained models may be taking a 'shortcut' by focusing on local textures, which could be seen as a version of Occam's razor: If textures are sufficient, why should a CNN learn much else?" (Seção 4) — convergente com a hipótese das regularidades superficiais de Jo & Bengio (2017).

• **A dependência espectral do modelo é herdada da distribuição espectral do conjunto de treino:** a explicação da exceção do blur atribui a maior fragilidade do modelo treinado em SIN à sobre-representação de sinais de alta frequência nas pinturas usadas na estilização e à consequente dependência de bordas nítidas — isto é, o conteúdo espectral dos dados de treino determina qual filtragem é mais danosa no teste.

• **Estratégias de classificação divergentes explicam o descompasso entre humano e máquina:** "While both human and machine vision systems achieve similarly high accuracies on standard images, our findings suggest that the underlying classification strategies might actually be very different" (Seção 4).

Evidência Espectral

Parcialmente. Não há transformada calculada nem medição de energia por banda, mas o artigo realiza filtragem espectral explícita e paramétrica: as Figuras 6c e 6d reportam a acurácia de classificação em função do log2 do desvio-padrão do filtro, para filtragem passa-alta e passa-baixa, comparando ResNet-50 treinada em IN, treinada em SIN e observadores humanos, em mais de cinco níveis por família. Mais importante para o SLR, a única exceção ao padrão geral é explicada em termos espectrais: os autores atribuem a maior fragilidade do modelo com viés de forma sob borramento à sobre-representação de sinais de alta frequência no conjunto de treino estilizado e à dependência resultante de bordas nítidas. É, portanto, um caso documentado em que a distribuição espectral dos dados de treino prediz qual filtragem de teste é mais danosa.

Limitações Reconhecidas pelos Autores

Os autores não escondem a única exceção ao seu resultado principal e oferecem uma explicação para ela, em vez de omiti-la: o modelo com viés de forma é mais suscetível a filtragem passa-baixa. Registram que treinar somente em Stylized-ImageNet custa cerca de 16 pontos de acurácia top-1 no ImageNet, e que o ganho de robustez é emergente e portanto não garantido — contrastando explicitamente com Geirhos et al. (2018), segundo os quais redes treinadas em distorções específicas não adquirem robustez a manipulações não vistas. Discutem ainda o problema de as CNNs serem usadas como modelos computacionais da visão humana apesar de as estratégias de classificação subjacentes serem demonstradamente distintas.

Relevância para as Questões de Pesquisa (RQs) do SLR

• **RQ1 (Degradação existe):** Relevante. Documenta a degradação sob filtragem passa-alta e passa-baixa, ruído, contraste e eidolon em curvas paramétricas com baseline e referência humana, e quantifica o custo de treinar sem textura (top-1 de 76,13% para 60,18%).

• **RQ2 (Mecanismo explicativo):** Altamente relevante, e provavelmente a referência central da revisão para esta questão. Estabelece por intervenção causal que CNNs treinadas no ImageNet classificam por textura local, o que explica diretamente por que denoising, blur e suavização em geral degradam classificadores: removem justamente o sinal em que a rede se apoia.

• **RQ3 (Relação quantitativa):** Relevante. A exceção do blur liga explicitamente a distribuição de energia espectral do conjunto de treino à magnitude da degradação sob uma filtragem específica — evidência de que a relação entre banda alterada e perda de desempenho é mediada pelo conteúdo espectral dos dados, e não fixa.

• **RQ4 (Condições de melhoria):** Altamente relevante. Delimita com precisão a condição em que reduzir a dependência de textura melhora em vez de piorar: usar o conjunto sem textura como aumento junto ao original, e não como substituto. Treinar só em SIN custa 16 pontos de top-1; treinar em SIN+IN com ajuste fino supera a linha de base em acurácia limpa (76,72% contra 76,13%), em detecção (75,1 contra 70,7 mAP50) e em robustez (mCE 69,3 contra 76,7).

Qualidade Metodológica e Validade

É o artigo de maior qualidade metodológica entre os já incorporados a esta revisão: publicado em veículo de primeira linha, com desenho psicofísico controlado (48.560 ensaios em 97 observadores), intervenção causal sobre os dados de treino, cinco arquiteturas, cinco datasets, comparação humana como referência e disponibilização integral de pesos, código, dataset e dados comportamentais. Para o nosso SLR, seu valor é duplo. Primeiro, fornece o mecanismo mais bem sustentado da literatura para a hipótese central da revisão: se a CNN classifica por textura local, então qualquer pré-processamento que suavize textura remove o sinal discriminativo. Segundo, o caso do borramento é uma evidência rara e valiosa para a RQ3, por mostrar que a suscetibilidade a uma filtragem espectral específica é predita pela distribuição espectral do conjunto de treino, e não por uma propriedade fixa da arquitetura.